

# MÉMOIRE

*présenté à*

**L'Institut Supérieur des Gestion de Gabès**

*en vue de l'obtention du diplôme de*

**Mastère de recherche en  
Informatique Décisionnelle et de Gestion**

*par*

**AICHA AKROUT**

**Classification des signaux EEG pour l'utilisation  
d'Interfaces Cerveau-Machine dans des  
applications d'imagination motrice**

*Soutenu le 10 / 04 / 2021 devant la commission d'examen :*

**M. Mohamed GHORBEL**

**Mlle. Hela FEHRI**

**M. Rafik KHEMAKHEM**

**Mlle. Amira ECHTIOUI**

Président

Rapporteur

Encadrant

Co-encadrante

**Année Universitaire : 2020 / 2021**

## *Dédicaces*

*Je dédie ce mémoire à ma chère **Mère**, qui a toujours cru en moi, et qui m'a constamment encouragé à persévérer dans mes études, car dit-elle, le savoir est la clé de la réussite.*

*Je dédie aussi ce mémoire à mon frère **Borhan**, pour son immense soutien ainsi que son aide grandement appréciée.*

*À ma sœur Rawdha.  
À mes frères.  
À mes amis.*

# **Remerciements**

*Je remercie tout d'abord **Dieu** tout puissant de nous avoir donné la santé et la volonté d'entamer et de terminer ce mémoire.*

*Je voudrais remercier **M. Mohamed GHORBEL**, Maître de conférences à l'ENET'COM-Sfax, pour m'avoir fait l'honneur de présider mon jury de ce mémoire.*

*Je souhaite aussi adresser de sincères remerciements à **Mlle. Hela FEHRI**, Maître-assistante à l'ISG-Gabès, d'avoir accepté de faire partie du jury de ce mémoire.*

*Un grand remerciement à **M. Rafik KHEMAKHEM**, maitre-assistant, et chef de département de l'informatique à l'ISG-Gabès, pour son aide, sa coopération et ses conseils très utiles, qui m'ont permis d'achever et de mener à bien ce mémoire.*

*Je tiens également à remercier **Mlle. Amira ECHTIOUI**, enseignante à l'ISIMS-Sfax pour sa collaboration durant ce travail de thèse, avec ses connaissances dans ce domaine de recherche ainsi que ses conseils et ses informations constructives qui ont renforcé la qualité de ce travail de recherche. Qu'elle me permet de lui exprimer l'assurance de ma gratitude et de mon profond respect.*

*Finalement, je tiens à remercier tous ceux et celles qui ont contribué, de près ou de loin, à réussir ce travail.*

# Table des matières

<b>Introduction générale.....</b>	<b>1</b>
<b>Chapitre 1 : Généralités sur les Interfaces Cerveau-Machine basées sur l'imagination motrice.....</b>	<b>2</b>
1. Introduction.....	2
2. Principes de base du fonctionnement d'une ICM .....	2
2.1 Définition d'une ICM .....	2
2.2 Structure générale d'une ICM .....	3
3. Quelques notions de neurophysiologie .....	3
4. Les techniques d'acquisition des activités cérébrales .....	5
4.1 Technique non-invasives .....	6
4.1.1 Imagerie par résonance magnétique fonctionnelle .....	6
4.1.2 Magnétoencéphalographie MEG.....	6
4.1.3 Electroencéphalographie EEG .....	7
4.2 Technique invasive .....	10
4.2.1 Electrocorticographie ECoG .....	10
4.3 Comparaison entre les différentes techniques d'enregistrement .....	11
5. Phénomènes neurophysiologiques utiles pour les ICMs.....	12
5.1 Potentiel cortical lent SCP .....	12
5.2 Potentiel évoqué P300 .....	13
5.3 Imagination motrice.....	14
5.4 Comparaison entre les phénomènes neurophysiologiques utilisés en ICM.....	15
6. Conclusion .....	15
<b>Chapitre 2 : Classification des mouvements d'imagination motrice en se basant sur l'apprentissage profond .....</b>	<b>16</b>

1. Introduction.....	16
2. Etat de l’art.....	16
3. Méthodologie proposée.....	18
3.1 Prétraitement des signaux EEG .....	18
3.2 Extraction des caractéristiques .....	19
3.2.1 Wavelet Packet Decomposition (WPD) .....	19
3.2.2 Common Spatial Pattern (CSP).....	19
3.3 Classification .....	20
3.3.1 Réseau de neurones artificiels (ANN).....	20
3.3.2 Réseaux de neurones convolutifs (CNN) .....	24
3.3.3 Combinaison des deux CNNs.....	26
4. Conclusion .....	27
<b>Chapitre 3 : Évaluation de la méthodologie proposée pour la classification des mouvements d’imagination motrice.....</b>	<b>28</b>
1. Introduction.....	28
2. Présentation des bases de données .....	28
3. Métrique d’évaluation .....	29
4. Résultats expérimentaux .....	29
4.1 Classification basée sur l’ANN .....	30
4.2 Classification basée sur le CNN .....	33
4.3 Classification basée sur la combinaison des deux CNNs .....	34
4.4 Etude comparative entre ANN, CNN et la combinaison des deux modèles CNNs .....	35
5. Conclusion .....	39
<b>Conclusion Générale .....</b>	<b>40</b>
<b>Références.....</b>	<b>41</b>

## Liste des figures

<b>Figure 1</b> : Schéma de fonctionnement d'une ICM .....	3
<b>Figure 2</b> : Les quatre lobes de l'hémisphère gauche. ....	4
<b>Figure 3</b> : Organisation somatotopique du cortex moteur primaire.....	5
<b>Figure 4</b> : Exemple de résultats d'IRMf. ....	6
<b>Figure 5</b> : La Magnétoencéphalographie. ....	7
<b>Figure 6</b> : Présentation d'un signal EEG. ....	8
<b>Figure 7</b> : Les rythmes cérébraux .....	9
<b>Figure 8</b> : Mise en place des électrodes selon le système international 10/20, <b>A</b> : vue sagittale gauche de la tête, <b>B</b> : vue horizontale dorsale de la tête. ....	10
<b>Figure 9</b> : Electrocorticographie ECoG. ....	11
<b>Figure 10</b> : Représentation de SCP sur 45 secondes .....	13
<b>Figure 11</b> : Potentiel évoqué P300.....	13
<b>Figure 12</b> : Effet de l'imagination motrice de la main gauche et de la main droite sur les signaux EEG. .	14
<b>Figure 13</b> : Méthodologie proposée.....	18
<b>Figure 14</b> : Traitement de la décomposition de paquets d'ondelettes à 3 niveaux.....	19
<b>Figure 15</b> : Modèle ANN utilisé.....	21
<b>Figure 16</b> : Schéma d'un réseau de neurones avec des couches dense. ....	22
<b>Figure 17</b> : exemple des couches dropout. ....	23
<b>Figure 18</b> : Processus du pooling. ....	25
<b>Figure 19</b> : couche Flatten.....	25
<b>Figure 20</b> : Modèle CNN utilisé.....	26
<b>Figure 21</b> : Combinaison des deux modèles CNNs.....	27
<b>Figure 22</b> : Schéma temporel du paradigme.....	29
<b>Figure 23</b> : Etude comparative entre les modèles ANN, CNN et la combinaison des deux modèles CNNs. .....	36
<b>Figure 24</b> : La différence entre les valeurs de précision de la classification entre les sujets.....	37

## Liste des tableaux

<b>Tableau 1 :</b> Les différents rythmes cérébraux. ....	8
<b>Tableau 2 :</b> Comparaison entre les différentes techniques de mesures utilisées pour les ICMs. ....	11
<b>Tableau 3 :</b> Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation d'un seul bloc (en %). ....	30
<b>Tableau 4 :</b> Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation de quatre blocs (en %). ....	30
<b>Tableau 5 :</b> Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation de cinq blocs (en %). ....	31
<b>Tableau 6 :</b> Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation de six blocs (en %). ....	31
<b>Tableau 7 :</b> Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation de sept blocs (en %). ....	32
<b>Tableau 8 :</b> Précision de la classification obtenue par l'application du modèle ANN (en %). ....	32
<b>Tableau 9 :</b> Précision de la classification obtenue par l'application du modèle CNN (en %). ....	34
<b>Tableau 10 :</b> Précision de la classification obtenue par l'application de la combinaison des deux modèles CNNs (en %). ....	35
<b>Tableau 11 :</b> Valeurs de précision obtenues par l'application du ANN, CNN, et la combinaison des deux modèles CNNs. ....	35
<b>Tableau 12 :</b> Tableau comparative entre la méthode proposé et quelques méthodes de l'état de l'art. ....	38

## **Liste des abréviations**

**ACP** : Analysis Component Principal

**ANN** : Artificial Neural Network

**BOLD** : Blood Oxygen Level-Dependent

**CNN** : Convolutional Neural Network

**CNV** : Contingent negative Variation

**CSP** : Common Spatial Patterns

**EEG** : Electroencéphalographie

**ECoG** : Electrocorticographie

**ERD** : Evenement Related Desynchronization

**FBCSP** : Filtre Bank Common Spatial Patterns

**ICM** : Interface Cerveau Machine

**LED** : Light-Emitting Diode

**LIS** : Locked-In Syndrom

**MEG** : Magnétoencéphalographie

**MI** : Motor Imagery

**PEV** : Potentiels Evoqués Visuels

**SAE** : Stacked Auto-Encoder

**SCP** : Slow cortical potential

**SLA** : Sclérose Latérale Amyotrophique

**SPIR** : Spectroscopie proche infrarouge

**SQUID** : Superconducting Quantum Interference Device

**SRM** : Sensorimoteur



**STFT** : Sort-Time Fourier Transform

**TOD** : Transform Ondelette Discret

**TP** : True Positive

**WPD** : Wavelet Packet Decomposition

# Introduction générale

Une Interface Cerveau Machine (ICM) est une forme émergente de dispositif permettant d'établir une communication directe entre le monde extérieur et le cerveau humain sans passer par les voies usuelles nerveuses et musculaires

Le contrôle des machines par la pensée est un sujet d'actualité de plus en plus intégré dans diverses applications. Les ICM sont principalement destinées aux personnes gravement handicapées qui ont perdu toutes leurs capacités d'expression ou de mouvement. En effet, cette technique peut leur offrir une nouvelle possibilité de regagner le lien avec leur environnement en remplaçant les mouvements des organes humains par des actions d'une machine.

Durant ces dernières années, les techniques utilisées pour la conception des interfaces cerveau machine se sont largement développées. Ainsi, des nouvelles méthodes de traitement du signal dédiées pour chaque type de tâches mentales viennent régulièrement d'apparaître dans le but d'amener les ICM à l'extérieur d'un environnement de laboratoire contrôlé. Cependant, malgré les développements technologiques, il existe de nombreux obstacles devant la construction d'une ICM efficace. Les plus grands défis sont liés à la précision, à la rapidité et à l'efficacité. En raison des limitations, aucun système d'ICM n'est encore disponible sur le marché.

Ce mémoire est organisé en 3 chapitres :

Dans un premier chapitre, les compétences et les connaissances nécessaires à la conception d'une ICM basée sur l'imagination motrice, seront expliquées et détaillées.

Dans le deuxième chapitre, nous présenterons l'état de l'art sur les méthodes qui ont opté pour la classification des mouvements d'imagination motrice. Ainsi que les détails de la méthodologie proposée dans le but d'effectuer la tâche de classification.

Dans le troisième chapitre, nous ferons une description de la base de données utilisée et la métrique d'évaluation de la classification. Ensuite, nous présenterons les expériences réalisées et les résultats obtenus avec leurs interprétations et une étude comparative entre les méthodes utilisées sera établie.

Une conclusion générale résumera l'ensemble des résultats obtenus et envisagera quelques perspectives ouvrant le chemin pour les travaux futurs.

# **Chapitre 1 :**

## **Généralités sur les Interfaces Cerveau-Machine basées sur l'imagination motrice**

### **1. Introduction**

Le principe d'une ICM est de détecter l'activité cérébrale et de la convertir en commandes qui expriment la volonté du sujet à exécuter des tâches spécifiques. Ces commandes seront envoyées vers des dispositifs de contrôle tels que des prothèses et des ordinateurs. Ils peuvent aider certains patients affectés par certaines maladies comme la Sclérose Latérale Amyotrophique (SLA), à communiquer avec le monde extérieur. Cette nouvelle voie est indépendante des nerfs et des muscles périphériques de l'utilisateur. L'interprétation d'une tâche mentale vers une commande d'une machine n'est pas un travail facile et requiert des compétences variées. Le développeur d'une ICM doit avoir des connaissances en neurophysiologie afin de comprendre l'origine et les caractéristiques de différentes tâches mentales. De même, des connaissances en matière de technologies d'imagerie cérébrale sont primordiales afin de comprendre les avantages et les inconvénients de chaque technique et d'utiliser la plus adéquate à l'ICM dans les meilleures conditions. Après l'acquisition des signaux, des connaissances profondes des méthodes de traitement du signal sont nécessaires pour concevoir une ICM de hautes performances.

Ce chapitre présente en première partie le principe de base de fonctionnement d'une ICM. La seconde partie met en évidence les notions des neurophysiologies a pour but de connaître la source des activités cérébrales. La troisième partie montre les principales technologies utilisées pour quantifier ces activités. La quatrième section s'intéresse au phénomène neurophysiologie les plus utilisées dans la création des ICMs.

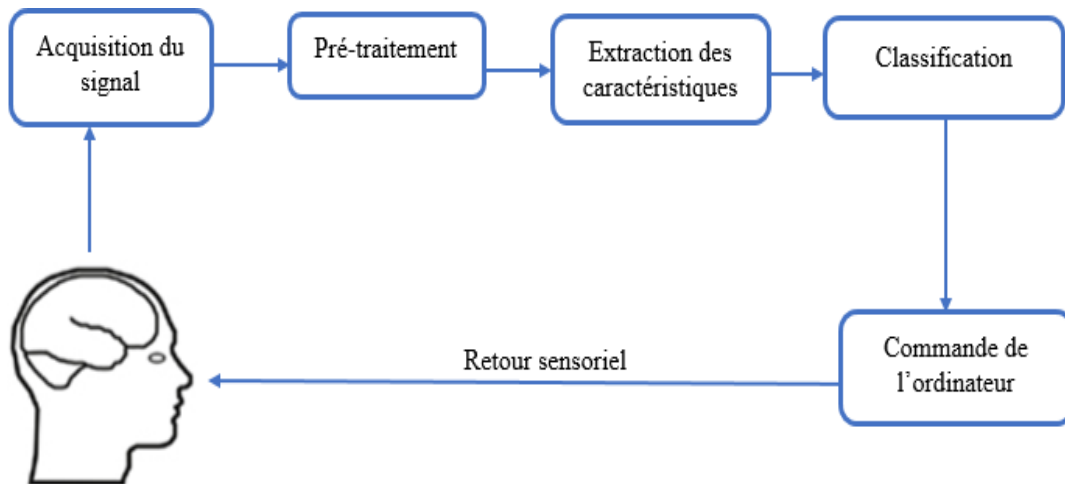
### **2. Principes de base du fonctionnement d'une ICM**

#### **2.1 Définition d'une ICM**

Une ICM désigne un système de liaison directe entre un cerveau d'un utilisateur et une machine, permettant à un individu d'effectuer des tâches. Ce type de dispositif permet de contrôler par la pensée un ordinateur ou une prothèse, sans solliciter ses bras, mains ou jambes.

## 2.2 Structure générale d'une ICM

De manière générale, la conception d'une ICM requiert des étapes : acquisition de l'activité cérébrale, prétraitement des signaux, extraction de caractéristiques, classification, commande de l'ordinateur et retour sensoriel [1].



**Figure 1 :** Schéma de fonctionnement d'une ICM

- **Acquisition du signal :** Cette étape consiste à mesurer les activités cérébrales et on les convertit en signaux numériques.
- **Prétraitement du signal :** Il s'agit d'extraire du signal biologique des commandes brutes.
- **Extraction des caractéristiques :** Le but de cette étape est de soutenir les informations les plus appropriées qui représentent une tâche mentale dans un signal. Cette phase permet de créer un vecteur caractéristique représentatif de la tâche.
- **Classification :** Cette étape consiste à attribuer une classe à chaque tâche mentale.
- **Commande de l'ordinateur :** Il s'agit de traduire le signal de contrôle en commandes et de contrôler une machine.
- **Retour sensoriel :** Ce retour permet à l'utilisateur d'apprendre à contrôler l'interface.


## 3. Quelques notions de neurophysiologie

Le cerveau est supposé l'organe le plus important dans le corps humain. La complexité de cet organe est donnée par le nombre de substance qu'il contient. De plus son utilité se voit dans le fonctionnement des autres organes du corps qui sont tous en relation directe avec le cerveau. Parmi

les fonctions de cerveau, nous citons le contrôle des actions de l'organisme à partir des informations sensorielles qu'ils parviennent.

Le cerveau se compose de deux hémisphères, droit et gauche, quasi-symétriques [2]. Le cortex cérébral est la couche externe du cerveau. Il comprend une écorce de plusieurs couches de cellules.

Le cortex peut être divisé en quatre zones ou lobes selon les fonctions cognitives [3].




**Figure 2 :** Les quatre lobes de l'hémisphère gauche.

- **Le lobe frontal :** c'est la partie avant du cerveau. Il est responsable du contrôle des mouvements volontaires. De même, il intervient dans les fonctions liées à la planification et au langage.
- **Le lobe pariétal :** c'est la partie derrière le lobe frontal dans la partie supérieure du cerveau. Il est responsable essentiellement des fonctions somato-sensorielles qui assurent le traitement des informations en provenance de la peau comme la chaleur et la texture.
- **Le lobe occipital :** c'est la partie arrière du cerveau. Il est responsable des fonctions liées à la vision.
- **Le lobe temporal :** c'est la partie qui se situe entre l'arcade auxiliaire et l'oreille. Il intervient dans certaines fonctions sensorielles, émotionnelles, de mémorisation et de compréhension.

Le cortex cérébral est divisé en plusieurs aires fonctionnelles dont chacune assure une fonction cognitive précise. Les aires motrices (cortex moteur) sont situées dans la partie postérieure du lobe frontal, contigu le sillon central. L'aire motrice primaire ou cortex moteur primaire, également appelée M1, est le centre de la commande motrice. Son activité est à l'origine de la planification, du contrôle et de l'exécution des mouvements volontaires [4]. Chaque organe moteur est relié à une région spécifique comme illustré dans la figure 3.

Le système nerveux est essentiellement constitué par les neurones. Il existe plus de 100 milliards de neurones dans le système nerveux humain, dont un peu moins de 20 milliards dans le cortex [5].



**Figure 3 :** Organisation somatotopique du cortex moteur primaire.

#### 4. Les techniques d'acquisition des activités cérébrales


Dans cette section, nous allons détailler les principales techniques d'acquisition des activités cérébrales. Ces techniques sont soit superficielles non invasives telles que l'EEG et la MEG ou invasives comme l'EEG intracérébral (IEEG).

## 4.1 Technique non-invasives

Il existe des techniques d'enregistrement qui nous permettent de recueillir des signaux « de surface » qui sont l'Imagerie par Résonance Magnétique fonctionnelle IRMf, la MagnétoEncéphalographie MEG, et l'électroencéphalographie EEG.

### 4.1.1 Imagerie par résonance magnétique fonctionnelle

L'IRM fonctionnelle (IRMf) est apparu en 1990, c'est une technique qui consiste en une mesure quantitative de l'activité cérébrale lors de l'exécution de tâches comportementales. Comme par exemple, pendant un exercice particulier, de calcul mental, rappel en mémoire d'une face, ou aussi l'observation de représentations projetées sur un écran, le flux sanguin attaché à cet exercice est étudié par l'IRMf, et permet donc de reconnaître les zones du cerveau qui sont compromises dans l'exercice. L'IRMf est aujourd'hui une technique de premier choix pour l'étude de l'activité du cerveau au cours du temps et de manière non invasive. Elle possède une résolution spatiale de 3 à 4 mm et une résolution temporelle de l'ordre d'une seconde. En plus de l'encombrement, le coût élevé et la complexité du dispositif expérimental rendent son utilisation peu adaptée au domaine des ICMs. La figure 4 présente un exemple d'IRMf qui représente une cartographie des aires corticales impliquées dans l'acquisition du langage chez l'enfant.



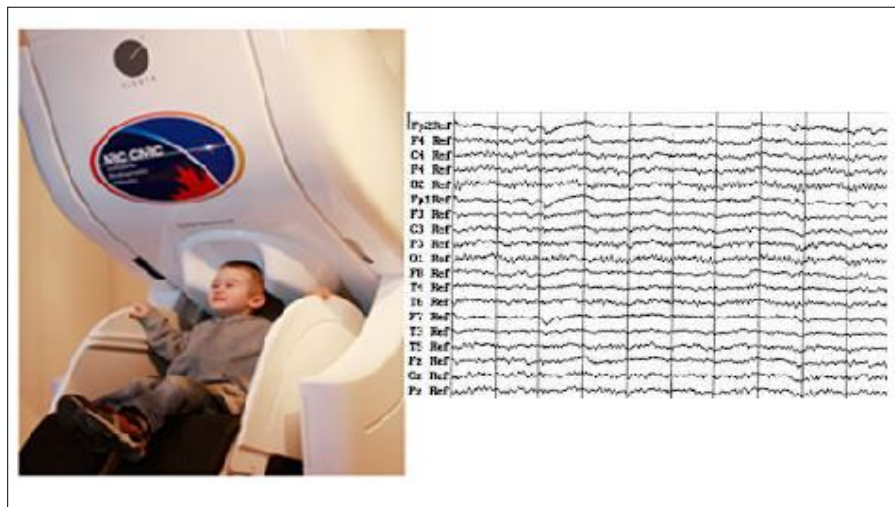
**Figure 4 :** Exemple de résultats d'IRMf.

### 4.1.2 Magnétoencéphalographie MEG

La magnétoencéphalographie (MEG) est une technique non invasive permise d'enregistrer des signaux originaux de champs magnétiques très faibles produits par le cerveau en activité pour en comprendre son fonctionnement et en déceler ses pathologies.

La MEG permet aux scientifiques et aux médecins de mesurer l'activité du cerveau en temps réel, en accordant des informations exactes sur le fonctionnement du cerveau en tout ce qui intéresse plus précisément le goût, le toucher, la parole, la vue...

Les champs magnétiques mesurés à la surface du scalp sont très faibles de l'ordre de 10 femto-Teslas ( $1\text{fT}=10^{-15}$  Tesla), comparé avec le champ magnétique terrestre qui est de 10 milliards de fois plus grand. Pour la mesure de champ magnétique, la MEG utilise un appareillage basé sur des magnétomètres à Superconducting Quantum Interference Device (SQUID) placé dans une pièce isolée magnétiquement par du mu-métal qui sont refroidis à l'hélium limitent son utilisation dans le domaine des ICMs.




**Figure 5 : La Magnétoencéphalographie.**

#### **4.1.3 Electroencéphalographie EEG**

Cette technique expose aussi bien des bénéfices que des inconvénients. Au nombre des avantages du EEG, nous savons mentionner :

- Sa bonne résolution temporelle.
- Technique non invasive.
- Cout réduit.






**Figure 6 :** Présentation d'un signal EEG.

Le signal EEG est composé par différentes bandes définies selon leur fréquence d'ondes afin de caractériser et d'identifier des états psychologiques en neurosciences. Nous présentons ces bandes dans le tableau 1 et la figure 7.

**Tableau 1 :** Les différents rythmes cérébraux.

<b>Rythme cérébral</b>	<b>Bande de fréquence</b>
<b>Delta</b>	Inférieure à 4 Hz
<b>Thêta</b>	4 à 8 Hz
<b>Alpha</b>	8 à 13 Hz
<b>Beta</b>	13 à 30 Hz
<b>Gamma</b>	Supérieure à 30 Hz




**Figure 7 : Les rythmes cérébraux**

- **Rythmes delta** : Ce sont des ondes lentes. Elles sont exposées lors d'un état de méditation profond ou d'un état sans rêves.
- **Rythmes thêta** : Ce sont des ondes exposées lors d'un sommeil profond. Ces ondes font une tâche lors de l'apprentissage et de la consolidation de mémoires.
- **Rythmes alpha** : Ce sont ondes qui se présentent lors d'un état d'éveil de vigilance ou de méditation légère. Elles sont adjointes à la synchronisation d'activité mentale et à l'apprentissage.
- **Rythmes bêta** : Ce sont ondes qui se présentent lors d'un état d'éveil lorsque notre attention est engagée par des tâches ou le monde externe.
- **Rythmes gamma** : Ce sont les ondes les plus rapides. Elles sont reliées au traitement de données par diverses régions du cerveau (c'est-à-dire la synchronisation de nombreuses régions du cerveau). Elles sont exposées lors d'états requérant un haut niveau de concentration ou d'attention.

Les bandes Alpha et Bêta sont les bandes de fréquences les plus utilisées en ICM basée sur l'imagination motrice [6].

Le système international 10/20 est une méthode internationalement reconnue pour décrire l'emplacement des électrodes du cuir chevelu. Ce système est basé sur la relation entre l'emplacement d'une électrode et la zone sous-jacente du cortex cérébral. Les nombres 10 et 20 font référence au fait que les distances entre électrodes adjacentes sont soit 10% soit 20% du total avant-arrière ou droite-gauche du crâne (figure 8).



**Figure 8 :** Mise en place des électrodes selon le système international 10/20, **A :** vue sagittale gauche de la tête, **B :** vue horizontale dorsale de la tête.

Chaque électrode est identifiée par une lettre et un chiffre, dont la lettre identifie la région (C : centrale, F : frontale, O : occipitale, T : temporale ; pariétale), les chiffres pairs pour l'hémisphère droit et les chiffres impairs pour l'hémisphère gauche. La lettre Z est pour la référence aux électrodes qui sont localisées sur la ligne centrale.


## 4.2 Technique invasive

### 4.2.1 Electrocorticographie ECoG

Il s'agit de placer une matrice d'électrodes sur la dure-mère ou directement à la surface du cortex cérébrale (figure 9).

Les signaux acquis sont de meilleure qualité c'est-à-dire ils offrent d'excellent rapport signal sur bruit.

Cette technique présente moins de risques par rapport aux approches intra-corticale tout en offrant une meilleure résolution que les systèmes non-invasifs.



**Figure 9 :** Electrocorticographie ECoG.

### 4.3 Comparaison entre les différentes techniques d'enregistrement

La résolution spatiale indique la capacité de la technique à distinguer ou séparer deux ou plusieurs activités cérébrales spatialement proches tandis que la résolution temporelle indique sa sensibilité aux changements rapides dans le traitement neuronal. Ce critère est très important dans le domaine des ICMs. Ainsi, parmi toutes les techniques d'enregistrement, l'EEG est la plus utilisée dans les systèmes ICM pratiques. Les autres techniques sont principalement utilisées pour des recherches fondamentales et des fins médicales. Le tableau 2 résume les principales propriétés des techniques d'imagerie présentées dans cette section.

**Tableau 2 :** Comparaison entre les différentes techniques de mesures utilisées pour les ICMs.

Technique de mesure	Nature de signal	Résolution spatiale	Résolution temporelle	Invasive	Probabilité
<b>ECoG</b>	Electrique	1 mm	30 ms	Oui	Oui
<b>IRMf</b>	Métabolique	5 mm	1 s	Non	Non
<b>MEG</b>	Magnétique	5 mm	50 ms	Non	Non
<b>EEG</b>	Electrique	1 mm	50 ms	Non	Oui
<b>EOG</b>	Oculaire	-	10 ms	Non	Oui
<b>SPIR</b>	Métabolique	1 cm	10 s	Non	Oui

## **5. Phénomènes neurophysiologiques utiles pour les ICMs**

Parmi les principaux phénomènes neurophysiologiques convenables utilisés en ICM, on peut citer par exemple les SCP (Slow Cortical Potentials), le P300 (Potentiel évoqué P300), et les signaux ERD/ERS (Event-Related Desynchronization / Event-Related Synchronization).

### **5.1 Potentiel cortical lent SCP**


Les SCP traduisent l'attention phasique et l'activation préparatoire. Les SCP ont une durée de 100ms à nombreuses secondes et sont attachés au niveau des régions corticales sous-jacentes c'est-à-dire de la couche apicale dendritique du néocortex.

Les SCP sont généralement digérés aux CNV (Contingent negative Variation ou Onde de variation contingente négative, lors d'une tâche de préparation attentionnelle.). Les CNV sont spécifiquement examinées lors de l'anticipation d'un événement espéré et sont supposées renvoyer l'activation des ressources essentielles pour débiter des réponses cognitives ou motrices correspondantes. Des changements dans les SCP dans une direction négative figurent un seuil d'excitation neuronale réduit et en conséquence une élévation de la préparation à répondre ou à réaliser une action anticipée.

Un changement des SCP dans la direction positive indice une excitabilité corticale réduite (un accroissement du seuil d'excitabilité) et ainsi une affaiblie préparation à répondre. Les SCP négatives ont été accordées avec une excitabilité supérieure des aires corticales sous-jacentes donc qu'à une feed-back corticale déficiente.

Le neurofeedback a pour but d'expliquer à réduire cette changement négatif et l'éveil cortical accordé. Durant l'apprentissage, l'accent est mis sur la potentialité à modifier entre déflexion positive et négative des SCP pour agrandir la capacité à discriminer ces deux processus et leurs corrélations comportementales.

Le but des protocoles SCP ou CNV est subséquemment d'influencer l'excitabilité corticale, mesure de l'éveil et de l'attention.



**Figure 10 :** Représentation de SCP sur 45 secondes

## 5.2 Potentiel évoqué P300

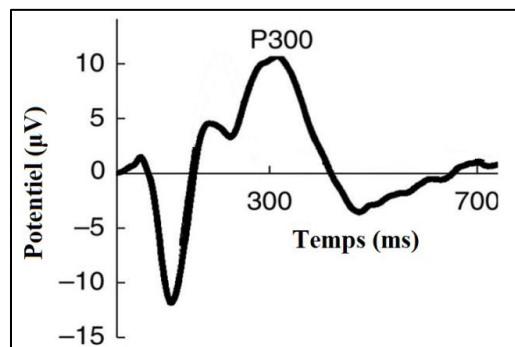
Les potentiels évoqués PE ou (ERP: Event Related Potentials) sont des activités cérébrales provoquées par des stimulations externes comme l'excitation des cellules sensorielles ou internes comme les activités cognitives. Ils peuvent être divisés en deux classes :

- **Exogènes :** qui sont le résultat d'un traitement automatique du stimulus (résultats tôt).
- **Endogènes :** qui sont le résultat d'un traitement plus conscient du stimulus (résultats plus tard).

Les signaux de la classe endogène peuvent être utilisés dans le domaine de l'ICM car ils dépendent du stimulus et de l'attention du sujet ce qui peut refléter un choix ou une décision [7].

On peut détecter le signal P300 à partir du lobe occipital. Les électrodes qui fournissent les signaux les plus pertinents sont : Fz, Cz, et Pz [8].

La figure 11 illustre la forme du signal P300. Le temps entre le stimulus et la réponse est variable (entre 250 et 350 ms) tandis que la durée de la réponse est assez courte (entre 50 et 100 ms) [9].

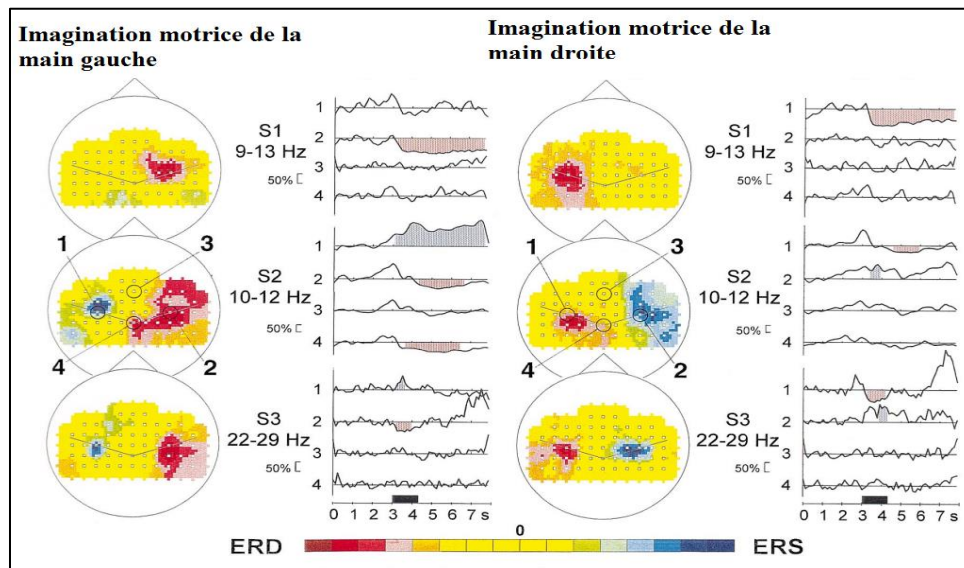


**Figure 11 :** Potentiel évoqué P300.

### 5.3 Imagination motrice

L'imagination motrice est la répétition mentale des actes moteurs sans mouvements apparents. Elle peut impliquer la simulation mentale du mouvement et par la suite l'activation d'une grande partie du lobe frontale par la génération d'activités cérébrales similaires à celles générées lors de la préparation et de l'exécution réelle du moteur. En conséquence, l'imagination motrice produit des changements dans les oscillations sensorimotrices du cerveau naturellement présents dans la planification et l'exécution de l'action.

Les signaux ERD/ERS peuvent être utilisés pour représenter les processus moteurs. Il s'agit d'une diminution (ERD) ou d'une augmentation dans l'amplitude des composantes oscillatoires du signal EEG [10]. On peut distinguer les différents types d'imaginations motrices suivant la zone correspondante dans le cortex moteur primaire conformément à la figure 3. Par exemple, l'imagination du mouvement de la main droite, de la main gauche et des pieds peut être détectée avec les signaux EEG en provenance des électrodes C3, C4 et Cz respectivement [11]. Les oscillations cérébrales les plus importantes impliquées dans l'imagination motrice des mouvements des mains sont le rythme mu rolandique (7-13 Hz) et le rythme bêta central (13-30 Hz) [12]. La figure 12 présente un exemple sur la génération des signaux ERD/ERS lors de l'imagination des mouvements de la main droite et de la main gauche [13].



**Figure 12 :** Effet de l'imagination motrice de la main gauche et de la main droite sur les signaux EEG.

## **5.4 Comparaison entre les phénomènes neurophysiologiques utilisés en ICM**

Les méthodes d'enregistrement invasives ou non ayant des avantages et des inconvénients. L'EEG de surface et la MEG présentent l'avantage d'une vision globale avec une précision temporelle élevée et d'une mise en place simple. Ces enregistrements présentent des inconvénients parce que les signaux sont perturbés par différents types d'artéfacts (oculaires, musculaires, etc...). L'EEG et la MEG ont des avantages. En effet, et pour la localisation de sources des pointes, la MEG donne de bons résultats pour la localisation et a montré de bon potentiel pour la localisation des générateurs oscillatoires. Pour l'IEEG, les électrodes de profondeur sont installées directement dans le crâne pendant une opération sous anesthésie. Ceci résulte en des signaux possèdent un rapport signal à bruit. Les méthodes d'enregistrement invasives ou non sont devenus des outils connus. Ils autorisent de décrire l'activité du cerveau et ses changements pendant les tâches cognitives, pour le diagnostic et le suivi de nombreuses pathologies du système nerveux central.

## **6. Conclusion**

Tout au long de ce chapitre, nous avons présenté les différents blocs fonctionnels de l'ICM. Par la suite, nous avons présenté les notions de base de la neurophysiologie afin de comprendre l'origine et les caractéristiques des activités cérébrales. Ensuite, nous avons mis l'accent sur la technique d'imagerie cérébrale qui définit comme l'ensemble des méthodes et des techniques de mesure du cerveau. En premier lieu, nous avons commencé par une description des techniques invasives, puis nous avons enchaîné avec les techniques les plus utilisées dans les interfaces cerveau machine qui sont les techniques non invasives pour conclure que l'EEG est la technique la plus adéquate aux ICMs. Dans ce qui suit, nous avons cité les principaux phénomènes neurophysiologiques convenables pour la conception des ICM étaient détaillés. Dans le chapitre suivant, nous allons détailler notre méthodologie utilisée pour la classification des tâches d'imagination motrice.



## **Chapitre 2 :**

# **Classification des mouvements d'imagination motrice en se basant sur l'apprentissage profond**

### **1. Introduction**

Le cœur de ce chapitre présente la méthode de traitement des signaux EEG que nous avons proposés. Cette méthode a pour objectif de détecter au niveau cérébral, une intention de mouvement de la main gauche, la main droite, les deux pieds et la longue. Ce chapitre présente également, un état de l'art sur les méthodes de traitement des signaux les plus utilisés pour la classification des tâches d'imagination motrice. Dans la suite, nous donnons une description de différentes approches proposées.

### **2. Etat de l'art**

Récemment plusieurs chercheurs ont développé des méthodes pour la classification des mouvements d'imagination motrice en se basant sur la machine ou le deep learning. Dans [14], les auteurs ont appliqué les perceptrons multicouches (MLP) pour remplacer le classificateur traditionnel de Support Vector Machine (SVM). Dans [15], les auteurs ont combiné le CNN et le MLP pour former un nouveau classificateur qui classifie des tâches multi classes d'imagination motrice. Pour améliorer les performances des réseaux, le transfert d'apprentissage et distillation des connaissances étaient explorés dans laquelle le CNN a été utilisé comme un classificateur spécifique à 2D. Dans [16], le CSP et le CNN sont utilisés pour discriminer les signaux d'IM-EEG, surpassant le FBCSP avec un nouveau schéma de sélection des caractéristiques. Dans [17], les auteurs ont utilisé les caractéristiques temps-fréquence générées par une transformation de Fourier à court Terme en CNN avec des Stacked auto-encoder et ils ont obtenu une précision compétitive.

Les auteurs dans [18], ont le signal EEG temporel en une image multi spectrales. Cette image est considérée comme une entrée au Deep Recurrent Convolutional network. Dans [19], les auteurs ont proposé un « separated channel convolutional network » pour encoder les données multicanaux. Ensuite les caractéristiques codées sont concaténées et introduites dans un réseau de reconnaissance pour effectuer la reconnaissance finale de la tâche d'IM.

Dans [20], les auteurs ont appliqué les modèles Shallow CNN et deep CNN. Les deux ont donné des précisions plus élevées par rapport au FBCSP. Hauke et al ont utilisé un modèle CNN simplifié. Ils ont montré que leur modèle est efficace pour la classification des tâches d'IM de 109 patients [21] et sans aucun prétraitement [22].

D'autres méthodes conventionnelles basées sur l'apprentissage automatique ont été développées pour le décodage de l'imagination motrice et l'extraction de caractéristiques. Parmi ces méthodes, Filter Bank Common Spatial Patterns (FBCSP) qui sont basés sur les méthodes Common Spatial Patterns (CSP) [23,24]. Ces méthodes ont atteint de meilleure performance. Toutes ces méthodes utilisent des caractéristiques artisanales. Le SVM a été utilisée par de nombreux chercheurs en tant que classifieur [25,26]. L'Analyse en Composantes Indépendantes (ACI) et l'Analyse en Composantes Principales (ACP) ont été utilisées pour la réduction de dimensionnalité et l'élimination du bruit [27-29].

Récemment, il a été démontré que des techniques d'apprentissage profond tel que CNN, DBN et la machine Boltzmann restreinte (RBM) atteignaient des précisions compétitives pour le décodage des signaux EEG basée sur l'imagination motrice à l'aide du système automatisé d'extraction de caractéristiques. Les chercheurs [30] ont utilisé plusieurs RBM pour extraire des caractéristiques robustes pour l'ensemble de données d'IM. Le modèle CNN est considéré comme un choix populaire pour analyser les caractéristiques spatiales et classifier les signaux EEG [31,26,32,33]. DBN est appliqué pour extraire des caractéristiques temporelles des signaux EEG [34,35]. Certains chercheurs ont combiné CNN avec RNN pour extraire les caractéristiques spatiales et temporelles [31,26].

Une autre étude a utilisé le DBN et le SVM [34] pour la classification des tâches d'IM. Les caractéristiques CNN a été combinées avec des caractéristiques CSP pour donner de bonnes valeurs de précisions [33]. CNN a été utilisé avec RNN [35], pour extraire des caractéristiques multidimensionnelles et capturer des événements cognitifs des signaux d'IM. Le CNN et les auto-encodeurs ont été utilisés dans une étude pour la reconnaissance des émotions à l'aide de signaux EEG [35].

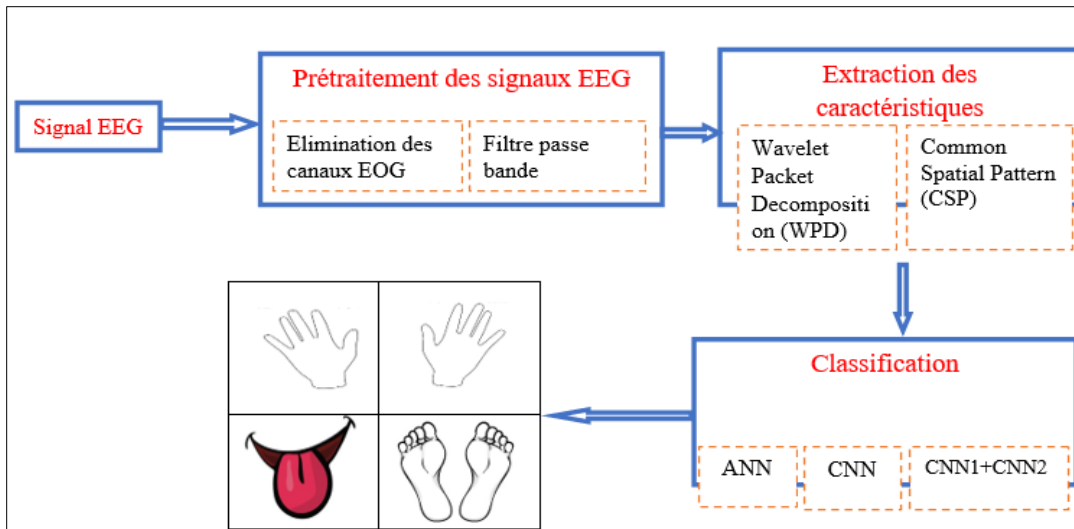
Le CNN a été utilisé pour la classification des images EEG qui ont été formées en transformant des signaux EEG 1D en 2D. Cette étude a proposé un nouvel ensemble de caractéristiques en combinant des informations spatiales, spectrales et temporelles dans des données EEG. Dans une autre étude

[33] le signal EEG est transformé en images en utilisant Short-Time Fourier Transform (STFT). Les caractéristiques des bandes mu et bêta ont été utilisées par certains chercheurs à l'aide du modèle CNN et l'autoencodeur empilé (SAE) pour la classification des tâches d'IM [36,37].

L'état de l'art mentionnés ci-dessous, nous amènons à proposer une nouvelle méthode de classification des tâches d'imagination motrice en fusion deux modèles CNNs. La section suivante détaille la démarche de notre méthodologie proposée.

### 3. Méthodologie proposée

Notre méthodologie proposée (figure 13) commence par un pré-traitement des signaux EEG, suivi d'une étape d'extraction des caractéristiques fréquentielles et spatiales. Par la suite, nous appliquons trois classifieurs : ANN, CNN, et la combinaison des deux modèles CNNs.



**Figure 13 : Méthodologie proposée.**

#### 3.1 Prétraitement des signaux EEG

Nous avons appliqué un simple prétraitement :

- On élimine les trois canaux EOG et on garde seulement les 22 canaux EEG.
- Application d'un filtre passe bande de 8 et 35 Hz. Ce type de filtre laissera passer les fréquences situées entre deux fréquences que nous avons choisi vu que les bandes de fréquences engagées dans les tâches d'imagination motrice sont les bandes Alpha (8-13 Hz) et Bêta (13-35 Hz).

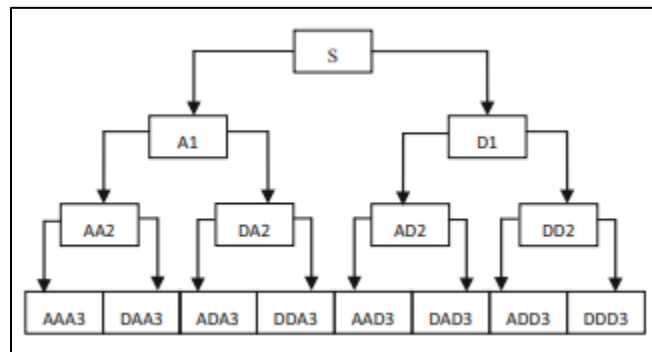
### 3.2 Extraction des caractéristiques

Dans cette étape, nous avons extrait des caractéristiques fréquentielles et spatiales respectivement à l'aide du Wavelet Packet Decomposition et le Common Spatial Pattern :

#### 3.2.1 Wavelet Packet Decomposition (WPD)

WPD est une transformée en ondelettes où le signal à temps discret passe à travers plus de filtres que le DWT, ce qui peut fournir une décomposition temps-fréquence à plusieurs niveaux des signaux. Dans le DWT, chaque niveau est calculé en passant uniquement les coefficients d'approximation d'ondelettes précédents, qui sont décomposés pour donner des informations d'approximation et de détail à un niveau supérieur. Cependant, dans le WPD, les coefficients de détail et d'approximation sont décomposés pour créer l'arbre binaire complet.

Pour  $n$  niveaux de décomposition, le WPD produit  $2^n$  ensembles différents de coefficients. La figure 14 donne le WPD à trois niveaux. Le symbole «S» représente un signal original. Les symboles «A» et «D» sont respectivement les coefficients d'approximation et de détail. On peut voir sur la figure 14 que dans l'analyse des paquets d'ondelettes, l'approximation et les détails à un certain niveau sont ensuite décomposés dans le niveau suivant, ce qui signifie que l'analyse des paquets d'ondelettes peut fournir une résolution de fréquence plus précise que l'analyse d'ondelettes.



**Figure 14 :** Traitement de la décomposition de paquets d'ondelettes à 3 niveaux.

#### 3.2.2 Common Spatial Pattern (CSP)

CSP est une technique de filtrage spatiale. Cette technique permet d'optimiser la différence des variances du signal EEG entre deux classes. Pendant la compétition de BCI qui a été passé en 2005, toutes les compétitions ont utilisé le CSP ou un algorithme dérivé du CSP [38].

L'algorithme CSP a été largement utilisé pour l'extraction de caractéristiques dans les systèmes des ICMs basés sur l'imagination motrice.

### **3.3 Classification**

Dans cette étape, nous avons appliqué les deux classifieurs ANN et CNN. De plus, nous avons proposé un autre classifieur qui combine deux modèles CNNs.

#### **3.3.1 Réseau de neurones artificiels (ANN)**

Les réseaux de neurones artificiels sont construits comme le cerveau humain, avec des nœuds de neurones interconnectés comme une toile. Le cerveau humain possède des centaines de milliards de cellules appelées neurones. Chaque neurone est composé d'un corps cellulaire qui est responsable du traitement des informations en transportant les informations vers (entrées) et éloignées (sorties) du cerveau.

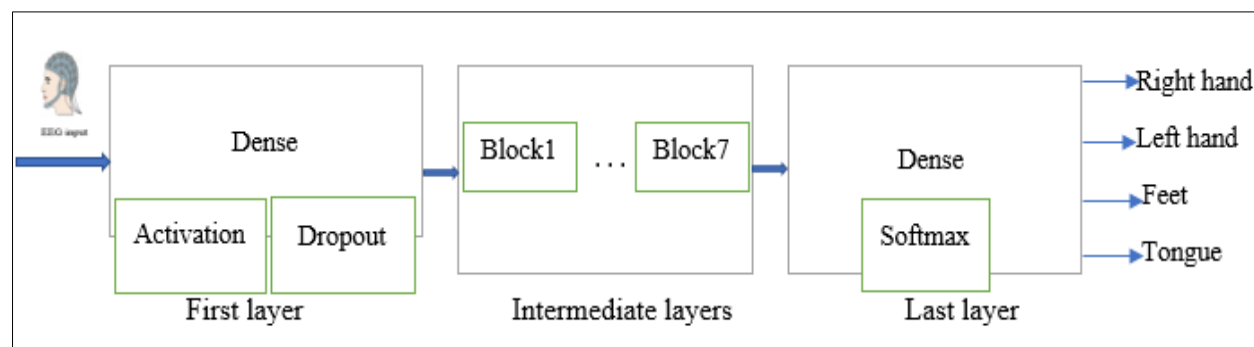
Un ANN a des centaines ou des milliers de neurones artificiels appelés unités de traitement, qui sont interconnectés par des nœuds. Ces unités de traitement sont constituées d'unités d'entrée et de sortie. Les unités d'entrée reçoivent diverses formes et structures d'informations basées sur un système de pondération interne, et le réseau neuronal tente de se renseigner sur les informations présentées pour produire un rapport de sortie. Tout comme les humains ont besoin de règles et de directives pour produire un résultat ou une sortie, les ANN utilisent également un ensemble de règles d'apprentissage appelé rétropropagation, une abréviation de propagation en arrière de l'erreur, pour perfectionner leurs résultats de sortie.

Un ANN passe initialement par une phase d'apprentissage où il apprend à reconnaître des modèles dans les données, que ce soit visuellement, auditif ou textuellement. Au cours de cette phase supervisée, le réseau compare sa production réelle produite avec ce qu'il était censé produire - la sortie souhaitée. La différence entre les deux résultats est ajustée à l'aide de la rétropropagation. Cela signifie que le réseau fonctionne à l'envers, allant de l'unité de sortie aux unités d'entrée pour ajuster le poids de ses connexions entre les unités jusqu'à ce que la différence entre le résultat réel et souhaité produise l'erreur la plus faible possible. Au cours de la phase de formation et de supervision, l'ANN apprend ce qu'il faut rechercher et ce que doit être sa sortie.

La figure 15 présente l'architecture ANN que nous avons utilisée. Une couche dense et une couche dropout, sont considérées comme une entre à l'architecture ANN. Les couches intermédiaires contiennent sept blocs. Chaque bloc est composé d'une couche Batch Normalisation, une couche dense, et une couche dropout. La dernière couche est la couche dense avec la fonction d'activation SoftMax.

Nous avons utilisé quatre fonctions d'activation :


- **Relu** : Rectified Linear activation est la fonction d'activation la plus couramment utilisée dans les modèles d'apprentissage profond. La fonction renvoie 0 si elle reçoit une entrée négative, sinon elle renvoie la valeur elle-même.
- **Elu** : Exponential Linear Unit est une fonction qui a tendance à faire converger le coût vers zéro plus rapidement et à produire des résultats plus précis.
- **Selu** : Scaled Exponential Linear Unit SELU est une sorte d'ELU mais avec une petite touche.
- **Tanh** : hyperbolic tangent Activation Function est aussi comme le sigmoïde logistique. La plage de la fonction Tanh va de (-1 à 1). L'avantage est que les entrées négatives seront mappées fortement négatives et les entrées nulles seront mappées près de zéro dans le graphique.



**Figure 15** : Modèle ANN utilisé

**Couches dense ou les couches entièrement connectées** : ces couches dans un réseau de neurones sont les couches où toutes les entrées d'une couche sont connectées à chaque fonction d'activation de la couche suivante. Dans les modèles d'apprentissage automatique les plus courants, les dernières couches sont des couches entièrement connectées qui compilent les données extraites par les couches précédentes pour former la sortie finale. C'est la deuxième couche la plus longue après

la couche de convolution. La figure suivante présente un réseau de neurones avec des couches dense.




**Figure 16 :** Schéma d'un réseau de neurones avec des couches dense.

**Couche SoftMax :** La fonction SoftMax calcule la distribution des probabilités de l'événement sur 'n' événements différents. D'une manière générale, cette fonction calculera les probabilités de chaque classe cible sur toutes les classes cibles possibles. Plus tard, les probabilités calculées seront utiles pour déterminer la classe cible pour les entrées données.

Le principal avantage de l'utilisation de SoftMax est la plage de probabilités de sortie. La plage sera de 0 à 1 et la somme de toutes les probabilités sera égale à un. Si la fonction SoftMax utilisée pour le modèle multi-classification, elle renvoie les probabilités de chaque classe et la classe cible aura la probabilité élevée.

**Couche dropout :** En termes simples, cette couche se réfère à l'ignorance d'unités (c'est-à-dire les neurones) pendant la phase d'entraînement d'un certain ensemble de neurones qui sont choisis au hasard. Plus techniquement, à chaque étape d'apprentissage, les nœuds individuels sont soit supprimés du réseau avec une probabilité  $1-p$ , soit conservés avec une probabilité  $p$ , de sorte qu'il reste un réseau réduit ; Les bords entrants et sortants d'un nœud abandonné sont également supprimés. La figure suivante présente la différence entre un réseau de neurones avant et après l'application du dropout.



**Figure 17 :** exemple des couches dropout.

**Couche Batch Normalisation :** La norme par lots est une technique de normalisation effectuée entre les couches d'un réseau neuronal plutôt que dans les données brutes. Cela se fait par mini-lots au lieu de l'ensemble de données complet. Il sert à accélérer la formation et à utiliser des taux d'apprentissage plus élevés, ce qui facilite l'apprentissage.

Dans la plupart des cas, il n'est pas possible d'alimenter toutes les données d'apprentissage dans un algorithme en une seule passe. Cela est dû à la taille de l'ensemble de données et aux limitations de mémoire de l'instance de calcul utilisée pour l'entraînement. Dans tous les cas, il s'avère que le choix des paramètres est complexe et fortement dépendant de ce que l'on cherche à réaliser. Cette complexité concerne la régulation de paramètres Batch size, dropout et le nombre d'itérations (epochs) qu'elles vont effectuer.

**La taille du lot (Batch size) :** est un terme utilisé dans l'apprentissage automatique et fait référence au nombre d'exemples d'entraînement utilisés dans une itération.

**Epoque (Epoch) :** Le nombre d'époques est un hyperparamètre qui définit le nombre de fois que l'algorithme d'apprentissage fonctionnera sur l'ensemble de données d'apprentissage.

Une époque signifie que chaque échantillon de l'ensemble de données d'apprentissage a eu la possibilité de mettre à jour les paramètres du modèle interne. Une époque est composée d'un ou plusieurs lots.

Dans notre travail nous avons utilisé les nombres d'epochs égale à 300.



### 3.3.2 Réseaux de neurones convolutifs (CNN)

Un réseau neuronal convolutif est un algorithme d'apprentissage profond qui peut prendre une image d'entrée, attribuer de l'importance (poids et biais apprenables) à divers aspects / objets de l'image et être capable de différencier l'un de l'autre. Le prétraitement requis dans un CNN est bien inférieur à celui d'autres algorithmes de classification. Alors que dans les méthodes primitives, les filtres sont conçus à la main, avec suffisamment de formation, les CNN ont la capacité d'apprendre ces filtres / caractéristiques.

L'architecture d'un CNN est analogue à celle du modèle de connectivité des neurones dans le cerveau humain et a été inspirée par l'organisation du cortex visuel. Les neurones individuels ne répondent aux stimuli que dans une région restreinte du champ visuel connue sous le nom de champ récepteur. Une collection de ces champs se chevauchent pour couvrir toute la zone visuelle.


Une architecture CNN est formée par un empilement des couches de traitement indépendantes :

- **Couche de convolution (CONV)**

La couche de convolution est le bloc de construction de base d'un CNN. Trois paramètres permettent de dimensionner le volume de la couche de convolution la profondeur, le pas et la marge.

- **La couche de Pooling**

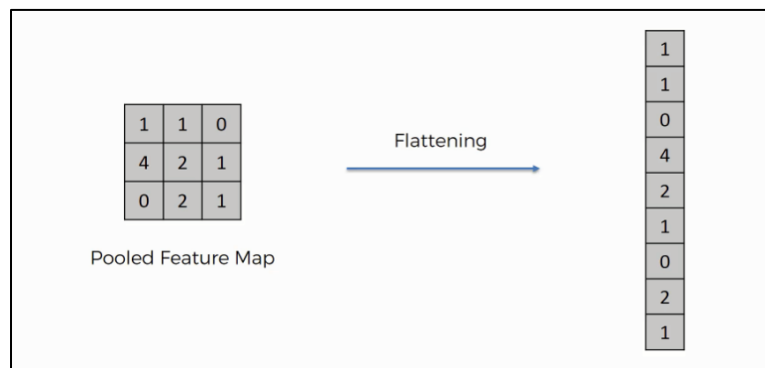
C'est une opération généralement appliquée entre deux couches de convolution. Celle-ci reçoit en entrée les features maps formées en sortie de la couche de convolution et son rôle est de réduire la taille des images, tout en préservant leurs caractéristiques les plus essentielles. Parmi les plus utilisés, on retrouve le max-pooling mentionné précédemment ou encore l'average pooling dont l'opération consiste à conserver à chaque pas, la valeur moyenne de la fenêtre de filtre. La figure suivante présente le processus du pooling.



**Figure 18 :** Processus du pooling.

- **Couche Flatten**

La couche Flatten consiste à mettre de bout en bout toutes les images (matrices) que nous avons pour en faire un vecteur. Les pixels (ce ne sont plus des images ou des pixels, mais des matrices de nombres) sont récupérés ligne par ligne et ajoutés au vecteur final. La figure suivante présente un exemple d'une couche Flatten.



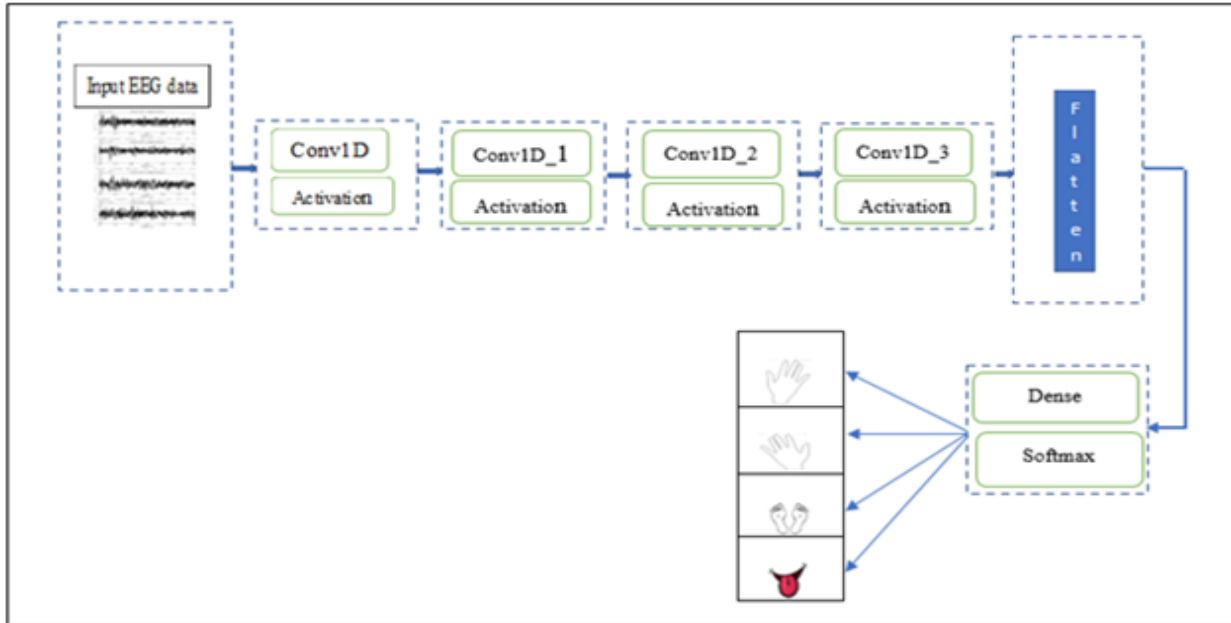
**Figure 19 :** couche Flatten

- **Couche Fully Connected (FC)**

Ces couches sont placées en fin d'architecture de CNN et sont entièrement connectées à tous les neurones de sorties (d'où le terme fully-connected). Après avoir reçu un vecteur en entrée, la couche FC applique successivement une combinaison linéaire puis une fonction d'activation dans le but final de classer l'input image. Elle renvoie enfin en sortie un vecteur de taille d

correspondant au nombre de classes dans lequel chaque composante représente la probabilité pour l'input image d'appartenir à une classe.

La figure suivante représente l'architecture CNN que nous avons utilisée avec les fonctions d'activation Relu, Selu, Elu et Tanh.

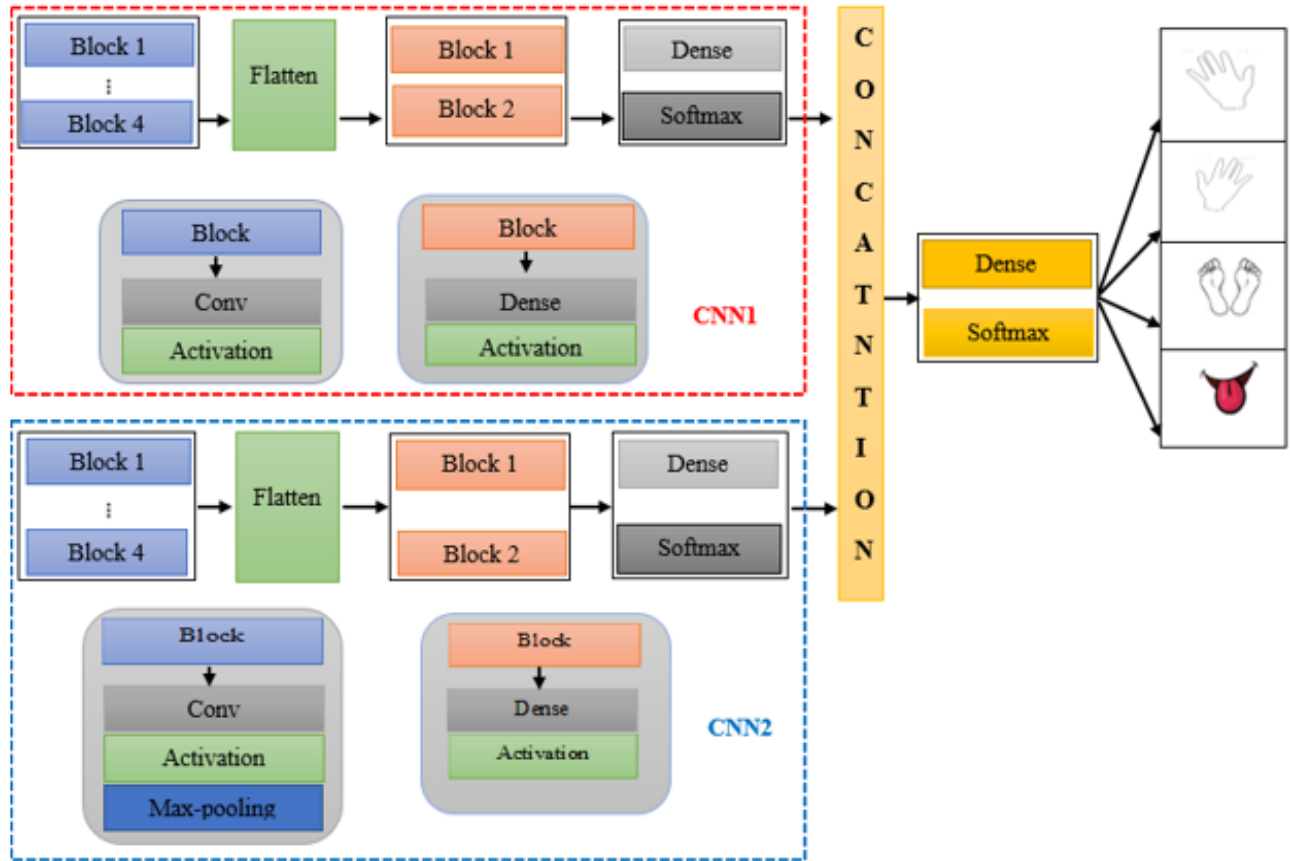


**Figure 20 :** Modèle CNN utilisé.

### 3.3.3 Combinaison des deux CNNs

Dans cette étude, nous proposons une méthode de fusion pour combiner les modèles CNN pour la classification EEG. Certains chercheurs ont proposé modèles CNN avec un plus grand nombre de couches [44, 45] à réaliser une bonne précision de décodage. Différentes architectures de CNN peuvent être utiles pour extraire différents types d'EEG, donc leur fusion peut nous aider à créer des caractéristiques génériques pour le décodage EEG.

Nous fusionnons les modèles CNN 1, CNN2 comme le montre la figure 21. La combinaison se fait par une simple concaténation des deux modèles CNNs suivie d'une couche dense avec la fonction d'activation SoftMax.



**Figure 21 :** Combinaison des deux modèles CNNs.

#### 4. Conclusion

Nous avons consacré ce chapitre à la présentation des différents modèles basés sur l'approche Deep Learning, en premier temps, nous avons commencé par un état de l'art sur les méthodes de traitement des signaux, ensuite une description globale des méthodes proposée pour la classification des tâches d'IM. Le chapitre suivant sera consacré essentiellement à l'implémentation de ces méthodes et le test de la performance de notre approche proposée.

## Chapitre 3 :

# Évaluation de la méthodologie proposée pour la classification des mouvements d'imagination motrice

### 1. Introduction

La disponibilité d'ensembles de données d'électroencéphalogramme (EEG) vastes et variés, les progrès rapides et les inventions dans les techniques d'apprentissage en profondeur, et les systèmes informatiques très puissants et diversifiés ont tous permis d'analyser facilement ces ensembles de données et de découvrir des informations vitales à l'intérieur. Cependant, le processus de classification des signaux EEG et la découverte d'informations vitales doivent être robustes, automatiques et d'une grande précision.

Dans ce chapitre, nous détaillons les résultats expérimentaux sur la performance de notre méthodologie proposée en termes de précision de la classification. De plus, nous représentons la base de données utilisé. Et nous finissons par comparer les résultats obtenus par notre système avec d'autres approches de l'état de l'art.


### 2. Présentation des bases de données

Nous avons utilisé dans ce travail la base de données « *BCI Competition IV 2a* » pour évaluer la performance de notre méthodologie proposée.

L'ensemble de données BCI Competition IV 2a contient des signaux EEG de quatre classes d'activité d'imagination motrice : main gauche, main droite, pied et langue provenant de neuf sujets sains. Les signaux EEG ont été enregistrés à partir de 22 électrodes du système EEG 10-20 standard avec une fréquence d'échantillonnage de 250 Hz. Un total de 288 essais de tâches d'IM ont été réalisés avec 72 essais pour chaque classe d'IM.

Les sujets étaient assis dans un fauteuil confortable devant un écran d'ordinateur. Au début d'un essai ( $t = 0$  s), une croix de fixation est apparue sur l'écran noir. De plus, un bref signal sonore d'avertissement a été émis. Après deux secondes ( $t = 2$  s), un signal en forme de flèche pointant vers la gauche, la droite, le bas ou le haut (correspondant à l'une des quatre classes main gauche, main droite, pied ou langue) est apparu et est resté sur l'écran pendant 1,25 s. Cela a incité les sujets

à effectuer la tâche d'imagerie motrice souhaitée. Aucun commentaire n'a été fourni. Les sujets ont été invités à effectuer la tâche d'imagerie motrice jusqu'à ce que la croix de fixation disparaisse de l'écran à  $t = 6$  s. Une courte pause a suivi où l'écran était de nouveau noir. Le paradigme est illustré dans la figure 22.



**Figure 22 :** Schéma temporel du paradigme.

### 3. Métrique d'évaluation

Nous avons évalué notre méthodologie en se basant sur les valeurs de précision (accuracy). La précision d'un test est sa capacité à différencier correctement les tâches d'IM. Pour estimer la précision d'un test, nous devons calculer la proportion de vrais positifs et de vrais négatifs dans tous les cas évalués. Mathématiquement, cela peut être énoncé comme suit :

$$Accuracy = (TP + TN) / (TP + TN + FP + FN) \quad (1)$$

On suppose qu'on a deux classes d'IM : main gauche et main droite :

- **True Positif (TP)** : où la prédiction était de la main gauche (ou de la main droite), et l'étiquette correcte était également de la main gauche (ou de la main droite);
- **True Negative (TN)** : où la prédiction était à droite (ou à gauche), et l'étiquette correcte était également à droite (ou à gauche);
- **False Positif (FP)** : où la prédiction était à gauche (ou à droite), mais l'étiquette correcte était à droite (ou à gauche);
- **False Négatif (FN)** : où la prédiction était à droite (ou à gauche), mais l'étiquette correcte était à gauche (ou à droite).

### 4. Résultats expérimentaux

Nous allons présenter dans cette section les principaux résultats obtenus après l'application des classifieurs ANN, CNN, et la combinaison des deux CNNs.

#### 4.1 Classification basée sur l'ANN

L'architecture ANN que nous avons appliquée sur la base de données BCI Competition IV 2a, est détaillée dans le chapitre précédent. Nous rappelons que chaque bloc est composé d'une couche Batch Normalisation, une couche dense, et une couche dropout.

Nous avons testé quatre fonctions d'activation Relu, Selu, Elu, et Tanh. Les tableaux ci-dessous résument les valeurs de la précision obtenues par l'application du modèle ANN.

**Tableau 3 :** Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation d'un seul bloc (en %).

Fonction d'activation	A01	A02	A03	A04	A05	A06	A07	A08	A09	Valeur moyenne
Relu	69.13	57.93	81.72	36.21	47.06	38.79	72.24	68.44	49.48	<b>57.88</b>
Selu	68.44	56.55	81.55	36.21	45.17	38.44	72.75	67.75	48.10	<b>57.21</b>
Elu	67.41	56.20	81.03	34.48	45.68	35.86	73.44	69.65	48.27	<b>56.89</b>
Tanh	66.03	57.24	80.51	34.48	45.86	37.75	73.96	68.62	48.79	<b>51.93</b>

D'après le tableau 3, nous remarquons que le modèle ANN a donné la plus grande valeur moyenne de précision avec la fonction d'activation Relu, et en utilisant un seul bloc. Cette valeur est égale à 57.88%

**Tableau 4 :** Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation de quatre blocs (en %).

Fonction d'activation	A01	A02	A03	A04	A05	A06	A07	A08	A09	Valeur moyenne
Relu	65.86	59.4	81.55	31.03	44.65	36.56	73.62	69.65	48.10	<b>56.71</b>
Selu	63.44	56.37	81.03	32.76	47.45	36.96	72.06	68.96	46.37	<b>56.15</b>
Elu	65.68	57.4	81.37	34.48	47.75	38.62	73.44	65.17	49.48	<b>57.04</b>
Tanh	65.86	57.2	81.72	36.21	45.51	32.06	72.93	66.03	45.17	<b>55.85</b>

D'après le tableau 4, nous remarquons que le modèle ANN a donné la meilleur valeur moyenne de précision avec la fonction d'activation Elu, et en utilisant quatre blocs. Cette valeur est égale à 57.04%.

**Tableau 5 :** Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation de cinq blocs (en %).

Fonction d'activation	A01	A02	A03	A04	A05	A06	A07	A08	A09	Valeur moyenne
Relu	65.8	58.2	79.13	32.76	42.24	38.79	74.82	70.17	47.24	<b>56.57</b>
Selu	67.06	56.8	79.48	29.31	44.82	38.27	72.58	67.75	45.34	<b>55.71</b>
Elu	65.5	58.1	81.20	36.21	45.51	38.27	72.75	68.44	49.13	<b>56.67</b>
Tanh	65.5	57.24	80.17	39.66	47.24	38.96	72.41	68.10	47.75	<b>57.44</b>

D'après le tableau 5, nous remarquons que le modèle ANN a donné la meilleur valeur moyenne de précision avec la fonction d'activation Tanh, et en utilisant cinq blocs. Cette valeur est égale à 57.44%.

**Tableau 6 :** Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation de six blocs (en %).

Fonction d'activation	A01	A02	A03	A04	A05	A06	A07	A08	A09	Valeur moyenne
Relu	66.8	59.6	80.00	37.93	43.79	39.31	73.62	70.51	47.75	<b>57.70</b>
Selu	64.65	58.96	80.68	34.48	46.03	37.24	72.24	67.41	48.79	<b>56.72</b>
Elu	65.34	56.8	81.03	32.76	45.17	39.48	73.44	66.20	48.27	<b>56.49</b>
Tanh	66.3	56.7	80.86	36.21	47.58	37.06	72.24	67.06	47.75	<b>56.86</b>

D'après le tableau 6, nous remarquons que le modèle ANN a donné la meilleur valeur moyenne de précision avec la fonction d'activation Relu, et en utilisant six blocs. Cette valeur est égale à 57.70%.



**Tableau 7 :** Précision de la classification obtenue par l'application du modèle ANN avec l'utilisation de sept blocs (en %).

Fonction d'activation	A01	A02	A03	A04	A05	A06	A07	A08	A09	Valeur moyenne
Relu	68.1	57.9	80.00	34.48	47.41	36.72	72.24	71.55	46.37	<b>57.19</b>
Selu	62.5	54.6	80.68	32.76	46.55	38.44	72.24	66.72	46.55	<b>55.67</b>
Elu	66.03	55.1	78.79	29.31	45.51	36.37	72.41	67.58	47.41	<b>55.39</b>
Tanh	60.86	54.6	80.51	32.76	45.00	35.51	71.37	68.27	47.58	<b>55.16</b>

D'après le tableau 7, nous remarquons que le modèle ANN a donné la plus grande valeur moyenne de précision avec la fonction d'activation Relu, et en utilisant sept blocs. Cette valeur est égale à 57.19%.

**Tableau 8 :** Précision de la classification obtenue par l'application du modèle ANN (en %).

Nombre de blocs	Fonction d'activation	A01	A02	A03	A04	A05	A06	A07	A08	A09	Valeur moyenne
<b>1</b>	Relu	69.13	57.93	81.72	36.21	47.06	38.79	72.24	68.44	49.48	<b>57.88</b>
	Selu	68.44	56.55	81.55	36.21	45.17	38.44	72.75	67.75	48.10	<b>57.21</b>
	Elu	67.41	56.20	81.03	34.48	45.68	35.86	73.44	69.65	48.27	<b>56.89</b>
	Tanh	66.03	57.24	80.51	34.48	45.86	37.75	73.96	68.62	48.79	<b>51.93</b>
<b>4</b>	Relu	65.86	59.4	81.55	31.03	44.65	36.56	73.62	69.65	48.10	<b>56.71</b>
	Selu	63.44	56.37	81.03	32.76	47.45	36.96	72.06	68.96	46.37	<b>56.15</b>
	Elu	65.68	57.4	81.37	34.48	47.75	38.62	73.44	65.17	49.48	<b>57.04</b>
	Tanh	65.86	57.2	81.72	36.21	45.51	32.06	72.93	66.03	45.17	<b>55.85</b>
<b>5</b>	Relu	65.8	58.2	79.13	32.76	42.24	38.79	74.82	70.17	47.24	<b>56.57</b>
	Selu	67.06	56.8	79.48	29.31	44.82	38.27	72.58	67.75	45.34	<b>55.71</b>
	Elu	65.5	58.1	81.20	36.21	45.51	38.27	72.75	68.44	49.13	<b>56.67</b>
	Tanh	65.5	57.24	80.17	39.66	47.24	38.96	72.41	68.10	47.75	<b>57.44</b>
<b>6</b>	Relu	66.8	59.6	80.00	37.93	43.79	39.31	73.62	70.51	47.75	<b>57.70</b>
	Selu	64.65	58.96	80.68	34.48	46.03	37.24	72.24	67.41	48.79	<b>56.72</b>
	Elu	65.34	56.8	81.03	32.76	45.17	39.48	73.44	66.20	48.27	<b>56.49</b>
	Tanh	66.3	56.7	80.86	36.21	47.58	37.06	72.24	67.06	47.75	<b>56.86</b>
<b>7</b>	Relu	68.1	57.9	80.00	34.48	47.41	36.72	72.24	71.55	46.37	<b>57.19</b>
	Selu	62.5	54.6	80.68	32.76	46.55	38.44	72.24	66.72	46.55	<b>55.67</b>
	Elu	66.03	55.1	78.79	29.31	45.51	36.37	72.41	67.58	47.41	<b>55.39</b>
	Tanh	60.86	54.6	80.51	32.76	45.00	35.51	71.37	68.27	47.58	<b>55.16</b>

D'après le tableau 8, nous remarquons que le modèle ANN a donné la plus grande valeur moyenne de précision avec la fonction d'activation Relu, et en utilisant un seul bloc. Cette valeur est égale à 57.88%. De plus, nous pouvons remarquer aussi que toutes les valeurs moyenne sont très proches. Elles varient entre 51.93% et 57.88%.

On peut déduire que la fonction d'activation Relu a donné les meilleures valeurs de précision par rapport aux fonctions d'activation Selu, Elu, et Tanh.

## **4.2 Classification basée sur le CNN**

Les réseaux neuronaux convolutionnels sont très similaires aux réseaux neuronaux ordinaires et aux MLP (perceptrons multicouches). Leurs résultats d'utilisation dans de nombreuses tâches de classification ont été remarquables et suscitent actuellement l'intérêt des chercheurs en raison de leur potentiel de performance. Les CNNs sont constitués d'une ou plusieurs couches convolutionnelles dans lesquelles la convolution est un type spécialisé d'opération linéaire. Les réseaux convolutionnels sont simplement des réseaux de neurones qui utilisent la convolution au lieu de la multiplication matricielle générale dans au moins une de leurs couches. La convolution est conçue pour traiter des données 2D, contrairement aux autres réseaux neuronaux qui fonctionnent sur des vecteurs 1D. Cette capacité rend les caractéristiques extraites plus faciles à visualiser et à interpréter.

Les principaux paramètres de l'architecture CNN que nous avons utilisé dans ce travail, sont :

**Input layer** : Il comprend une matrice I de taille 32\*1.

**Convolutional layer** : La couche convolutionnelle effectue un apprentissage de convolution 2D qui représente une distribution spatiale sur la carte des caractéristiques. Toutes les couches convolutionnelles utilisent de petits champs réceptifs de taille  $3 \times 3$  et un stride de 1 pixel avec les fonctions d'activation Relu, Elu, Selu et Tanh. La taille du filtre de la couche convolutionnelle limite la granularité de l'apprentissage en englobant des régions de la carte des caractéristiques de taille fixe. Nous avons utilisé dans notre travail 4 couches de convolution successives.

**Couche Flatten** : Les sorties générées par toutes les couches convolutives précédentes sont transformé en un vecteur qui sera utilisé comme entrée pour les couches suivantes.

**Fully connected layer :** La dernière couche du réseau est une couche dense. Elle est de taille 128. L'entrée des couches fully connected est un vecteur 1D construit en concaténant les sorties de tous les filtres de la couche convolutionnelle.

**Output layer :** La couche de classification ou couche de sortie qui met en correspondance les dernières couches produites avec les étiquettes des classes. On utilise dans cette couche la fonction d'activation SoftMax.

Les résultats de la précision de classification est donnée par le tableau 9 :

**Tableau 9 :** Précision de la classification obtenue par l'application du modèle CNN (en %).

	<b>Relu</b>	<b>Selu</b>	<b>Elu</b>	<b>Tanh</b>
<b>A01</b>	75.86	81.03	74.14	79.31
<b>A02</b>	56.90	53.45	51.72	55.17
<b>A03</b>	87,93	86.21	86.21	84.48
<b>A04</b>	51.72	39.66	46.55	48.28
<b>A05</b>	50.00	41.38	39.66	41.38
<b>A06</b>	43.10	32.76	36.21	36.21
<b>A07</b>	63.79	63.79	60.34	63.79
<b>A08</b>	70.69	74.14	75.86	68.97
<b>A09</b>	55.17	51.72	53.45	53.45
<b>Valeur moyenne</b>	<b>61.68</b>	<b>56.89</b>	<b>57.87</b>	<b>57.85</b>

D'après le tableau 9, le modèle CNN atteint la meilleure valeur moyenne de précision avec la fonction d'activation Relu qui est égale à 61.68%. La mauvaise valeur moyenne de précision est obtenue avec la fonction d'activation Selu qui est égale à 56.89%.

Dans ce cas, on peut déduire que la fonction d'activation Relu est considérée comme la fonction d'activation la plus performante par rapport aux autres.

#### **4.3 Classification basée sur la combinaison des deux CNNs**

La combinaison des deux modèles CNNs que nous avons proposés est détaillée dans le chapitre 2. Nous avons testé quatre fonctions d'activation Relu, Selu, Elu, et Tanh. Le tableau 10 résume les valeurs de la précision obtenues par l'application de la combinaison des deux modèles CNNs.

**Tableau 10 :** Précision de la classification obtenue par l'application de la combinaison des deux modèles CNNs (en %).

	A01	A02	A03	A04	A05	A06	A07	A08	A09	Valeur moyenne
<b>Relu</b>	67.24	62.07	87.93	48.28	48.28	32.76	63.79	70.69	55.17	<b>59.57</b>
<b>Selu</b>	77.59	53.45	91.38	41.38	44.83	27.59	72.41	68.97	48.28	<b>58.43</b>
<b>Elu</b>	79.31	58.62	84.48	44.83	50.00	34.48	65.52	72.41	51.72	<b>60.15</b>
<b>Tanh</b>	75.86	56.90	81.38	43.10	46.55	36.21	63.79	75.86	55.17	<b>59.42</b>


D'après le tableau 10, la combinaison des deux modèles CNNs a donné la meilleure valeur moyenne de précision avec la fonction d'activation Selu, qui est égale à 60.15%. On peut remarquer aussi que les faibles valeurs de précision sont obtenues par les sujets A04, A05, et A06 et en utilisant les quatre fonctions d'activation Relu, Selu, Elu, et Tanh.

#### 4.4 Etude comparative entre ANN, CNN et la combinaison des deux modèles CNNs

Le tableau 11 résume les valeurs de précision obtenues par l'application du ANN, CNN, et la combinaison des deux modèles CNNs.

**Tableau 11 :** Valeurs de précision obtenues par l'application du ANN, CNN, et la combinaison des deux modèles CNNs.

	ANN	CNN	Combinaison des deux modèles CNNs
<b>Relu</b>	57.21%	<b>61.68%</b>	59.57%
<b>Selu</b>	56.29%	56.86%	58.43%
<b>Elu</b>	56.49%	57.87%	60.15%
<b>Tanh</b>	55.44%	57.85%	59.42%



**Figure 23 :** Etude comparative entre les modèles ANN, CNN et la combinaison des deux modèles CNNs.


D'après la figure 23 et le tableau 11, nous remarquons que le modèle CNN donne la meilleure valeur de précision parmi les trois classifieurs et en utilisant la fonction d'activation Relu. Cette valeur est de l'ordre de 61,68%.

On peut déduire aussi que la combinaison des deux modèles CNNs n'atteint pas la meilleure valeur de précision. Ce qui signifie que l'utilisation d'un seul modèle CNN est plus performant qu'à l'application d'une combinaison des modèles CNNs.

On peut noter qu'avec la fonction d'activation Relu, ANN et CNN atteignent leur valeur de précision supérieure, tandis que la fusion des deux modèles CNNs a donné la valeur de précision maximale avec la fonction d'activation Elu.

Les valeurs supérieures de précision de la classification sont 57,88%, 61,68% et 60,15%. Elles sont obtenues respectivement par ANN, CNN et la combinaison des deux classifieurs CNNs. Nous

pouvons conclure que le modèle CNN est le meilleur choix pour la classification des mouvements d’IM par rapports autres classifieurs.



**Figure 24 :** La différence entre les valeurs de précision de la classification entre les sujets.

Nous remarquons dans la figure 24 qu’il y a une différence énorme entre les valeurs de précision de la classification des sujets et avec les quatre fonctions d'activation. A titre d'exemple, les meilleures valeurs de précision des trois classifieurs obtenues par le sujet A03. La combinaison des deux CNNs, et le CNN, ont obtenues des bonnes précisions avec la fonction d’activation Selu, qui sont égale respectivement 91,38% et 87,93%. Tant dit ce que le modèle ANN atteint une précision de l’ordre de 81,98% avec la fonction d’activation Relu pour le même sujet A03. Le modèle ANN a permis de détecter les mouvements d’IM pour certains sujets par rapport au modèle CNN. Notre modèle ANN a moins de paramètres mais nécessite un processus d'extraction de caractéristiques plus performante pour améliorer leur résultat. Le tableau suivant présente une comparaison entre la méthode proposée et quelques méthodes de l’état de l’art, en termes de précision de la classification.

**Tableau 12 :** Tableau comparative entre la méthode proposé et quelques méthodes de l'état de l'art.

	CNN proposée	Ensemble [39]	KNN [39]	[40]
<b>Valeur de la précision</b>	61.68%	58.22%	58.80%	41.07%

Les approches proposées par [39,40], sont évaluée sur la base des données BCI Compétition VI de données 2a. L'approche CNN proposée offrait une bonne amélioration de la précision par rapport aux méthodes présentées dans [39,40].

Pour la méthode Ensemble [39], les auteurs ont proposé « Adaptive Boosting for Multiclass Classification 'l'AdaBoostM2' » comme approche de classification, l'arbre de décision comme apprenant. Le nombre d'époques de la méthode Ensemble est fixé à 100. Ce modèle est capable d'identifier des tâches d'IM avec une valeur de précision de 58,22%.

Alternativement, la métrique de distance euclidienne est utilisée dans l'implémentation du classifieur k-plus proches voisins (kNN) [39]. Cet algorithme peut donner une bonne classification si le nombre des caractéristiques est suffisamment grand. Mais la précision du KNN peut être gravement dégradée par la présence des caractéristiques bruyantes ou non pertinentes, ce qui influence sur la valeur de précision (58,88%).

La méthode de [40] a été choisie comme référence pour évaluer la méthode CNN proposée. Ce modèle [40] est implémenté dans PyTorch. Le modèle CNN 'Deeper ' et 'Sallow', a été développé pour la classification des mouvements d'IM utilisant 'cropped training' et a obtenu une précision moyenne 41,07%.

Les résultats de la comparaison sur l'ensemble de données BCI Competition IV 2a prouvent que l'approche proposée basée sur CNN conduit à de meilleures performances en présentant la valeur de précision la plus élevée par rapport à nos méthodes proposées et aux méthodes de l'état de l'art.

Dans ce travail, la fusion des deux CNNs n'a pas amélioré le résultat de la classification. Ce point peut être amélioré soit en ajoutant d'autres caractéristiques par exemple les caractéristiques temporelles, soit en appliquant d'autres méthodes de fusion autres que la concaténation.

## **5. Conclusion**

Nous avons présenté dans ce chapitre la démarche de la réalisation de notre méthodologie proposée pour la classification des mouvements d'IM qui est présentée sous la forme d'un système automatique basé sur les méthodes d'apprentissage profond. Nous avons utilisé trois classifieurs ANN, CNN, et la combinaison des deux CNNs.

Les résultats obtenus montrent que l'extraction des caractéristiques fréquentielles et spatiales obtenues respectivement par WPD et CSP, sont des facteurs importants pour l'obtention de meilleurs résultats.

Ces résultats peuvent être aussi développé dans les futurs travaux tout en améliorant les techniques d'extraction des caractéristiques, pour mieux classifier les tâches d'IMs.



## Conclusion Générale

Ce travail de recherche a été élaborée dans le cadre de la classification des mouvements d'imagination motrice. Généralement, les techniques d'apprentissage profond, c'est-à-dire des réseaux de neurones profonds, ont été étudiées pour traiter des signaux complexes des fonctions cérébrales. En termes de recherche sur la classification des tâches d'IM, les méthodes basées sur CNN sont largement utilisées.

Nous avons commencé ce manuscrit par présenter quelques notions de base de la physiologie tout en allant vers l'électrophysiologie du cerveau. Quelques généralités sur le système nerveux seront nécessaires pour comprendre l'origine de l'activité électrique cérébrale. Puis, nous allons décrire les principaux outils existants pour le diagnostic du cerveau seront évoqués, à savoir l'Electroencéphalographie 'EEG', et la Magnétoencéphalographie 'MEG'. Ensuite, nous avons présenté le phénomène neurophysiologie les plus utilisées dans la création des ICMs. De plus, les compétences et les connaissances nécessaires à la conception d'une ICM basée sur l'imagination motrice, sont expliquées.

Par la suite, nous avons illustré les approches et les principaux travaux existants dans le domaine classification des mouvements d'IM à l'aide des méthodes d'apprentissage profond.

Ensuite, nous avons présenté notre démarche pour la problématique posée. Pour ce faire nous avons proposé trois modèles : ANN, CNN, et la combinaison des deux modèles CNNs.

Les résultats obtenus ont montré que le modèle CNN utilisé est efficace pour la classification des tâches d'IM en obtenant un bon taux de précision. Afin de montrer la faisabilité de notre démarche, nous avons comparé les résultats obtenus par notre système avec d'autres approches de l'état de l'art. D'après les évaluations menées dans ce mémoire, nous avons illustré que le modèle CNN atteint de bons résultats et assure une précision de 61.68%.

De plus, la fusion des deux CNNs n'a pas amélioré le résultat de la classification. Nous essayerons dans nos futures recherches de l'améliorer soit en ajoutant d'autres caractéristiques par exemple les caractéristiques temporelles, soit en appliquant d'autres méthodes de fusion autres que la concaténation.

# Références

1. Lotte, F, M Congedo, A Lécuyer, F Lamarche, et B Arnaldi. 2007. « A review of classification algorithms for EEG-based brain-computer interfaces ». *Journal of Neural Engineering* 4 (2) (juin): R1-R13. doi:10.1088/1741-2560/4/2/R01.
2. X. Artusi, “Interface Cerveau Machine avec adaptation automatique à l'utilisateur”, Thèse de Doctorat de l'École Centrale de Nantes, Nantes, France, (2012).
3. A. Bashashati , M. Fatourehchi , R. K. Ward et G. E. Birch , “A survey of signal processing algorithms in brain-computer interfaces based on electrical brain signals”, *Journal Of Neural Engineering*, Iop Publishing, Vol. 4, No. 2, pp. R32–R57, (2007).
4. B. Bioulac, P. Burbaud, J.-R. Cazalets et C. Gross, “Fonctions motrices”, *EMC-Kinésithérapie*, Vol. 1, No. 4, pp.183–233, (2005).
5. F. A. Azevedo, L. R. Carvalho, L. T. Grinberg, J. M. Farfel, R. E. Ferretti, R. E. Leite, W. Jacob Filho, R. Lent et S. Herculano-Houzel, “Equal numbers of neuronal and nonneuronal cells make the human brain an isometrically scaled-up primate brain”, *journal of comparative neurology*, pp. 513-532, (2009).
6. G. Pfurtscheller, C. Brunner, A. Schlogl et F.H. Lopes da Silva, “Mu rhythm (de)synchronization and EEG single-trial classification of different motor imagery tasks”, *NeuroImage*, Vol. 31, No. 1, pp. 153-159, (2006).
7. U. Hoffmann, J. Vesin, T. Ebrahimi et K. Diserens, “An efficient P300-based brain-computer interface for disabled subjects”, *Journal of Neuroscience Methods*, Vol. 167, No. 1, pp. 115-125, (2008).
8. E. Donchin, D. Karis, T. Bashore, M. Coles et G. Gratton, “Cognitive Psychophysiology and human information processing”, In Coles MGH, Donchin E and Porges SW editors, *Psychophysiology: Systems, processes, and applications*, New York: Guilford Press, pp. 244–267, (1986).
9. B. Yan, Z. Li, H. Li, G. Yang and H. Shen, “Research on brain-computer interface technology based on steady state visual evoked potentials”, *International Conference on Bioinformatics and Biomedical Engineering*, Chengdu, China, pp. 1-4, (18-20 Juin 2010).

10. Y. Jeona, C. S. Namb, Y.-J. Kimc et M. C. Whang, “Event-related (De)synchronization (ERD/ERS) during motor imagery tasks: Implications for brain computer interfaces”, *International Journal of Industrial Ergonomics*, Vol. 41, No. 5, pp. 428-436, (2011).
11. H. Shan, H. Xu, S. Zhu et B. He, “A novel channel selection method for optimal classification in different motor imagery BCI paradigms”, *BioMedical Engineering OnLine*, Vol. 14, No.93 , pp. 1-18, (2015).
12. R. Scherer, A. Mohapp, P. Grieshofer, G. Pfurtscheller et C. Neuper, “Sensorimotor EEG patterns during motor imagery in hemiparetic stroke patients”, *International Journal of Bioelectromagnetism*, Vol. 9, No. 3, pp. 155-162, (2007).
13. G. Pfurtscheller et C. Neuper, “Motor imagery activates primary sensorimotor area in humans”, *Neuroscience Letters*, Vol. 239, No. 2-3, pp. 65-68, (1997).
14. S., Kumar, A., Sharma, K., Mamun, and T.Tsunoda, “A deep learning approach for motor imagery EEG signal classification,” in *Proceedings of the 2016 3rd Asia-Pacific World Congress on Computer Science and Engineering (APWC on CSE)*, (Nadi: IEEE). (2017).
15. S., Sakhavi, C., Guan, and S. Yan, “Parallel convolutional-linear neural network for motor imagery classification,” in *Proceedings of the European Signal Processing Conference*, (Nice: IEEE), 2736–2740. (2015).
16. S., Sakhavi, and C.Guan, “Convolutional neural network-based transfer learning and knowledge distillation using multi-subject data in motor imagery BCI,” in *Proceedings of the International IEEE/EMBS Conference on Neural Engineering*, Shanghai: IEEE, 588–591. (2017).
17. Y. R., Tabar, and U.Halici, A novel deep learning approach for classification of EEG motor imagery signals. *J. Neural Eng.* 14:016003. doi: 10.1088/1741-2560/14/1/016003. (2017).
18. P., Bashivan, I., Rish, M., Yeasin, and N. C. Codella, Learning representations from EEG with deep recurrent-convolutional neural networks. *arXiv* (2015).
19. X., Zhu, P. Li, C., Li, D., Yao, R., Zhang, and P. Xu, Separated channel convolutional neural network to realize the training free motor imagery BCI systems. *Biomed. Sign. Process. Control* 49, 396–403. (2019).
20. R.T Schirrmeister., J.T., Springenberg, L.D.J., Fiederer, M. Glasstetter, K., Eggensperger, M. Tangermann, , et al. Deep learning with convolutional neural networks for EEG

- decoding and visualization. *Hum. Brain Mapp.* 38, 5391–5420. doi: 10.1002/hbm.23730. (2017).
21. A.L., Goldberger, L.A.N., Amaral, L., Glass, J. M., Hausdorff, P.C., Ivanov, R.G. Mark, et al. PhysioBank, physiotookit, and physionet components of a new research resource for complex physiologic signals. *Circulation* 101, 215–220. (2000).
  22. O. Abdel-Hamid, A.R. Mohamed, H. Jiang, L. Deng, G. Penn, and D. Yu, “Convolutional neural networks for speech recognition,” *IEEE-ACM Transactions on Audio Speech and Language Processing*, vol. 22, no. 10, pp. 1533–1545, (2014).
  23. M.T.F. Talukdar, S.K. Sakib, N.S. Pathan, S.A. Fattah, Motor imagery EEG signal classification scheme based on autoregressive reflection coefficients, in : 2014 International Conference on Informatics, Electronics & Vision (ICIEV), Dhaka, pp. 1–4. (2014).
  24. R.T. Schirrmester, J.T. Springenberg, L.D.J. Fiederer, M. Glasstetter, K. Eggersperger, M. Tangermann, T. Ball, Deep learning with convolutional neural networks for EEG decoding and visualization, *Hum. Brain Mapp.* 38 (2017) 5391–5420, <http://dx.doi.org/10.1002/hbm.23730>.
  25. Rawashdeh Majdi, et al., Reliable service delivery in tele-health care systems, *J. Netw. Comput. Appl.* 115 (2018) 86–93.
  26. N. Guler, E. Ubeyli, I. Guler, Recurrent neural networks employing Lya-punov exponents for EEG signals classification, *Expert Syst. Appl.* (ISSN : 09574174) 29 (3) (2005) 506–514, <http://dx.doi.org/10.1016/j.eswa.2005.04.011>.
  27. A. Ghoneim, et al., Medical image forgery detection for smart healthcare, *IEEE Commun. Mag.* 56 (4) (2018) 33–37, <http://dx.doi.org/10.1109/MCOM.2018.1700817>.
  28. M.T.F. Talukdar, S.K. Sakib, N.S. Pathan, S.A. Fattah, Motor imagery EEG signal classification scheme based on autoregressive reflection coefficients, in : 2014 International Conference on Informatics, Electronics & Vision (ICIEV), Dhaka, 2014, pp. 1–4.
  29. Hossain, et al., Improving consumer satisfaction in smart cities using edge computing and caching: A case study of date fruits classification, *Future Gener. Comput. Syst.* 88 (2018) 333–341.
  30. M. Plis, Sergey, R. Hjelm, Salakhutdinov Devon, Bockholt Allen, Henry J. Johnson, J. Hans Paulsen, Deep learning for neuroimaging: à validation study, *Front. Neurosci.* (ISSN : 1662-453X) 8 (August) (2014) 1–11, <http://dx.doi.org/10.3389/fnins.2014.00229>.

31. H. Cecotti, A. Graser, Convolutional neural networks for P300 detection with application to brain-computer interfaces, *IEEE Trans. Pattern Anal. Mach. Intell.* (ISSN : 01628828) 33 (3) (2011) 433–445, <http://dx.doi.org/10.1109/TPAMI.2010.125>.
32. P. Thodoroff, J. Pineau, A. Lim, Learning robust features using deep learning for automatic seizure detection, in : *Machine Learning for Healthcare Conference*, 2016.
33. H. Yang, S. Sakhavi, K.K. Ang, C. Guan, On the use of convolutional neural networks and augmented CSP features for multi-class motor imagery of EEG signal classification, in : *2015 37th Annual Int. Conf. Of the IEEE Engineering in Medicine and Biology Society (EMBC)*, IEEE, 2015, pp.2620–2623.
34. X. An, D. Kuang, X. Guo, Y. Zhao, L. He, A deep learning method for classification of EEG data based on motor imagery, in : *Intelligent Computing in Bioinformatics*, Springer, Berlin, 2014, pp. 203–210.
35. V. Lawhern, et al., EEGNet: à compact convolutional neural network for EEG-based brain–computer interfaces, *J. Neural Eng.* 15 (5) (2018).
36. Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, Gradient based learning applied to document recognition, *Proc. IEEE* 86 (1986) 2278–2324.
37. Y. Bengio, P. Lamblin, D. Popovici, H. Larochelle, Greedy layer-wise training of deep networks, *Adv. Neural Inform. Process. Syst.* 19 (153) (2006).
38. Grosse-Wentrup, M., Liefhold, C., Gramann, K. et Buss, M. (2009). Beamforming in noninvasive brain-computer interfaces. *Biomedical Engineering, IEEE Transactions on*, 56(4):1209 –1219.
39. T. Nguyen, I.Hettiarachchi, A. Khosravi, S.M. Salaken, As. Bhatti, S. Nahavandi, Multiclass\_EEG\_Data\_Classification\_using\_Fuzzy\_Systems, *IEEE International Conference on Fuzzy Systems (FUZZ-IEEE)*, Naples, Italy, pp. 1-6.(2017)
40. R.T. Schirrmeister, J.T. Springenberg, L.D.J. Fiederer, M. Glasstetter, K. Eggersperger, M. Tangermann, T. Ball, Deep learning with convolutional neural networks for EEG decoding and visualization, *Hum. Brain Mapp.* 38, 5391–5420, <http://dx.doi.org/10.1002/hbm.23730>. (2017)

---

# **Classification des signaux EEG pour l'utilisation d'Interfaces Cerveau-Machine dans des applications d'imagination motrice**

---

**Aicha AKROUT**

---

**Résumé.** L'interface Cerveau Machine (ICM) est système qui permet une communication directe entre le cerveau de l'utilisateur et la machine. De tels dispositifs peuvent être réalisés par une mesure non invasive des informations du cortex par électroencéphalographie (EEG). L'un des principaux défis dans ce domaine est d'extraire en temps réel des signaux de commande robustes et suffisamment complexes à partir de sources d'information très limitées et bruyantes pour permettre le contrôle de programmes ou d'effecteurs. Dans ce mémoire, nous avons proposé une méthodologie basée sur les méthodes d'apprentissage profond pour la classification des mouvements d'imagination motrice. Notre méthodologie commence par un simple prétraitement qui est l'élimination des canaux EOG et l'application d'un filtre passe bande. Ensuite, nous avons extrait les caractéristiques fréquentielles et spatiales respectivement à l'aide du WPD et CSP. Nous avons testé les classifieurs ANN, CNN, et nous proposons un autre classifieur basé sur la combinaison des deux CNNs. Les résultats de la comparaison sur l'ensemble de données BCI Competition IV 2a prouvent que l'approche proposée basée sur le CNN conduit à de meilleures performances en présentant la valeur de précision la plus élevée par rapport à nos méthodes proposées et aux méthodes de l'état de l'art.

**Mots clés :** ICM, EEG, imagination motrice, réseau de neurone convolutionnel, réseau de neurone artificiel

**Abstract.** The Brain-Computer Interface (BCI) is a system that allows direct communication between the user's brain and the machine. Such devices can be achieved by non-invasive measurement of information from the cortex by electroencephalography (EEG). One of the main challenges in this field is to extract in real-time robust and sufficiently complex control signals from very limited and noisy information sources to allow the control of programs or effectors. In this dissertation, we have proposed a methodology based on deep learning methods for the classification of motor imagery movements. Our methodology begins with a simple preprocessing which is the elimination of EOG channels and the application of a bandpass filter. Then, we extracted the frequency and spatial characteristics respectively using WPD and CSP. We have tested the ANN, CNN classifiers, and we propose another classifier based on the combination of the two CNNs. The results of the comparison on the BCI Competition IV 2a dataset prove that the proposed CNN-based approach leads to better performance by exhibiting the highest accuracy value compared to our proposed methods and the methods of the state of the art.

**Keywords:** BCI, EEG, Motor imagery, Convolution Neural Network, Artificial Neural Network.