

MÉMOIRE

présenté à

L'Institut Supérieur des Gestion de Gabès

en vue de l'obtention du diplôme de

**Mastère de recherche en
Informatique Décisionnelle et de Gestion**

par

Dhouha SAGGA

**Application de l'approche Deep Learning sur
des segments EEG pour une détection
automatique des crises d'épilepsie**

Soutenu le 10 / 04 / 2021 devant la commission d'examen :

M. Mohamed GHORBEL

Mlle. Hela FEHRI

M. Rafik KHEMAKHEM

Mlle. Amira ECHTIOUI

Président

Rapporteur

Encadrant

Co-encadrante

Année Universitaire : 2020 / 2021

« En vérité, le chemin importe peu, la volonté d'arriver
suffit à tout »

Albert Camus

Dédicace

Je dédie ce modeste travail à :

Ma mère Fariha et l'Ame de mon père Sahbi

Mes frères et mes sœurs,

Toute ma famille,

Mes amis

Tous les gens qui ont participé à l'élaboration de ce travail,

Remerciement

Je remercie Allah de m'avoir donné la capacité d'écrire et de réfléchir, la force d'y croire, la patience d'aller jusqu'au bout du rêve et la volonté et la patience de mener à terme le présent travail.

*Je voudrais remercier **M. Mohamed GHORBEL**, Maître de conférences à l'ENET'COM-Sfax, pour m'avoir fait l'honneur de présider mon jury de ce mémoire.*

*Je souhaite aussi adresser de sincères remerciements à **Mlle. Hela FEHRI**, Maître-assistante à l'ISG-Gabès, d'avoir accepté de faire partie du jury de ce mémoire.*

*Au terme de ce projet j'exprime mes profondes gratitude et respectueuse reconnaissance à mon encadreur, **M. Rafik KHEMAKHEM** maitre-assistant, et chef de département de l'informatique à ISG-Gabès, pour l'assistance qu'il m'a prêtée, son soutien et ses conseils avisés pendant toute la durée de ce travail.*

*Mes remerciements vont exceptionnellement à mon co-encadrante, **Mlle. Amira ECHTIOUI**, enseignante à l'ISIMS-Sfax, pour son soutien scientifique, ses nombreuses relectures, commentaires, suggestions et pour son dévouement et ainsi pour la confiance qu'ils m'ont toujours témoignée.*

Nos sincères remerciements à tous les membres du jury qui nous ont fait l'honneur de réviser ce travail. Enfin, j'adresse toute mon affection à ma famille leurs amours, leurs confiances me portent et me guide tous les jours.

Table de matières

Introduction générale.....	1
Chapitre 1 : Cerveau, techniques d'acquisition et bio marqueurs physiologiques.....	3
1 Introduction.....	3
2 Organisation du système nerveux	3
2.1 Cerveau, neurones et synapses	3
2.2 Les potentiels électriques.....	5
2.2.1 Le potentiel de repos	5
2.2.2 Le potentiel d'action.....	5
3 Les techniques d'acquisition des activités cérébrales	6
3.1 Techniques non-invasives.....	6
3.1.1 L'électroencéphalographie EEG :	6
3.1.2 La magnétoencéphalographie MEG :.....	8
3.1.3 Comparaison entre EEG et MEG	8
3.2 Techniques invasives	9
4 Principaux rythmes de l'EEG	10
5 Notions générales sur l'épilepsie	11
5.1 Définition.....	11
5.2 Causes et symptômes.....	11
5.3 Diagnostic	12
5.4 Classification des crises épileptiques	12
5.5 Les états d'épilepsie.....	14
5.6 Les pointes épileptiques.....	15
6 Conclusion	15
Chapitre 2 : Détection des crises épileptiques en se basant sur l'apprentissage profond .	17
1 Introduction.....	17
2 Etat de l'art.....	17
3 Architecture générale du système proposée.....	19

3.1	Représentation des entrées.....	20
3.2	Architecture du modèle CNN	20
3.2.1	Couche convolutive.....	20
3.2.2	Couche pooling	21
3.2.3	Couche Flatten.....	22
3.2.4	Couche entièrement connectée.....	22
3.3	Architecture du modèle VGGNET	24
3.4	Architecture du modèle ResNet.....	24
3.5	Modèle Xception	25
3.6	Modèle WaveNet.....	27
4	Conclusion	28
Chapitre 3 : Évaluation des architectures utilisées pour la détection des crises épileptiques		29
1	Introduction.....	29
1.1	Description de la base de données	29
1.2	Métrique d'évaluation.....	29
1.2.1	La précision (accuracy)	30
1.2.2	Matrices de confusion	30
2	Résultats expérimentaux	31
2.1	Classification basée sur le CNN	32
2.2	Classification basée sur le VGGNET	34
2.3	Classification basée sur le ResNet.....	37
2.4	Classification basée sur le Xception.....	41
2.5	Classification basée sur le WaveNet	44
3	Etude comparative de la méthode proposée.....	47
4	Discussion	53
5	Conclusion	54
Conclusion Générale		55

Liste des Figures

Figure 1 : Architecture du cerveau humain.....	4
Figure 2 : Présentation de neurone.	
Figure 3 : Présentation de synapse.....	4
Figure 4 : Transmission de l'influx nerveux entre deux neurones.....	5
Figure 5 : Potentiel de repos et d'action.....	6
Figure 6 : L'électroencéphalographie : EEG	7
Figure 7 : Emplacement des électrodes suivant le système 10-20%.....	7
Figure 8 : La magnétoencéphalographie MEG.	8
Figure 9 : Implantation des électrodes dans les enregistrements EEG : technique invasive.	9
Figure 10 : Crises partielles.....	13
Figure 11 : Crises généralisées.....	14
Figure 12 : Passage d'un état normal à un état critique.	14
Figure 13 : Exemple de pointes, de poly pointes et d'ondes à front raide.	15
Figure 14 : Architecture générale du système proposée	19
Figure 15 : Exemple de couche de convolution.	21
Figure 16 : Application Max pooling sur une image.	22
Figure 17 : Mise à plat des images finales en sortie des filtres+simplifications.....	22
Figure 18 : Exemple des couches entièrement connectées.	23
Figure 19 : Architecture du modèle CNN.	23
Figure 20 : Architecture du modèle VGG-19.	24
Figure 21 : Architecture du modèle ResNet.	25
Figure 22 : Architecture du modèle Xception.....	26
Figure 23 : Architecture du modèle WaveNet.	27
Figure 24 : Aperçus sur la matrice de confusions.	31
Figure 25 : Matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Relu.	32
Figure 26 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle CNN avec la fonction d'activation Relu.	32
Figure 27 : Matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Selu.....	32
Figure 28 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle CNN avec la fonction d'activation Selu.	33

Figure 29 : Matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Elu.	33
Figure 30 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle CNN avec la fonction d'activation Elu.	33
Figure 31 : Matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Tanh.....	34
Figure 32 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle CNN avec la fonction d'activation Tanh.	34
Figure 33 : Matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Relu.	34
Figure 34 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle VGGNET avec la fonction d'activation Relu.	35
Figure 35 : Matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Selu.....	35
Figure 36 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle VGGNET avec la fonction d'activation Selu.	36
Figure 37 : Matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Elu.	36
Figure 38 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle VGGNET avec la fonction d'activation Elu.	36
Figure 39 : Matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Tanh.....	37
Figure 40 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle VGGNET avec la fonction d'activation Tanh.	37
Figure 41 : Matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Relu.	38
Figure 42 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle ResNet avec la fonction d'activation Relu.....	38
Figure 43 : Matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Selu.....	38
Figure 44 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle ResNet avec la fonction d'activation Selu.	39
Figure 45 : Matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Elu.	39

Figure 46 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle ResNet avec la fonction d'activation Elu.....	40
Figure 47 : Matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Tanh.....	40
Figure 48 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle ResNet avec la fonction d'activation Tanh.	40
Figure 49 : Matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Relu.	41
Figure 50 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle Xception avec la fonction d'activation Relu.....	41
Figure 51 : Matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Selu.....	42
Figure 52 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle Xception avec la fonction d'activation Selu.	42
Figure 53 : Matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Elu.	42
Figure 54 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle Xception avec la fonction d'activation Elu.....	43
Figure 55 : Matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Tanh.....	43
Figure 56 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle Xception avec la fonction d'activation Tanh.	44
Figure 57 : Matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Relu.	44
Figure 58 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle WaveNet avec la fonction d'activation Relu.	44
Figure 59 : Matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Selu.....	45
Figure 60 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle WaveNet avec la fonction d'activation Selu.....	45
Figure 61 : Matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Elu.	45
Figure 62 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle WaveNet avec la fonction d'activation Elu.	46

Figure 63 : Matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Tanh.....	46
Figure 64 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle WaveNet avec la fonction d'activation Tanh.....	47
Figure 65 : Tracés de précision et de perte sur les ensembles de formation et de validation pour les modèles (a) CNN, (b) VGGNET, (c) ResNet, (d) Xception et (e) WaveNet en utilisant la fonction d'activation Relu.	48
Figure 66 : Tracés de précision et de perte sur les ensembles de formation et de validation pour les modèles (a) CNN, (b) VGGNET, (c) ResNet, (d) Xception et (e) WaveNet en utilisant la fonction d'activation Selu.	49
Figure 67 : Tracés de précision et de perte sur les ensembles de formation et de validation pour les modèles (a) CNN, (b) VGGNET, (c) ResNet, (d) Xception et (e) WaveNet en utilisant la fonction d'activation Elu.	50
Figure 68 : Tracés de précision et de perte sur les ensembles de formation et de validation pour les modèles (a) CNN, (b) VGGNET, (c) ResNet, (d) Xception et (e) WaveNet en utilisant la fonction d'activation Tanh.	51
Figure 69 : comparaison de précision et de perte sur les ensembles de formation et de validation entre les modèles CNN, VGGNET, ResNet, Xception et WaveNet en utilisant les fonctions d'activation (a) Relu, (b) Selu, (c) Elu, et (d) Tanh.	52

Liste des tableaux

Tableau 1 : Points communs entre MEG et EEG.	8
Tableau 2 : Points de différence entre MEG et EEG.	9
Tableau 3 : Comparaison entre les différentes techniques d'enregistrement.	9
Tableau 4 : Les différents rythmes physiologiques de base en EEG.	10
Tableau 5 : Valeurs de précision des modèles CNN, VGGNET, ResNet, WaveNet et Xception.	53
Tableau 6 : Comparaison entre les méthodes de détection automatique de crise le plus couramment utilisé basé sur le DL.	54

Listes des abréviations

ANN: Artificial neural network

AUC: Area under the ROC Curve

BCI: Brain-Computer Interface

CNN: Convolutional Neural Network

CRCNN: Cascade-Residual Convolutional Neural Network

CT : Computerized Tomography

DL: Deep Learning

ECoG : Eastern Cooperative Oncology Group

EEG: Electroencephalography

Elu: Exponential Linear Unit

EOG : Electrooculographie

FN: False Negative

FP: False Positive

IRM : Imagerie par Résonance Magnétique

IRMf : Imagerie par Résonance Magnétique fonctionnelle

MEG : Magnétoencéphalographie

MLP : Multi Layer Perceptron

NN : Neural Network

PA : Potentiel d'Action

PR : Potentiel de Repos

ReLU: Rectified Linear Unit

ResNet : Residual Network

RPS: Royal photographic society

Selu: Scaled exponential Linear Unit

SGD: Stochastic Gradient Descent

SNC : Système Nerveux Central

SNP : Système Nerveux Périphérique

SPIR : Standard Portable Intermediate Representation

SVM: Support Vector Machine

Tanh: Hyperbolic Tangent

TN: True Negative

TP: True Positive

VGGNET: Visual Geometry Group network

Introduction générale

L'épilepsie est une affection chronique du cerveau qui touche environ 1% des individus à l'échelle mondiale [1]. Elle se caractérise par des crises récurrentes qui sont la manifestation physique de décharges électriques excessives et soudaines, généralement brèves et répétitives, produites par une population de neurones. Ces décharges peuvent se produire dans diverses parties du cerveau. Les crises peuvent varier en gravité, mais aussi en position et en volume, entraînant une brève perte de concentration, de petits secousses musculaires ou conduisant parfois à des convulsions graves et prolongées...[2-4]

Les patients dont les crises ne peuvent être contrôlées actuellement par les thérapies disponibles souffrent d'une qualité de vie considérablement réduite en raison du caractère imprévisible de ces convulsions. Le suivi de ces patients dans leurs hôpitaux peut améliorer l'environnement domestique, car il leur permet de se sentir plus en sécurité dans leur vie quotidienne. La surveillance des patients atteints d'épilepsie est devenue un sujet d'intérêt au cours des dernières décennies, il peut également améliorer l'efficacité de traitement de cette anomalie. Ainsi que la détection automatisée des crises d'épilepsie facilite l'utilisation de systèmes d'alerte automatique qui est bénéfique pour les patients et les cliniciens.

Le diagnostic se concentre sur des modalités assez différentes, telles que l'observation des comportements du patient pendant une crise ou l'étude des signaux électrophysiologiques ou de l'IRM. Ces signaux peuvent être captés de différentes manières : soit avec des électrodes de surface, soit avec des électrodes intra-cérébrales. L'électroencéphalographie de surface est une technique utilisée pour la recherche et la démonstration de l'activité électrique cérébrale puisque les fréquences et les formes des différentes ondes obtenues par cette technique d'investigations sont considérées comme des signes indicateurs de la maladie étudiée [5].

Notre objectif est de proposer un système de détection automatique des crises épileptiques, basé sur les réseaux de neurones convolutionnels (CNN). Pour atteindre cet objectif, nous avons créé cinq modèles avec différentes architectures et par la suite nous avons appliqué ces modèles sur notre base de données.

Pour expliciter notre démarche, nous organisons ce manuscrit de mémoire autour de trois chapitres comme suit : nous allons présenter, dans le chapitre 1, le contexte général c'est-à-dire l'épilepsie et les méthodes d'observation, particulièrement l'EEG.

Le deuxième chapitre présente l'état de l'art sur les méthodes qui ont opté pour la détection et la classification des signaux EEG épileptiques. Ainsi que les détails des approches proposées dans le but d'effectuer la tâche de classification.

Le troisième chapitre concerne l'expérimentation, en expliquant la procédure suivie dans ce travail, dans la première section : la base de données utilisée et les étapes d'évaluation. La deuxième section explique les expériences réalisées et les résultats obtenus avec leurs interprétations et une étude comparative entre les méthodes utilisées sera établie.

Nous clôturons cette mémoire par une conclusion générale et quelques perspectives d'amélioration.

Chapitre 1 : Cerveau, techniques d'acquisition et biomarqueurs physiologiques

1 Introduction

L'épilepsie est une affection neurologique chronique caractérisée par la répétition de crises épileptiques [6]. Ces crises entraînent une altération violente de la conscience et des actions du patient dans laquelle la fonction cérébrale devient anormale. Près de 1% de la population mondiale souffre d'épilepsie et la plupart d'entre eux ne sont pas pris en charge sur l'aspect médical. Ainsi le cerveau régit nos attitudes, nos actes, nos impulsions et nos pensées. Grâce à lui, nous pouvons voir, analyser et comprendre le monde qui nous entoure [7]. Les cellules du cerveau produisent spontanément le signal électroencéphalogramme (EEG). Ce signal est un outil de diagnostic médical précieux ; il doit être bien interprété par le médecin pour un bon diagnostic de neurologie. Par conséquent, comprendre le fonctionnement du cerveau et la production de ce signal est crucial afin de faciliter l'analyse et préciser le diagnostic en vue de prescrire un traitement adéquat au patient épileptiques.

Dans ce chapitre, nous allons présenter quelques notions de base de la physiologie tout en allant vers l'électrophysiologie du cerveau. Quelques généralités sur le système nerveux seront nécessaires pour comprendre l'origine de l'activité électrique cérébrale. Puis, nous allons décrire les principaux outils existants pour le diagnostic du cerveau seront évoqués, à savoir l'Electroencéphalographie 'EEG', et la Magnétoencéphalographie 'MEG'. Ensuite, nous allons montrer brièvement les principales pathologies neurologiques et se focaliser essentiellement sur l'épilepsie.

2 Organisation du système nerveux

Le système nerveux est divisé en deux entités : le système nerveux central (SNC) et le système nerveux périphérique (SNP) [8]. Le SNC, également connu sous les noms de l'axe nerveux, comporte la moelle épinière, et l'encéphale qui est constitué de trois parties importantes reliées les unes aux autres par des fibres nerveuses. Ces parties sont le cerveau ou le prosencéphale, cervelet et le tronc cérébral. Le SNP se compose des nerfs crâniens et rachidiens, moteurs et sensitifs. Sa fonction primaire est de faire circuler l'information entre les organes et le système nerveux central (SNC) [9].

2.1 Cerveau, neurones et synapses

Le cerveau est un organe biologique plus compliqué du corps humain. Sa protection essentiellement assurée par la boîte crânienne. Il remplit les fonctions réglementaires des autres

organes, mais aussi les mécanismes cognitifs nécessaires pour expérimenter l'environnement, pour y penser et y réagir [10].




Figure 1 : Architecture du cerveau humain.

Un neurone est une cellule excitable constituant l'unité fonctionnelle de la base du système nerveux. Il se compose de 3 parties : le corps cellulaire ou Soma, l'axone (émetteur de signaux électriques ou potentiel d'action) et les dendrites (à travers les synapses, elles assurent les connexions entre les neurones).

Une synapse est une zone de contact fonctionnelle qui s'établit entre un neurone et une autre cellule (récepteur sensoriel, musculaire), ou entre deux neurones. Elle permet la transmission de l'influx nerveux et utilise une substance chimique, les neurotransmetteurs, pour transmettre l'information.




Figure 2 : Présentation de neurone.




Figure 3 : Présentation de synapse.

2.2 Les potentiels électriques

Un signal électrique est utilisé pour transmettre des informations à distance qui se propage à travers la membrane cellulaire du neurone.




Figure 4 : Transmission de l'influx nerveux entre deux neurones.

Concernant l'activité électrique neuronale, deux types de potentiels peuvent être distingués : potentiel de repos PR et potentiel d'action PA.

2.2.1 Le potentiel de repos

Il se produit lorsque le neurone n'implique pas l'envoi d'impulsions nerveuses ou de signaux. Elle est de l'ordre de -65mV à -70mV .

2.2.2 Le potentiel d'action

C'est un signal électrique unidirectionnel traversant les axones des neurones qui provoque la libération de neurotransmetteurs au niveau des synapses. Un stimulus perçu au niveau des dendrites ou du corps cellulaire d'un neurone conduira à une dépolarisation membranaire, ce qui serait d'autant plus pertinent si l'intensité du stimulus est élevée. Lorsque la dépolarisation dépasse un certain seuil, elle déclenche un potentiel d'action qui s'étend le long de l'axone : c'est l'influx nerveux. Le potentiel d'action est caractérisé par sa courte durée ($0,3\text{ms}$) et par sa grande amplitude ($70\text{-}110\text{mV}$).

■ Forme classique de potentiel d'action

1. Le potentiel de départ est le potentiel de repos (-70mV).
2. Le potentiel augmente très rapidement (phase ascendante) pour atteindre un pic de $+30\text{mV}$.

- La dépolarisation d'une cellule désigne le passage transitoire du potentiel de repos d'une valeur négative à une valeur supérieure.
3. Après ce pic, le potentiel diminue pour se rapprocher du potentiel de repos.
- La repolarisation est la récupération de charge électrique positive pour une cellule après dépolarisation.
4. Pour de nombreux types cellulaires dans lesquels la fin de la repolarisation est plus lente, on observe des phénomènes dits post-potentiels qui peuvent être :
- Négatifs, si le potentiel transitoire est inférieur au potentiel de repos : on parle alors d'hyperpolarisation ou d'Under-shoot.
 - Positifs, s'il reste transitoirement supérieur.
- L'hyperpolarisation est le processus ou acte consistant à rendre le potentiel membranaire d'une cellule plus négatif.




Figure 5 : Potentiel de repos et d'action.

3 Les techniques d'acquisition des activités cérébrales

Dans cette section, nous allons détailler des principales techniques d'acquisition des activités cérébrales. Ces techniques sont soit superficielles non invasives telle que l'EEG et la MEG ou invasive comme l'EEG intracérébral (IEEG).

3.1 Techniques non-invasives

3.1.1 L'électroencéphalographie EEG :

Il s'agit d'une méthode de surveillance et d'étude de l'activité cérébrale électrique. Les signaux électriques du cerveau sont mesurés avec l'électroencéphalogramme. Ils sont captés par des paires d'électrodes disposées sur le cuir chevelu, permettant un enregistrement simultané en

différents points. Ces signaux sont apériodiques (ondes cérébrales) qui varient l'activité du cerveau et état de vigilance (sommeil, veille, activité physique ou intellectuelle ...).



Figure 6 : L'électroencéphalographie : EEG

Les électrodes sont utilisées pour mesurer les rythmes cérébraux et le potentiel évoqué, ainsi pour capter le bruit électromagnétique produit par les appareils électriques [11]. Plusieurs types d'électrodes existe tel que : actives, passives.

Le système international 10-20% est le système le plus utilisé afin d'assurer un placement correct reproductible des électrodes [9]. Les chiffres 10 et 20 montrent que la distance entre deux électrodes voisines est de 10% à 20% de la distance totale, soit entre l'avant et l'arrière de la tête, soit entre les côtés gauche et droit du crâne.

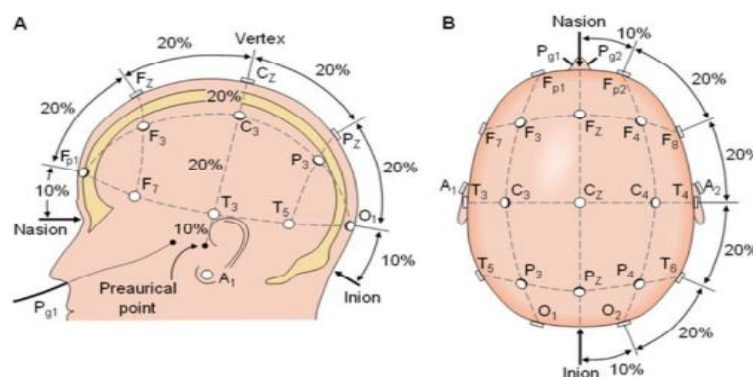


Figure 7 : Emplacement des électrodes suivant le système 10-20%.

La ligne de départ de ce système est celle qui réunit le nasion (le point juste au-dessus de la racine du nez) et l'inion (le point le plus proéminent de l'os occipital, dans la partie inférieure de l'arrière du crâne) en passant par le vertex (Sommet de la tête).

Les mesures transversales sont basées sur la distance entre les points pré-auriculaires droit et gauche. Sur la ligne par ces deux points et le point rolandique médian sont placées à 10%, 20% au-dessus, les électrodes rolandiques latérales. Une ligne circulaire, dérivant les bords de la

calotte crânienne, passe par les points Fronta-polaire et Occipital médians et les électrodes Temporales.

3.1.2 La magnétoencéphalographie MEG :

MEG est une technique d'imagerie non invasive axée sur la mesure des variations de champ magnétique causées par la stimulation électrique intracellulaire de neurones pyramidaux formant un dipôle parallèle à la surface du crâne. La MEG a une résolution spatiale moyenne et une résolution temporelle exceptionnelle qui permet de réaliser des applications en temps réel.



Figure 8 : La magnétoencéphalographie MEG.

3.1.3 Comparaison entre EEG et MEG

Pour mieux comprendre les points communs et les différences entre ces techniques d'enregistrements non-invasives, nous avons présenté les tableaux 1 et 2 :

Tableau 1 : Points communs entre MEG et EEG.


Signal	MEG/EEG
Origine	Potentiels post synaptique
Localisation	Synapses
Type	Champ électromagnétique
Résolution spatiale	>6 mm
Résolution temporelle	1 ms
Intégration	1 ms
Durée d'examen	20 à 30 min

Tableau 2 : Points de différence entre MEG et EEG.

MEG	EEG
Mesure le champ magnétique	Mesure le potentiel électrique
Réponse focale	Réponse diffuse
Peu affecté par tissus cérébraux	Très affecté par les tissus
Peu sensible aux sources profondes	Sensible aux sources profondes
Appareillage couteux	Appareillage moins cher
Sélectif pour sources tangentielles	Sensible à toutes orientations
Réponse dipolaire perpendiculaire à la direction du dipôle	Réponse dipolaire parallèle à la direction du dipôle

3.2 Techniques invasives

Un examen invasif est un examen médical qui implique une effraction de la peau plus importante qu'une simple ponction veineuse. Elle peut être douloureuse (non obligatoire) et nécessite souvent une anesthésie locale ou générale. Elle peut nécessiter une hospitalisation et entraîner un certain nombre d'effets secondaires, voire un risque d'accident. Exemple coronarographie, ponction pleurale [12].

**Figure 9 : Implantation des électrodes dans les enregistrements EEG : technique invasive.**

1.3.3. Comparaison entre les différentes techniques d'enregistrement

Les différences entre les techniques d'enregistrements invasive et non-invasives [13] sont présentées dans le tableau suivant :

Tableau 3 : Comparaison entre les différentes techniques d'enregistrement.

Technique de mesure	Nature du signal	Résolution spatiale	Résolution temporelle	Invasive	Portabilité
ECoG	Electrique	1 mm	30 ms	Oui	Oui
IRMf	Métabolique	5 mm	1 s	Non	Non
MEG	Magnétique	5 mm	50 ms	Non	Non
EEG	Electrique	1 cm	50 ms	Non	Oui
EOG	Oculaire	-	10 ms	Non	Oui
SPiR	Métabolique	1 cm	10 s	Non	Oui

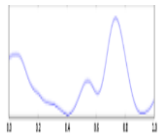
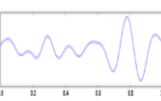
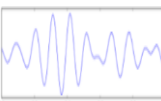
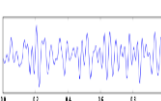
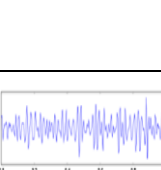
4 Principaux rythmes de l'EEG

Un rythme cérébral fait référence à une oscillation électromagnétique dans une bande de fréquences donnée résultant de l'activité électrique cohérente d'un grand nombre de neurones cérébraux, comme on peut le voir en électroencéphalographie (EEG) [14].

Ces rythmes sont classés selon leur fréquence en 5 groupes (Tableau 4) :

- **Le rythme delta** : c'est les rythmes cérébraux les plus lents dont la fréquence est inférieure de 4 Hz, pourtant leur amplitude est plus grande. Ils apparaissent sur une trace EEG d'un patient dans un état de sommeil lent [15].
- **Le rythme thêta** : c'est un rythme cérébral qui possède des fréquences assez basses (4 à 7 HZ). Il se produit lors de la première phase du sommeil lent. Il ouvre l'esprit au monde subconscient, à une compréhension soudaine, des intuitions et à plus de créativité.
- **Le rythme alpha** : c'est un rythme cérébral dont la fréquence est comprise entre 8 et 13 Hz. Il apparaît surtout avec les yeux fermés. Les ondes alpha ont été les premiers signaux détectés par l'inventeur de l'EEG puisque leur amplitude est grande. Ils se localisent dans la région occipitale. Ces types d'ondes jettent un pont entre conscient et subconscient [16].

Tableau 4 : Les différents rythmes physiologiques de base en EEG.

Rythme	Fréquence	Statut	Voltage	Etat	Figure
Delta	Moins de 4 HZ	Diffus	30 μ V	Sommeil profond sans rêve	
Thêta	4 à 7 HZ	Centro temporal	20 μ V	Rêve, méditation profonde, hypnose	
Alpha	8 à 13 HZ	Amplitude maximale postérieure	25_75 μ v (autour de 50 μ v)	Relaxation	
Bêta	13 à 35 HZ	Antérieur et moyen	20 μ v	Pensée active, action, vivacité d'esprit ou concentration active	
Gamma	>35 HZ	Antérieur et moyen	20 μ v	Excitation	

- **Le rythme bêta :** c'est un rythme cérébral dont la fréquence est comprise entre 13 et 35 Hz, occupe fréquemment de manière asynchrone les régions moyennes des deux hémisphères. Les ondes bêta dominent quand on a les yeux ouverts [17].
- **Le rythme gamma :** c'est un rythme cérébral dont la fréquence est supérieure à 35 Hz et de très faible amplitude. La détection de ce rythme peut être utilisée pour la confirmation de telles pathologies.

5 Notions générales sur l'épilepsie

5.1 Définition

L'épilepsie est un trouble neurologique qui touche environ 50 millions des populations du monde, tel que la proportion de personnes souffrant d'épilepsie évolutive à un moment donné se situe entre 4 et 10 pour 1000 personnes. Près de 1% de la population tunisienne est atteinte d'épilepsie qui touche notamment les enfants et les adolescents et peut se manifester à n'importe quel âge [18].

La crise épileptique est l'ensemble des signes cliniques et électriques représentant la décharge exagérée d'un groupe neuronal plus ou moins prolongé.

5.2 Causes et symptômes

L'épilepsie n'a pas de cause connue chez la moitié des personnes épileptiques. Dans l'autre moitié, le trouble peut être dû à divers facteurs :

- **Causes génétiques :** environ 40 % des épileptiques ont une forme génétique.
- **Causes vasculaires :** traumatisme crânien, malformation cérébrale, maladie neurodégénérative évolutive, AVC.
- **Causes acquises :** malformation congénitale, tumeur cérébrale, traumatisme, lésion cérébrale.
- **Causes toxiques :** l'alcoolisme chronique ainsi que le sevrage, antidépresseurs (surconsommation, surdosage ou sevrage), une forte dose d'alcool, drogues type cocaïne ou amphétamine.
- **Causes infectieuses :** méningite, encéphalite, abcès cérébral.

Les symptômes d'une crise d'épilepsie diffèrent d'une personne à une autre selon divers facteurs :

- Conscience altérée ou perte de conscience.
- Convulsions.
- Respiration bruyante.
- Transformation des perceptions sensorielles.
- Gestes involontaires : mastication, battements des paupières.
- Secousses musculaires saccadées et violentes.
- Arrêt respiratoire.
- Coloration rougeâtre/bleue du visage.

5.3 Diagnostic

Lorsqu'un patient souffre de symptômes liés à des crises, l'essence de ces crises doit d'abord être déterminée. En plus de la genèse épileptique, le diagnostic différentiel peut prendre en compte tous les différents types de syncope ou crise psychogène d'origine non épileptique. Le fondement du diagnostic est une anamnèse détaillée du chemin des crises.

Les patients sont également incapables de fournir eux-mêmes des détails fiables sur ce plan, car leurs crises sont suivies d'amnésie dans de nombreuses situations et ils ne se souviennent pas souvent des symptômes ou des signes précurseurs. Au mieux, ils pourront dire ce qu'ils ont entendu des tiers qui ont contribué à l'une de ces crises. Ils peuvent également divulguer ce qu'ils ont appris pendant la crise. Mais généralement, une description des événements par la famille, les amis ou les collègues serait nécessaire. Il est simple, grâce aux fonctions de caméra vidéo des téléphones portables, de capturer des images d'urgences qui peuvent ensuite être montrées au médecin. Compte tenu des incertitudes auxquelles nous sommes confrontés au cours de l'étude, nous essayons souvent d'obtenir un enregistrement d'une crise typique à l'aide d'un EEG à long terme ou d'une surveillance vidéo-EEG chez nos patients [19].

5.4 Classification des crises épileptiques

L'épilepsie survient suite à l'excès soudaine des signaux électriques dans tout ou partie du cerveau. Lorsque cette activité électrique irrégulière se produit dans une zone délimitée du cerveau, elle est considérée comme une crise partielle. Quand elle couvre tous les cerveaux, elle est appelée généralisée. Il existe d'autres type de crise tel que la crise inclassable.

- **Les crises partielles (ou focales) :** elles peuvent être simples ou complexes.
 - **Crises partielles simples :** La personne reste consciente et se souvient de la crise. Les sensations rencontrées par les patients varient selon la région focale impliquée : odeurs bizarres, sentiments étranges (peur, hallucination, impression de déjà-vu ...), picotements.

- **Crises partielles complexes** : Ce type de crise peut débuter comme une crise partielle simple pour ensuite se propager aux régions qui contrôlent la conscience. Dans ce cas, une perte de contrôle et de conscience est observée. Les patients peuvent avoir des mouvements indésirables, comme marcher en cercle ou macher d'une manière non réglementée. Après la crise, la personne peut être désorientée, ressentir des vertiges, des maux de tête, de la fatigue ou encore des palpitations [20].



Figure 10 : Crises partielles.

- **Les crises généralisées** : elles se caractérisent par une décharge anormale et simultanée de neurones dans le cerveau. On peut la diviser en différentes formes :
 - **Crises toniques** : elles se manifestent par une importante raideur ou une augmentation accrue du tonus musculaire. Elle peut durer de 15 secondes à 1 minute selon le cas de patient.
 - **Crises cloniques** : elles se traduisent par des spasmes rythmés et des secousses violentes affectant les membres et la face. Elles peuvent durer de 30 secondes à 3 minutes.
 - **Les crises tonico-cloniques (grand mal)** : il s'agit de la forme la plus intense de crise généralisée. Dans ce cas le patient a perdu connaissance, on observe un raidissement des muscles, un manque de coordination des mouvements et une perte de contrôle de la vessie (perte des urines) [21].
 - **Les crises myocloniques** : se caractérisent par des contractions suivies d'une secousse plus violente.
 - **Les crises d'absence (petit mal)** : cela peut entraîner une perte de connaissance brève avec secousses musculaires brèves.
 - **Les crises atoniques** : sont caractérisées par des chutes avec une perte du tonus musculaire.



Figure 11 : Crises généralisées.

Les crises inclassables : Les crises inclassables sont celles qui ont au moins des connaissances cliniques à leur disposition [22], puisqu'elles sont rares.

5.5 Les états d'épilepsie

L'épilepsie est caractérisée par l'émergence brutale de crises. Il s'agit d'une transition entre un état stable nommé « inter-critique » et un état pathologique nommé « critique ». Cette transformation est corrélée à un changement dynamique de l'activité électrique des neurones. L'étude de cette activité permet de différencier 4 phases : phases pré-ictal (pré-critique), phase ictal (critique), post-ictal (post-critique), et phase inter-ictal (inter-critique) [23]. La forme d'onde du signal EEG associée à ces quatre phases est présentée dans la figure suivante :




Figure 12 : Passage d'un état normal à un état critique.

- **Phase pré-ictal :** Lors de cette phase, le patient peut présenter des signes de problèmes de comportement (tremblement, nerfs, agitation, etc.). Cette phase est marquée par l'apparition brusque de pointes isolées sporadiques et de fortes amplitudes. Cela peut durer quelques minutes à une heure [24].
- **Phase ictal :** Une activité ictal ou critique est corrélée à une crise épileptique qui peut être clinique ou infraclinique. L'électroencéphalographie est le seul examen clinique pouvant montrer des symptômes et des signes définissant la crise épileptique.
- **Phase post-ictal :** elle fait référence aux activités enregistrées juste après une crise d'épilepsie.

- **Phase inter-ictal** : elle dure entre deux crises consécutives. Le suivi de l'EEG reflète des anomalies appelées « événements paroxystiques » pouvant impliquer la nature de crise et la ou les régions intéressées, par la suite les foyers épileptogènes [25]. Cependant, au cours de cette phase, le patient ne présente réellement aucun signe de sa maladie (pas d'agitation ni convulsions).

5.6 Les pointes épileptiques

Les événements paroxystiques varient selon qu'ils surviennent à l'intérieur ou à l'extérieur d'une crise, et dans certaines situations, la distinction entre état critique et inter-critique peut être abordée. Des ondes anormales paroxystiques se détachant du signal de fond peuvent apparaître sur le tracé EEG pendant le temps inter-critique. Une description de ces éléments graphiques est fournie par la fédération internationale des sociétés d'électroencéphalographie et de neurophysiologie clinique.

- **La pointe** : est une onde très aiguë séparée de l'activité de fond par son amplitude et une durée de 20 à 70 ms.
- **La pointe lente (onde aigu)** : pointe de grande amplitude d'une durée comprise entre 70 et 200 ms ayant ainsi un aspect moins aigu qu'une pointe.
- **Les pointes-ondes** : est une pointe accompagnée d'une onde lente de même polarité que la pointe arrondie et de longueur de morphologie entre 300 et 400 ms voire plus lente (400 à 1000 ms) alors appelée " point onde lente ".
- **Les poly-pointes** : succession de deux ou plusieurs pointes.




Figure 13 : Exemple de pointes, de poly pointes et d'ondes à front raide.

6 Conclusion

Tout au long de ce chapitre, nous avons présenté des notions de base de la physiologie ainsi que l'électrophysiologie du cerveau. Nous avons mis l'accent sur l'ensemble des techniques de

mesure cérébrale tel que les techniques invasives et non invasives. Ensuite, nous avons présenté les notions générales sur l'épilepsie, leur classification, causes, symptômes, et les points épileptiques. Dans le chapitre suivant, nous allons détailler notre méthodologie utilisée pour la détection des crises épileptiques.

Chapitre 2 :

Détection des crises épileptiques en se basant sur l'apprentissage profond

1 Introduction

L'épilepsie est un ensemble de changements soudains et persistants dans l'activité électrique neuronale détectée par l'EEG. Plusieurs approches de traitement de signal ont été utilisées pour aider les cliniciens dans l'investigation et le diagnostic des troubles neurologiques, ainsi que dans la classification de l'activité épileptique. Ces méthodes sont capables de faire la distinction entre les épisodes critiques et normaux, cependant les signaux sont extrêmement perturbés par des signaux extra-cérébraux appelés « artéfacts ». Ces objets oculaires, musculaires ou cardiaques peuvent masquer la véritable activité épileptique. L'analyse d'un enregistrement EEG par le spécialiste dans ce cas prend plus de temps et peut être très approprié, ce qui nécessite une méthode automatisée pour une lecture et une analyse précise des signaux EEG. Dans ce chapitre, un état de l'art sur les méthodes de traitement des signaux les plus utilisés pour la détection des crises épileptiques. Dans la suite, nous donnons une description de différentes approches proposées.

2 Etat de l'art

De nombreuses méthodes de détection des crises d'épilepsie ont été proposées par des chercheurs par exemples dans [26], les auteurs ont proposé CNN 3D basé sur le multicanal EEG pour prédire les différentes étapes des données EEG, y compris les stades inter-ictal, précritique et ictal. Cette méthode a surpassé le CNN 2D et les méthodes de traitement du signal traditionnelles avec une précision de plus de 90%, une sensibilité de 88,90% et une spécificité de 93,78%.

Dans [27], les auteurs visent à explorer la capacité d'un modèle CNN à détecter les crises à l'aide de signaux EEG du cuir chevelu brut et à comparer ses performances avec un modèle ANN en utilisant plusieurs fonctionnalités sélectionnées comme entrées basée sur le classifieur bayésien [28] pour sélectionner les caractéristiques dominantes indépendamment. Le modèle CNN a donné une précision de 99,07% et une spécificité de 99,63% alors que le modèle ANN a donné une précision de 98,62% et une spécificité de 98,92%. Donc, ils ont démontré que le ANN avec des caractéristiques dominantes est plus capable de détecter les événements de crise que le CNN. De plus, et quoique que le CNN ne nécessite aucune extraction de caractéristiques, il est légèrement meilleur que le ANN dans la précision de la classification.

Dans [29], les auteurs appliquent un apprentissage profond basé sur les réseaux de neurones convolutifs (CNN) avec une technique de validation croisée qui a été appliqué dans la phase de conception du système. Pour plus d'efficacité, des résultats comparatifs entre d'autres approches d'apprentissage automatique telle que SVM avec la fonction de noyau linier et le réseau neuronale NN à trois couches avec 18 neurones cachés et une fonction d'activation gaussienne, et de CNN ont été obtenus. Le résultat de précision pour SVM et NN était de 75%, mais celui de CNN était de 96,67% ce qui indique l'efficacité de l'utilisation de CNN dans l'identification des crises épileptiques.

Un algorithme de descente de gradient stochastique (SGD) a été utilisé dans [30], afin d'apprendre le meilleur ensemble de poids et de biais du réseau neuronal qui minimise la fonction de perte. Les résultats de classification complets montrent que le CNN est capable de classifier des signaux EEG et de détecter des crises d'épilepsie en atteignant 99,48% de la précision globale de la classification.

Dans [31], les auteurs ont réalisé des expériences afin de comparer les performances des signaux EEG en utilisant des caractéristiques extraites du domaine temporel et fréquentiel. Cette méthode a évité le processus complexe d'extraction de caractéristiques et a utilisé une structure CNN simple. L'utilisation des caractéristiques fréquentielles donne une précision moyenne de 96.7, 95.4 et 92.3% pour les trois expériences tandis que les caractéristiques temporelles donnent des valeurs de précisions de 91.1, 83.8 et 85.1% dans les trois expériences. La classification basée sur l'utilisation des caractéristiques fréquentielle était remarquablement plus précise, sensible et spécifique que la classification basée sur les caractéristiques temporelles.

Dans [32], les auteurs ont utilisé RPS comme entrée au modèle CNN pour construire l'espace des phases d'un système dynamique. Cette image est utilisée pour tester un CNN de l'architecture AlexNet afin de classer l'image RPS en classes épileptiques et non épileptiques. La précision de classification du modèle pour les classes binaires est de $(98,5 \pm 1,5) \%$ (épileptique vs non épileptique) et pour les classes ternaires $(95 \pm 2) \%$ (normal vs inter-ictal vs ictal) qui est plus élevé par rapport aux quelques résultats existants dans la littérature.

Dans [33], les auteurs ont proposé une méthode basée sur le CNN, et effectué dans le cadre d'apprentissage non supervisé pour la détection automatique du début des crises. Les différents hyperparamètres et les critères d'arrêt du système ont été optimisés grâce à une validation croisée imbriquée. Le résultat de modèle CNN généralisé pour la détection des crises a atteint une sensibilité moyenne de 86,29%, un taux de fausse de 0,74 et une latence de 2,1 sec.

Dans [34], les auteurs ont proposé un cadre CNN multi-vues pour prédire la survenue des crises épileptiques. L'élément central du cadre proposé est de considérer le domaine temporel et le domaine fréquentiel en deux différentes entrées et utiliser une couche partagée pour apprendre la représentation d'entités. Un SVM est utilisé comme classificateur final. Les résultats expérimentaux indiquent que le score privé du CNN multi-vues proposé surpasse toutes les méthodes répertoriées puisqu'il atteint une surface moyenne sous la courbe (ROC) de 0,82 et 0,89 sur deux sujets de l'ensemble de données EEG.

Plus de la détection des crises d'épilepsie, le CNN a été appliqué dans divers problèmes connexes, tels que l'interface cerveau-ordinateur (BCI) et la reconnaissance des émotions.

3 Architecture générale du système proposée

L'apprentissage en profondeur à l'aide de réseaux de neurones convolutifs (CNN) a pris de l'ampleur ce dernière année. La classification d'image est l'une des applications clés d'apprentissage profond en utilisant CNN. Afin d'identifier les signaux EEG comme normaux ou épileptique, nous avons proposé cinq approches d'apprentissage profond : CNN 1D, VGGNET, ResNet, Xception et WaveNet. L'architecture générale du système proposée est présenté dans la figure 14. Dans la première étape, le procédé comprend la représentation d'entrée EEG afin d'extraire les caractéristiques requises pour la classification. Google Colaboratory a été utilisé dans ce travail pour gérer, analyser et tester les cinq pré-architectures pour la détection des crises épileptiques.

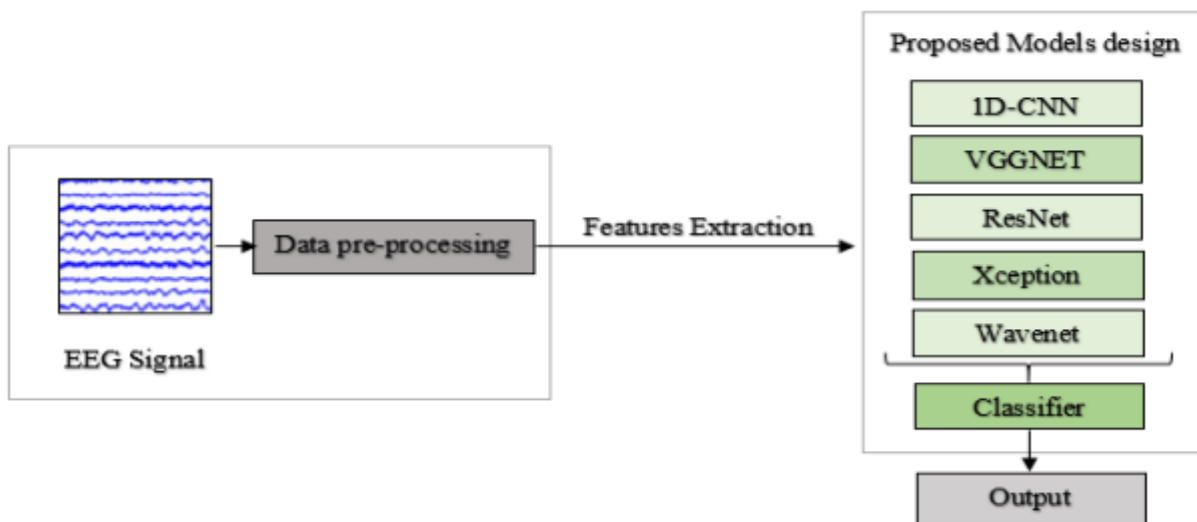


Figure 14 : Architecture générale du système proposée

3.1 Représentation des entrées

Il existe de nombreuses techniques utilisées pour la représentation d'entrée EEG dans les modèles d'apprentissage profond. Puisque les modèles d'apprentissage profond comme les réseaux de neurones convolutionnels nécessitent des entrées 2D, par conséquent, de nombreux chercheurs ont converti les enregistrements EEG en images et topo-maps [35-36]. Certains modèles d'apprentissage profond ont utilisé la tension d'électrode pour transformer les enregistrements EEG en images topographiques organisées en séries chronologiques [36]. Cependant, il existe des preuves que le signal EEG est corrélé sur les données de séries temporelles, [37], donc dans ce travail, nous avons utilisé des données EEG brutes comme entrée, représentées sous forme de tableau bidimensionnel dans lequel toutes les électrodes d'entrée sont présentées en hauteur et tous les pas de temps en largeur.

3.2 Architecture du modèle CNN

Le modèle CNN est un type de réseau de neurones artificiels acycliques dans lequel le lien entre les neurones est inspiré par le cortex visuel des animaux. A ce jour, CNN est le modèle le plus performant dans l'apprentissage profond pour classer des images. En entrée, une image est fournie sous la forme d'une matrice de pixels qui peuvent être binaire (des 0 et des 1 : des pixels noirs et des pixels blancs), en niveaux de gris (de 0 jusqu'à 255 : dégradation de couleur blanc jusqu'au noir) ou en couleur (RGB : Red, Green, Blue).

Le CNN se compose de 4 types de couches différentes : couche convolutive, couche pooling, couche flatten, et couche entièrement connectée.

3.2.1 Couche convolutive

La couche de convolution est le cœur de CNN ; il est chargé d'extraire les caractéristiques de haut niveau des images d'entrée. La couche de convolution est basée sur la convolution des filtres sur l'image afin d'extraire les entités qui seront enregistrées dans les cartes d'entités. La figure 15 représente un exemple de couche de convolution. De plus, la couche de convolution C_i (couche réseau i) est paramétrée par son nombre N de filtres de convolution M_{ij} ($j \in 1 \dots N$), appelés aussi noyaux, et la taille des filtres qui sont souvent carrés (K). Chaque carte des caractéristiques est le résultat d'une somme de convolution des cartes de la couche M_{i-1} précédente par son noyau de convolution respectif. Un biais b_i est alors ajouté et le résultat est passé à une fonction d'activation $f(x)$.




Figure 15 : Exemple de couche de convolution.

Trois paramètres permettent de dimensionner le volume de la couche de convolution : kernel, stride et padding.

- 1) **kernel (noyau)** : représente la taille de la matrice du filtre souvent en 3×3 .
- 2) **stride (pas)** : représente le décalage du kernel entre chaque calcul.
- 3) **padding (marge)** : ajoutez des 0 autour de l'image d'entrée, afin de maximiser la taille de l'image de sortie ou arrêter les dépassements.

3.2.2 Couche pooling

Après chaque couche convolutive, il peut y avoir une couche de pooling. Cette couche sous échantillonne le long de la dimensionnalité spatiale de l'entrée donnée, ce qui réduira davantage le nombre de paramètres dans cette activation. Il existe de nombreuses façons de faire cette mise en commun, comme prendre la valeur maximale (max pooling : revient à prendre la valeur maximale de la sélection), la valeur moyenne (mean pooling ou average pooling : la somme de toutes les valeurs divisées par le nombre de valeurs) ou la somme (sum pooling : c'est la moyenne sans avoir divisé par le nombre de valeurs) [38-40].




Figure 16 : Application Max pooling sur une image.

3.2.3 Couche Flatten

La couche Flatten consiste à mettre de bout en bout toutes les images (matrices) que nous avons pour en faire un vecteur. Les pixels (ce ne sont plus des images ou des pixels, mais des matrices de nombres) sont récupérés ligne par ligne et ajoutés au vecteur final.

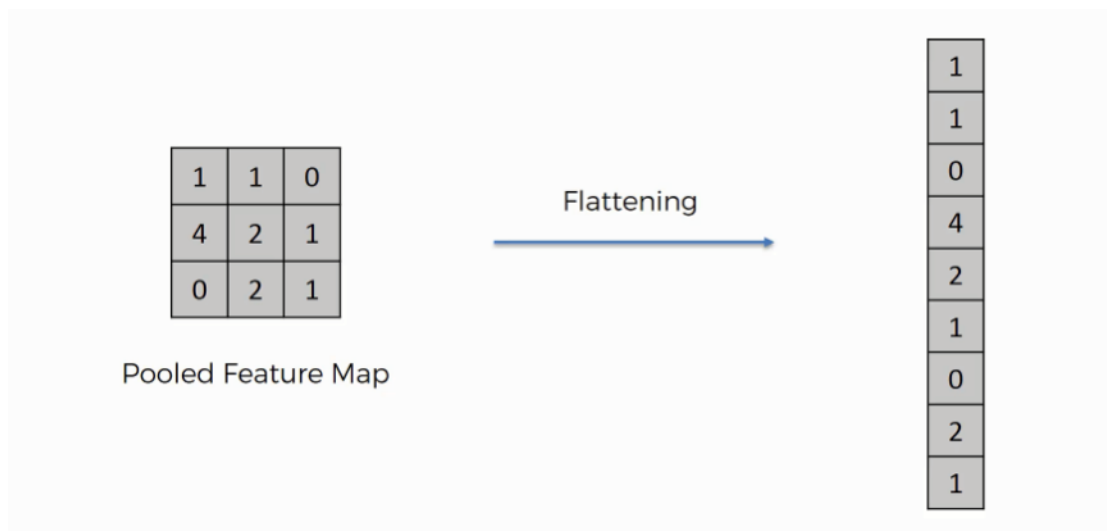


Figure 17 : Mise à plat des images finales en sortie des filtres+simplicifications.

3.2.4 Couche entièrement connectée

Les couches entièrement connectées sont les principaux blocs de construction de réseaux de neurones convolutifs (CNN), qui ont fait leurs preuves dans la reconnaissance et la classification des images. Le processus CNN commence par la convolution et la mise en commun, la décomposition de l'image en caractéristiques et leur étude indépendante. Le résultat de ce processus alimente une structure de réseau neuronal entièrement connecté qui conduit la décision de classification finale. Le but d'une couche entièrement connectée est de prendre les résultats du processus de convolution / regroupement et de les utiliser pour classer l'image dans une étiquette. La sortie de la convolution / mise en commun est aplatée en un seul vecteur de valeurs, chacune représentant une probabilité qu'une certaine caractéristique appartienne à une étiquette.

La figure 18 représente un exemple des couches entièrement connectées.




Figure 18 : Exemple des couches entièrement connectées.

La figure 19 montre l'architecture du modèle CNN que nous avons utilisé dans ce travail. Alors, afin de détecter cette anomalie nous avons créé un simple CNN composé par 4 couches convolutives, une couche Flatten, et deux couches entièrement connectées. Chaque couche convolutive génère une carte d'entités pour conserver les informations sur les images d'entrée [41]. Les résultats obtenus par ces opérations seront transférés à la couche suivante. Ensuite, la couche de max pooling est utilisée dans le milieu de la couche de convolution pour minimiser la dimensionnalité de la carte des caractéristiques ainsi que le nombre de paramètres entraînaables. Les deux premières couches convolutives ont 64 filtres tandis que les deux derniers ont 128 filtres, chacun qui a une taille de noyau 3×3 . La fonction d'activation ReLU (Rectified Linear Unit) est utilisée dans chaque couche. ReLU est une fonction importante utilisée pour former un modèle pour un réseau neuronal. La principale raison d'utiliser ReLU dans les couches convolutives est sa convergence qui est plus rapide en raison du manque du problème du gradient d'extinction et de la rareté des fonctionnalités. Les deux couches entièrement connectées agissent comme un classificateur. Ils utilisent des caractéristiques extraites pour déterminer la probabilité qu'un objet est présente.

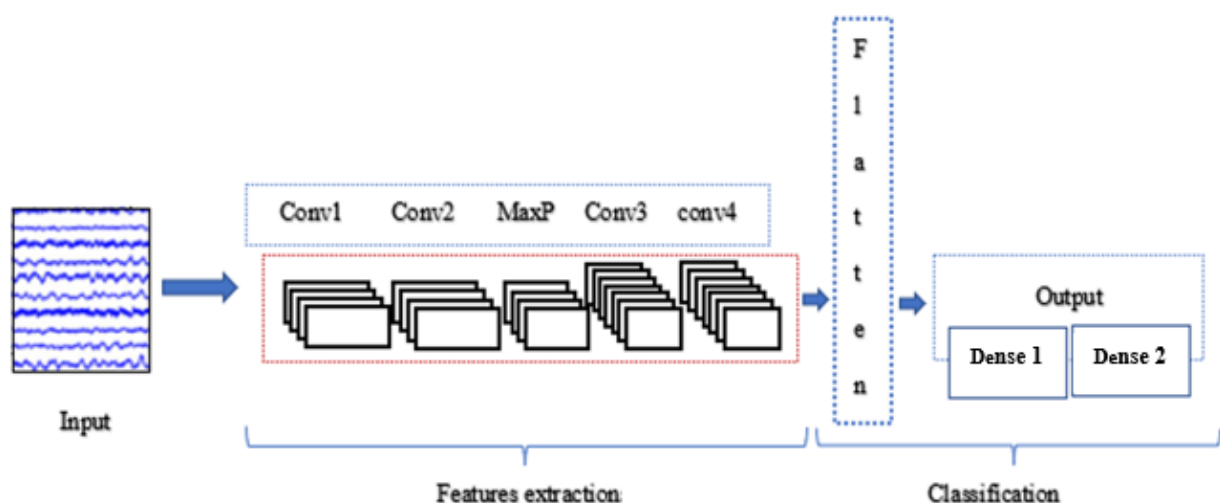


Figure 19 : Architecture du modèle CNN.

3.3 Architecture du modèle VGGNET

Le modèle VGGNET a été présenté par Ka-ren Simonyan et Andrew Zisserman dans [42]. C'était considéré comme un réseau très profond pour la reconnaissance d'image. La contribution clé a été de montrer que le réseau de profondeur est un élément essentiel pour obtenir une meilleure reconnaissance ou une meilleure précision de classification CNN. L'une des configurations VGG couramment utilisées pour la détection d'objets sont VGG-16 et VGG-19. Dans ce travail, nous avons utilisé la version VGG-19, qui se compose de 16 blocs. Chaque bloc contient une couche convolutive, une couche batch normalization et une fonction d'activation. Les blocs sont suivis par des trois couches entièrement connectées.

Les caractéristiques de VGG-19 sont les couches convolutives 3×3 qui sont empilées les unes sur les autres, et la profondeur devient de plus en plus grande. La réduction de la taille du volume est gérée par la mise en commun maximale. La figure 20 présente l'architecture du modèle VGG-19.

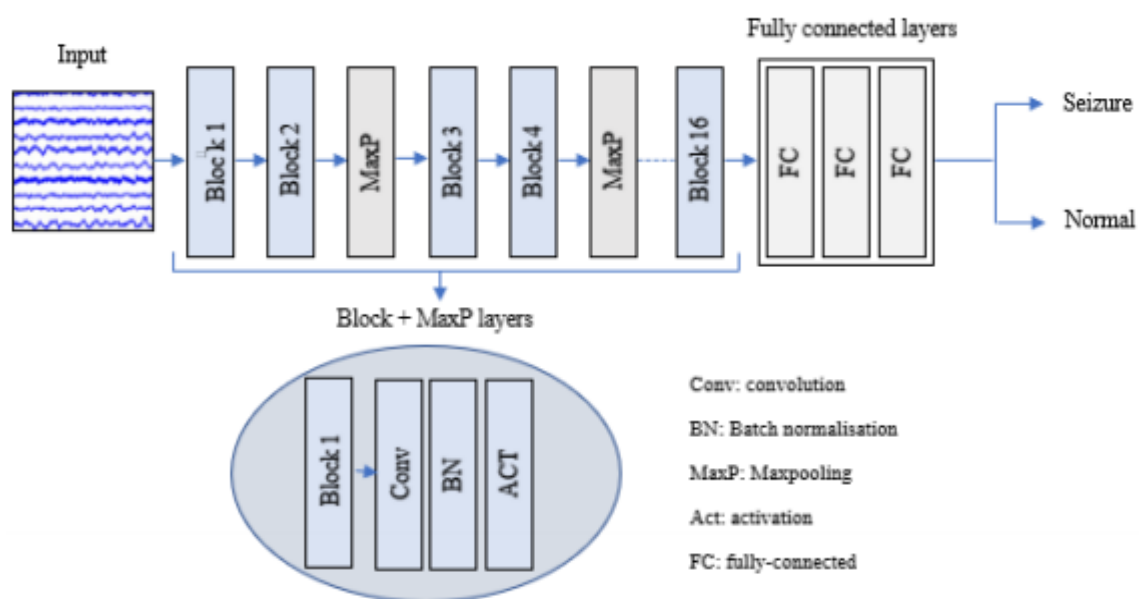


Figure 20 : Architecture du modèle VGG-19.

3.4 Architecture du modèle ResNet

Residual Network ou ResNet, est un réseau de neurones introduit en 2015 par Kaiming He, Xiangyu Zhang, Shaoqing Ren et Jian Sun dans leur article « Residual Deep Learning for the Recognition of Picture ». Il est considéré comme une continuation de réseaux profonds qui a révolutionné la course architecturale CNN en introduisant le concept d'apprentissage résiduel dans les CNN et mis au point une méthodologie efficace pour la formation des réseaux. ResNet est également placé sous les CNN basés sur les trajets multiples en raison de l'utilisation d'un

clustering global moyen au lieu d'une couche connectée. La taille du modèle est en fait beaucoup plus petite, ce qui minimise la taille du modèle ResNet. La partie spéciale de ResNet est le bloc d'apprentissage résiduel. Cela signifie que chaque couche doit alimenter la couche suivante, et la distance directement dans les couches est d'environ 2 à 3 sautes. L'approche consiste à ajouter un raccourci ou une connexion de saut qui permet aux informations de circuler. Dans ce travail, ResNet est composé d'une couche convolutive 3×3 unique suivie de 9 blocs résiduels et 3 couches entièrement connectées avec une mise en commun maximale appliqué entre les couches. La figure 21 présente l'architecture du modèle ResNet.

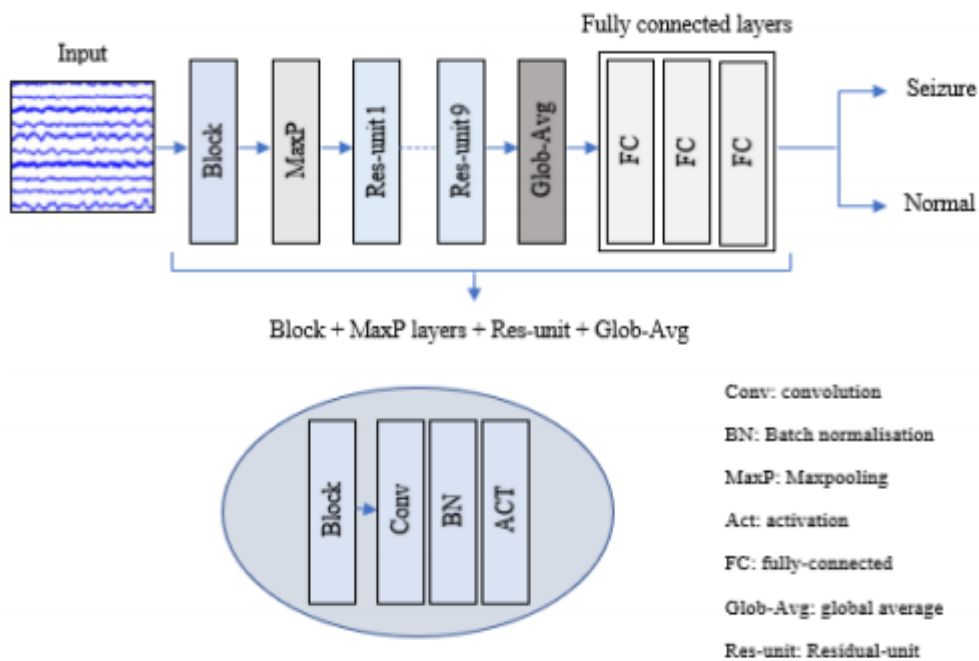


Figure 21 : Architecture du modèle ResNet.

3.5 Modèle Xception

La figure 22 présente l'architecture générale pour Xception qui est une nouvelle structure proposée par François Chollet en 2017. Xception est considéré comme une extension de l'architecture Inception qui remplace leur module habituel avec des convolutions profondément séparables afin de minimiser la taille de l'architecture jusqu'à 91 Mo. Il a 36 couches convolutives formant la base de l'extraction des caractéristiques du réseau. Leur architecture est un empilement linéaire de couches convolutives parfaitement séparables avec connexions résiduelles. Ce qui facilite la définition ainsi que la modification de leur architecture.

Dans Xception, les données passent d'abord par le flux d'entrée, puis par le flux intermédiaire qui se répète huit fois, et enfin à travers le flux de sortie. Notez que la convolution et les couches de convolution séparables sont livrées avec de lot de normalisation (non incluse dans la figure 22). Toutes les couches de convolution séparable utilisent un multiplicateur de profondeur de 1.

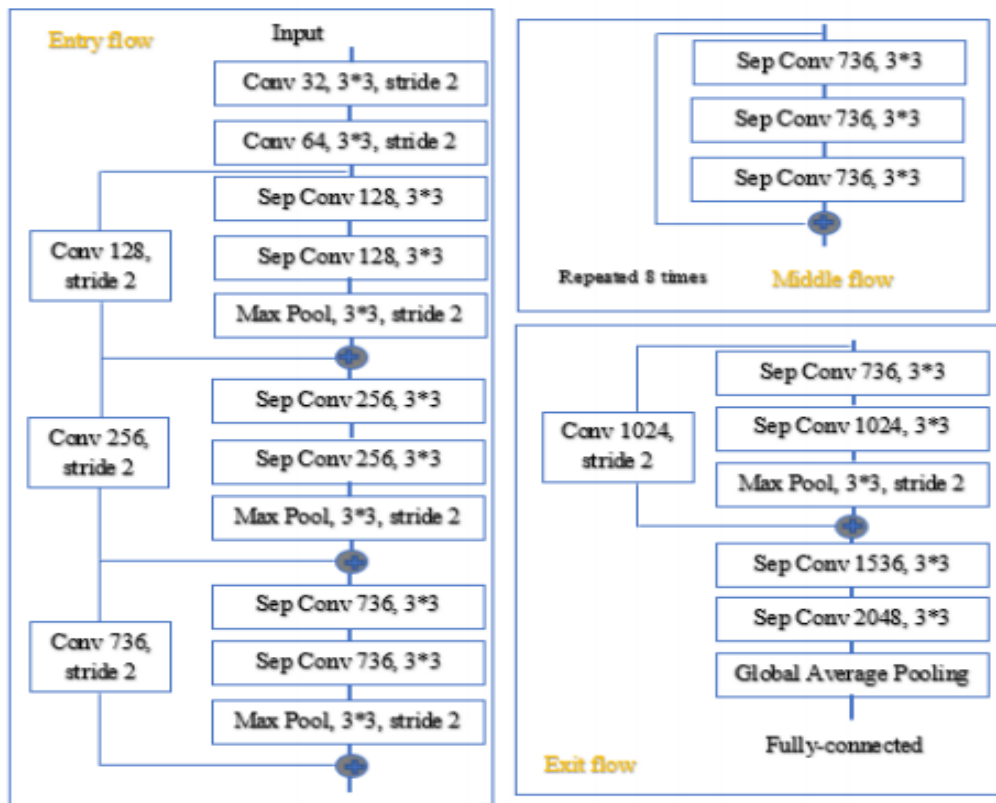


Figure 22 : Architecture du modèle Xception.

Convolution séparable : C'est une solution au problème de la complexité des calculs au niveau de convolution qui rend le fonctionnement de réseau un peu plus long, avec moins de calculs, le réseau est capable de traiter plus de données en un temps réduit.

Il existe deux types de convolution séparables tels que convolution séparable spatiale et convolution séparable en profondeur. Puisque le traitement de convolution séparable spatiale se limite principalement à des dimensions spatiales (la largeur et la hauteur). La spécification majeure de la structure Xception est le concept de convolution spatiale en profondeur [43].

Convolution séparable en profondeur : C'est une solution qui traite à la fois des dimensions spatiales et des dimensions en profondeur (nombre de canaux). Une image d'entrée peut avoir 3 canaux (RGB). Après quelques convolutions, une image peut avoir plusieurs canaux. Semblable à la convolution spatiale séparable, une convolution séparable en profondeur divise un noyau en 2 noyaux distincts qui effectuent deux convolutions : la convolution en profondeur et la convolution ponctuelle (taille de 1×1).

La convolution modifiée dans la structure Xception est la convolution ponctuelle suivie d'une convolution en profondeur. Selon lequel, une convolution 1×1 est effectuée avant toutes les convolutions spatiales de taille $n \times n$.

3.6 Modèle WaveNet

WaveNet est un réseau neuronal profond pour la production de formes d'ondes audio générées par des chercheurs de la société d'intelligence artificielle basée à Londres DeepMind. Afin de résoudre les dépendances temporelles à long terme requises pour la génération d'audio brute, les architectures sont construites sur la base de convolutions causales dilatées, qui ont un très grand champ récepteur. Ce réseau est basé sur l'architecture pixel CNN. Le modèle est complètement probabiliste et autorégressif. La distribution prédictive de chaque audio d'échantillon est conditionnée sur tous les précédents. Néanmoins, avec des dizaines de milliers d'échantillons par seconde d'audio, il peut être efficacement alimenté par les données. Un seul WaveNet peut capturer les caractéristiques de nombreuses enceintes différentes avec la même fidélité et peuvent basculer entre elles en conditionnant l'identité dès l'enceinte. Ça peut être utilisé comme modèle discriminant, offrant des résultats prometteurs pour la reconnaissance de phonèmes.

La figure 23 montre l'architecture du modèle WaveNet utilisé dans ce travail. Dans ce modèle, les entrées passent par une convolution causale utilisée pour les données temporelles, suivie de 60 opérations de convolution et une unité d'activation fermée utilisée entre eux pour modéliser les opérations complexes. Ces blocs sont suivis par deux fonctions activations Relu et une fonction de sortie sigmoïde.

La première étape est le prétraitement audio, après l'entrée la forme d'onde est quantifiée dans une plage entière fixe. L'entier les amplitudes sont ensuite codées à chaud. Ces échantillons encodés à chaud sont passés par convolution causale.

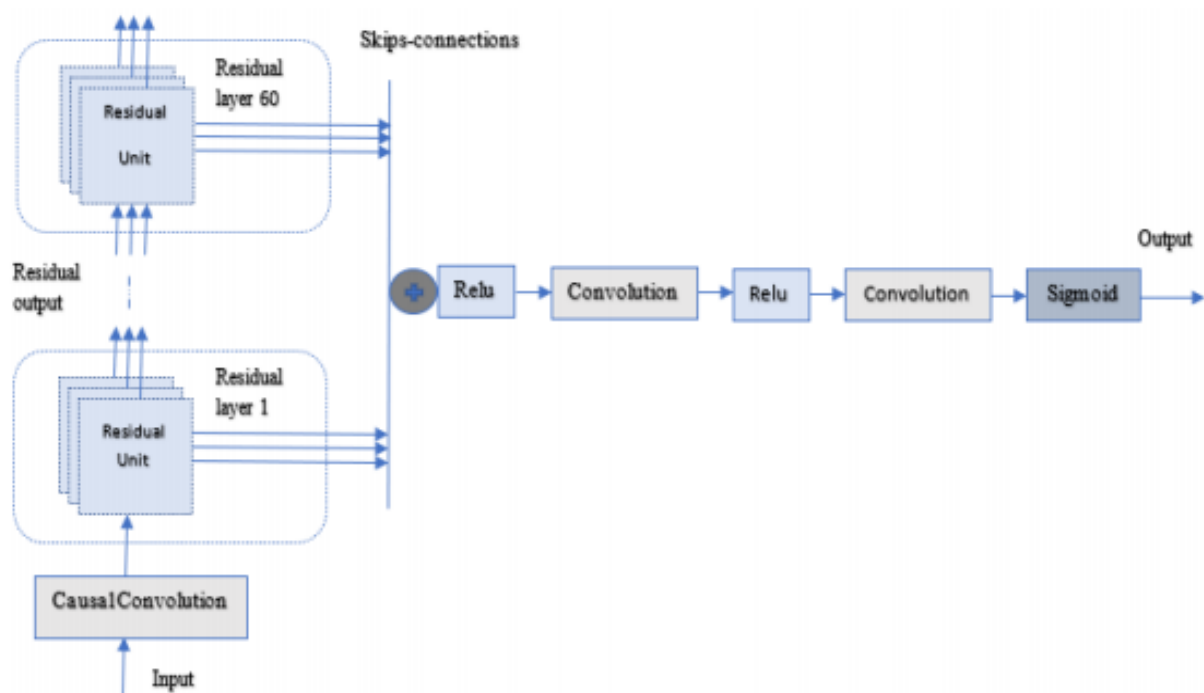


Figure 23 : Architecture du modèle WaveNet.

Convolution causale dilatée : est une convolution causale où le filtre est appliqué sur une zone plus grande que sa longueur en sautant les valeurs d'entrée avec un certain pas. Une convolution causale dilatée permet effectivement au réseau d'avoir de très grands champs récepteurs avec seulement quelques couches.

4 Conclusion

Nous avons consacré ce chapitre à la présentation des différents modèles basé sur l'approche Deep Learning, en premier temps, nous avons commencé par un état de l'art sur les méthodes de traitement des signaux, ensuite une description globale des méthodes proposées pour la détection des crises et en fin une conclusion. Le chapitre suivant sera consacré essentiellement à l'implémentation de ces méthodes et le test de la performance de notre approche proposée.

Chapitre 3 :

Évaluation des architectures utilisées pour la détection des crises épileptiques

1 Introduction

L'épilepsie est un trouble cérébral chronique qui se traduit par des convulsions. La surveillance de l'activité cérébrale par électroencéphalogramme (EEG) est une méthode établie pour le diagnostic de l'épilepsie et pour le suivi des patients épileptiques. Pourtant, il n'est pas favorable d'inspecter visuellement les signaux EEG pour diagnostiquer l'épilepsie, en particulier dans le cas d'enregistrements à long terme. Ce processus est un exercice long et fastidieux sujet aux erreurs. Ces dernières années, le sous-domaine de l'apprentissage automatique appelé apprentissage profond a remporté un succès remarquable dans divers domaines de recherche sur l'intelligence artificielle. Dans ce chapitre, nous détaillons les résultats expérimentaux sur la performance de nos modèles d'apprentissage profond. De plus, nous représentons la base de données utilisée. Et nous finissons par comparer les résultats obtenus par notre système avec d'autres approches de l'état de l'art.

1.1 Description de la base de données

Afin de réaliser ces expériences, nous avons utilisé l'ensemble de données CHB-MIT, collecté à l'hôpital pour enfants de Boston. C'est un ensemble de données plus grand disponible gratuitement pour les données concernant des crises épileptiques [44]. Les données sont enregistrées auprès de 23 patients épileptiques, dont 5 hommes et 18 femmes âgées de 10 à 22 ans. Cette base contient 686 enregistrements EEG du cuir chevelu à canaux multiples de patient pédiatriques qui ont été affectés par des crises épileptiques réfractrices, dans la plupart de l'activité de crise dure environ 25 s pour chaque enregistrement EEG. Le système international de montage d'électrodes EEG 10/20 est utilisé pour enregistrer à propos de l'ensemble de données. Parmi 686 enregistrements EEG, seulement 198 contiennent une ou plusieurs crises. Il y a 969 h d'enregistrements EEG du cuir chevelu contenant 173 crises d'épilepsie. Le taux d'échantillonnage utilisé est de 256 Hz et une résolution de 16 bits.

1.2 Métrique d'évaluation

Différents critères de performance peuvent être utilisés pour évaluer les performances des modèles de classification, à savoir l'exactitude, sensibilité, spécificité, précision, rappel et score

F1. Dans ce travail, nous sommes intéressés seulement par un critère de classification : la précision.

1.2.1 La précision (accuracy)

La précision est le nombre des échantillons correctement classée (les résultats corrects positifs et les résultats corrects négatifs) divisés par le nombre total d'échantillons (combien d'élément sélectionné sont pertinents ?).

Afin de déterminer l'efficacité d'un classificateur, il faut distinguer quatre types des éléments classés pour la classe souhaitée : TP (vrai positif), TN (vrai négatif), FP (faux positif) et FN (faux négatif).

- **TP** : les cas où la prédiction est positive, et où la valeur réelle est effectivement positive. Exemple : Vous avez prédit que le patient est infecté par l'épilepsie, et il l'est en fait.
- **TN** : les cas où la prédiction est négative, et où la valeur réelle est effectivement négative. Exemple : Vous avez prédit que le patient n'est pas infecté par l'épilepsie, et il est en fait comme vous l'aviez prédit (il n'est pas infecté par l'épilepsie).
- **FP (erreur du type 1)** : les cas où la prédiction est positive, mais où la valeur réelle est négative. Exemple : Vous avez prédit positif et vous vous trompez. Vous avez prédit que le patient est infecté par l'épilepsie, mais il n'est en fait pas comme vous l'aviez prédit (il n'est pas infecté par l'épilepsie).
- **FN (erreur du type 2)** : les cas où la prédiction est négative, mais où la valeur réelle est positive. Exemple : Vous avez prédit négatif et vous vous trompez. Vous avez prédit que le patient n'est pas infecté par l'épilepsie, mais il est en fait infecté par l'épilepsie.

Dans ce qui suit, nous présentons le critère de performance adoptée pour évaluer les performances des différents modèles pré-entraînés utilisés.

$$Accuracy = (TP + TN) / (TP + TN + FP + FN) \quad (1)$$

1.2.2 Matrices de confusion

Une matrice de confusion ou table de contingence est un outil permettant d'évaluer l'efficacité d'un modèle d'apprentissage automatique en vérifiant, notamment, la fréquence à laquelle ses prédictions sont correctes par rapport à la réalité dans les problèmes de classification. Cette matrice permet d'expliquer comment le modèle de classification est confus lors de la réalisation de prédictions. Cela permet de savoir quelles erreurs ainsi que les types d'erreurs sont commises.

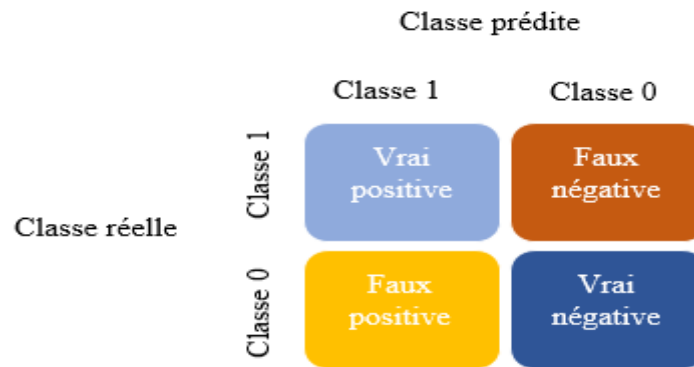


Figure 24 : Aperçus sur la matrice de confusions.

2 Résultats expérimentaux

Nous avons optimisé les modèles CNN, VGGNET, ResNet, Xception et WaveNet sur 20 époques. Nous définissons la taille de lot (batch size) à 32, l'optimiseur ADAM est utilisé pour optimiser la fonction de perte et le taux d'apprentissage est de 0,0001. Tous les modèles adoptés sont formés par une fonction de perte d'entropie croisée (cross-entropy loss function). Nous avons divisé l'ensemble de données en deux parties, 90% pour le training et 10% pour la validation. Nous avons évalué les 5 modèles proposés en 5 fonctions d'activation : Relu, Selu, Elu, Tanh and Sigmoid :

- **Relu** : Rectified Linear activation est la fonction d'activation la plus couramment utilisée dans les modèles d'apprentissage profond. La fonction renvoie 0 si elle reçoit une entrée négative, si non elle renvoie la valeur elle-même.
- **Elu** : Exponential Linear Unit est une fonction qui a tendance à faire converger le coût vers zéro plus rapidement et à produire des résultats plus précis.
- **Selu** : Scaled Exponential Linear Unit SELU est une sorte d'ELU mais avec une petite touche.
- **Tanh** : hyperbolic tangent Activation Function est aussi comme le sigmoïde logistique. La plage de la fonction Tanh va de (-1 à 1). L'avantage est que les entrées négatives seront mappées fortement négatives et les entrées nulles seront mappées près de zéro dans le graphique.
- **Sigmoid** : est une fonction qui prend une valeur réelle en entrée et génère une autre valeur entre 0 et 1.

2.1 Classification basée sur le CNN

La matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Relu est représentée par la figure 25.




Figure 25 : Matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Relu.

D'après la figure 25, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenu par le modèle CNN avec la fonction d'activation Relu. Dans la figure 26, nous remarquons que la totalité des segments bien classés est 2775 segments, donc un taux de précision de 98.61% et la totalité des segments mal classés est 39, et le taux d'erreur est de 1.39%.




Figure 26 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle CNN avec la fonction d'activation Relu.

La matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Selu est représentée par la figure 27.




Figure 27 : Matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Selu.

D'après la figure 27, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenu par le modèle CNN avec la fonction d'activation Selu. Dans la figure 28, nous remarquons que la totalité des segments bien classés est 2778 segments, donc un taux de précision de 98.72 % et la totalité des segments mal classés est 36 et le taux d'erreur est de 1.28%.




Figure 28 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle CNN avec la fonction d'activation Selu.

La matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Elu est représentée par la figure 29.




Figure 29 : Matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Elu.

D'après la figure 29, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenu par le modèle CNN avec la fonction d'activation Elu. Dans la figure 30, nous remarquons que la totalité des segments bien classés est 2772 segments, donc un taux de précision de 98.50 % et la totalité des segments mal classés est 42, et le taux d'erreur est de 1.50%




Figure 30 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle CNN avec la fonction d'activation Elu.

La matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Tanh est représentée par la figure 31.




Figure 31 : Matrice de confusion obtenue par le modèle CNN avec la fonction d'activation Tanh.

D'après la figure 31, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenu par le modèle CNN avec la fonction d'activation Tanh. Dans la figure 32, nous remarquons que la totalité des segments bien classés est 2760 segments, donc un taux de précision de 98.08 % et la totalité des segments mal classés est 54, et le taux d'erreur est de 1.92%.




Figure 32 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle CNN avec la fonction d'activation Tanh.

2.2 Classification basée sur le VGGNET

La matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Relu est représentée par la figure 33.




Figure 33 : Matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Relu.

D'après la figure 33, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle VGGNET avec la fonction d'activation Relu. Dans la figure 34, nous remarquons que la totalité des segments bien classés est 2764 segments, donc un taux de précision de 98.22 % et la totalité des segments mal classés est 50, et le taux d'erreur est de 1.78%.




Figure 34 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle VGGNET avec la fonction d'activation Relu.

La matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Selu est représentée par la figure 35.




Figure 35 : Matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Selu.

D'après la figure 35, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle VGGNET avec la fonction d'activation Selu. Dans la figure 36, nous remarquons que la totalité des segments bien classés est 2488 segments, donc un taux de précision de 88.41 % et la totalité des segments mal classés est 326, et le taux d'erreur est de 11.59%.




Figure 36 : Nombre total des segments mal et bien classés et le taux d’erreur et de précision obtenus par le modèle VGGNET avec la fonction d’activation Selu.

La matrice de confusion obtenue par le modèle VGGNET avec la fonction d’activation Elu est représentée par la figure 37.




Figure 37 : Matrice de confusion obtenue par le modèle VGGNET avec la fonction d’activation Elu.

D’après la figure 37, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle VGGNET avec la fonction d’activation Elu. Dans la figure 38, nous remarquons que la totalité des segments bien classés est 2652 segments, donc un taux de précision de 94.24% et la totalité des segments mal classés est 162, et le taux d’erreur est de 5.76%.




Figure 38 : Nombre total des segments mal et bien classés et le taux d’erreur et de précision obtenus par le modèle VGGNET avec la fonction d’activation Elu.

La matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Tanh est représentée par la figure 39.




Figure 39 : Matrice de confusion obtenue par le modèle VGGNET avec la fonction d'activation Tanh.

D'après la figure 39, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle VGGNET avec la fonction d'activation Tanh. Dans la figure 40, nous remarquons que la totalité des segments bien classés est 2642 segments, donc un taux de précision de 93.89% et la totalité des segments mal classés est 175, et le taux d'erreur est de 6.21%.




Figure 40 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle VGGNET avec la fonction d'activation Tanh.

2.3 Classification basée sur le ResNet

La matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Relu est représentée par la figure 41.




Figure 41 : Matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Relu.

D'après la figure 41, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle ResNet avec la fonction d'activation Relu. Dans la figure 42, nous remarquons que la totalité des segments bien classés est 2748 segments, donc un taux de précision de 97.65% et la totalité des segments mal classés est 66, et le taux d'erreur est de 2.35%.




Figure 42 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle ResNet avec la fonction d'activation Relu.

La matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Selu est représentée par la figure 43.




Figure 43 : Matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Selu.

D'après la figure 43, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle ResNet avec la fonction d'activation Selu. Dans la figure 44, nous remarquons que la totalité des segments bien classés est 2773 segments, donc un taux de précision de 98.55% et la totalité des segments mal classés est 41, et le taux d'erreur est de 1.45%.




Figure 44 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle ResNet avec la fonction d'activation Selu.

La matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Elu est représentée par la figure 45.




Figure 45 : Matrice de confusion obtenue par le modèle ResNet avec la fonction d'activation Elu.

D'après la figure 45, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle ResNet avec la fonction d'activation Elu. Dans la figure 46, nous remarquons que la totalité des segments bien classés est 2774 segments, donc un taux de précision de 98.57% et la totalité des segments mal classés est 40, et le taux d'erreur est de 1.43%.




Figure 46 : Nombre total des segments mal et bien classés et le taux d’erreur et de précision obtenus par le modèle ResNet avec la fonction d’activation Elu.

La matrice de confusion obtenue par le modèle ResNet avec la fonction d’activation Tanh est représentée par la figure 47.




Figure 47 : Matrice de confusion obtenue par le modèle ResNet avec la fonction d’activation Tanh.

D’après la figure 47, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle ResNet avec la fonction d’activation Tanh. Dans la figure 48, nous remarquons que la totalité des segments bien classés est 2768 segments, donc un taux de précision de 98.37% et la totalité des segments mal classés est 46, et le taux d’erreur est de 1.63%.




Figure 48 : Nombre total des segments mal et bien classés et le taux d’erreur et de précision obtenus par le modèle ResNet avec la fonction d’activation Tanh.

2.4 Classification basée sur le Xception

La matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Relu est représentée par la figure 49.




Figure 49 : Matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Relu.

D'après la figure 49, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle Xception avec la fonction d'activation Relu. Dans la figure 50, nous remarquons que la totalité des segments bien classés est 2775 segments, donc un taux de précision de 98.61% et la totalité des segments mal classés est 39, et le taux d'erreur est de 1.39%.




Figure 50 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle Xception avec la fonction d'activation Relu.

La matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Selu est représentée par la figure 51.




Figure 51 : Matrice de confusion obtenue par le modèle Xception avec la fonction d’activation Selu.

D’après la figure 51, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle Xception avec la fonction d’activation Selu. Dans la figure 52, nous remarquons que la totalité des segments bien classés est 2745 segments, donc un taux de précision de 97.54% et la totalité des segments mal classés est 69, et le taux d’erreur est de 2.46%.




Figure 52 : Nombre total des segments mal et bien classés et le taux d’erreur et de précision obtenus par le modèle Xception avec la fonction d’activation Selu.

La matrice de confusion obtenue par le modèle Xception avec la fonction d’activation Elu est représentée par la figure 53.




Figure 53 : Matrice de confusion obtenue par le modèle Xception avec la fonction d’activation Elu.

D'après la figure 53, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle Xception avec la fonction d'activation Elu. Dans la figure 54, nous remarquons que la totalité des segments bien classés est 2763 segments, donc un taux de précision de 98.18% et la totalité des segments mal classés est 51, et le taux d'erreur est de 1.82%.




Figure 54 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle Xception avec la fonction d'activation Elu.

La matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Tanh est représentée par la figure 55.




Figure 55 : Matrice de confusion obtenue par le modèle Xception avec la fonction d'activation Tanh.

D'après la figure 55, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle Xception avec la fonction d'activation Tanh. Dans la figure 56, nous remarquons que la totalité des segments bien classés est 2681 segments, donc un taux de précision de 95.28% et la totalité des segments mal classés est 133, et le taux d'erreur est de 4.72%.




Figure 56 : Nombre total des segments mal et bien classés et le taux d’erreur et de précision obtenus par le modèle Xception avec la fonction d’activation Tanh.

2.5 Classification basée sur le WaveNet

La matrice de confusion obtenue par le modèle WaveNet avec la fonction d’activation Relu est représentée par la figure 57.




Figure 57 : Matrice de confusion obtenue par le modèle WaveNet avec la fonction d’activation Relu.

D’après la figure 57, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle WaveNet avec la fonction d’activation Relu. Dans la figure 58, nous remarquons que la totalité des segments bien classés est 2688 segments, donc un taux de précision de 95.52% et la totalité des segments mal classés est 126, et le taux d’erreur est de 4.48%.




Figure 58 : Nombre total des segments mal et bien classés et le taux d’erreur et de précision obtenus par le modèle WaveNet avec la fonction d’activation Relu.

La matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Selu est représentée par la figure 59.




Figure 59 : Matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Selu.

D'après la figure 59, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle WaveNet avec la fonction d'activation Selu. Dans la figure 60, nous remarquons que la totalité des segments bien classés est 2708 segments, donc un taux de précision de 96.23% et la totalité des segments mal classés est 106, et le taux d'erreur est de 3.77%.




Figure 60 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle WaveNet avec la fonction d'activation Selu.

La matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Elu est représentée par la figure 61.




Figure 61 : Matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Elu.

D'après la figure 61, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle WaveNet avec la fonction d'activation Elu. Dans la figure 62, nous remarquons que la totalité des segments bien classés est 2735 segments, donc un taux de précision de 97.19% et la totalité des segments mal classés est 69, et le taux d'erreur est de 2.81%.




Figure 62 : Nombre total des segments mal et bien classés et le taux d'erreur et de précision obtenus par le modèle WaveNet avec la fonction d'activation Elu.

La matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Tanh est représentée par la figure 63.




Figure 63 : Matrice de confusion obtenue par le modèle WaveNet avec la fonction d'activation Tanh.

D'après la figure 63, on peut extraire le nombre total des segments bien classés et le nombre total des segments mal classés obtenus par le modèle WaveNet avec la fonction d'activation Tanh. Dans la figure 64, nous remarquons que la totalité des segments bien classés est 2703 segments, donc un taux de précision de 96.06% et la totalité des segments mal classés est 111, et le taux d'erreur est de 3.94%.





Figure 64 : Nombre total des segments mal et bien classés et le taux d’erreur et de précision obtenus par le modèle WaveNet avec la fonction d’activation Tanh.


3 Etude comparative de la méthode proposée

Les résultats de formation des modèles proposés ont été présentés sous forme de tracés dans les figures 65, 66, 67, et 68.


On remarque que la précision de formation et de validation augmente avec l’augmentation de nombre des époques. Si la valeur de la précision est faible, on aura besoin d’entraîner notre modèle et par conséquent on doit augmenter le nombre des époques.




(a)




(b)



(c)




(d)



(e)


Figure 65 : Tracés de précision et de perte sur les ensembles de formation et de validation pour les modèles (a) CNN, (b) VGGNET, (c) ResNet, (d) Xception et (e) WaveNet en utilisant la fonction d'activation Relu.




(a)




(b)



(c)



(d)




(e)


Figure 66 : Tracés de précision et de perte sur les ensembles de formation et de validation pour les modèles (a) CNN, (b) VGGNET, (c) ResNet, (d) Xception et (e) WaveNet en utilisant la fonction d'activation Selu.




(a)




(b)



(c)



(d)



(e)

Figure 67 : Tracés de précision et de perte sur les ensembles de formation et de validation pour les modèles (a) CNN, (b) VGGNET, (c) ResNet, (d) Xception et (e) WaveNet en utilisant la fonction d'activation Elu.

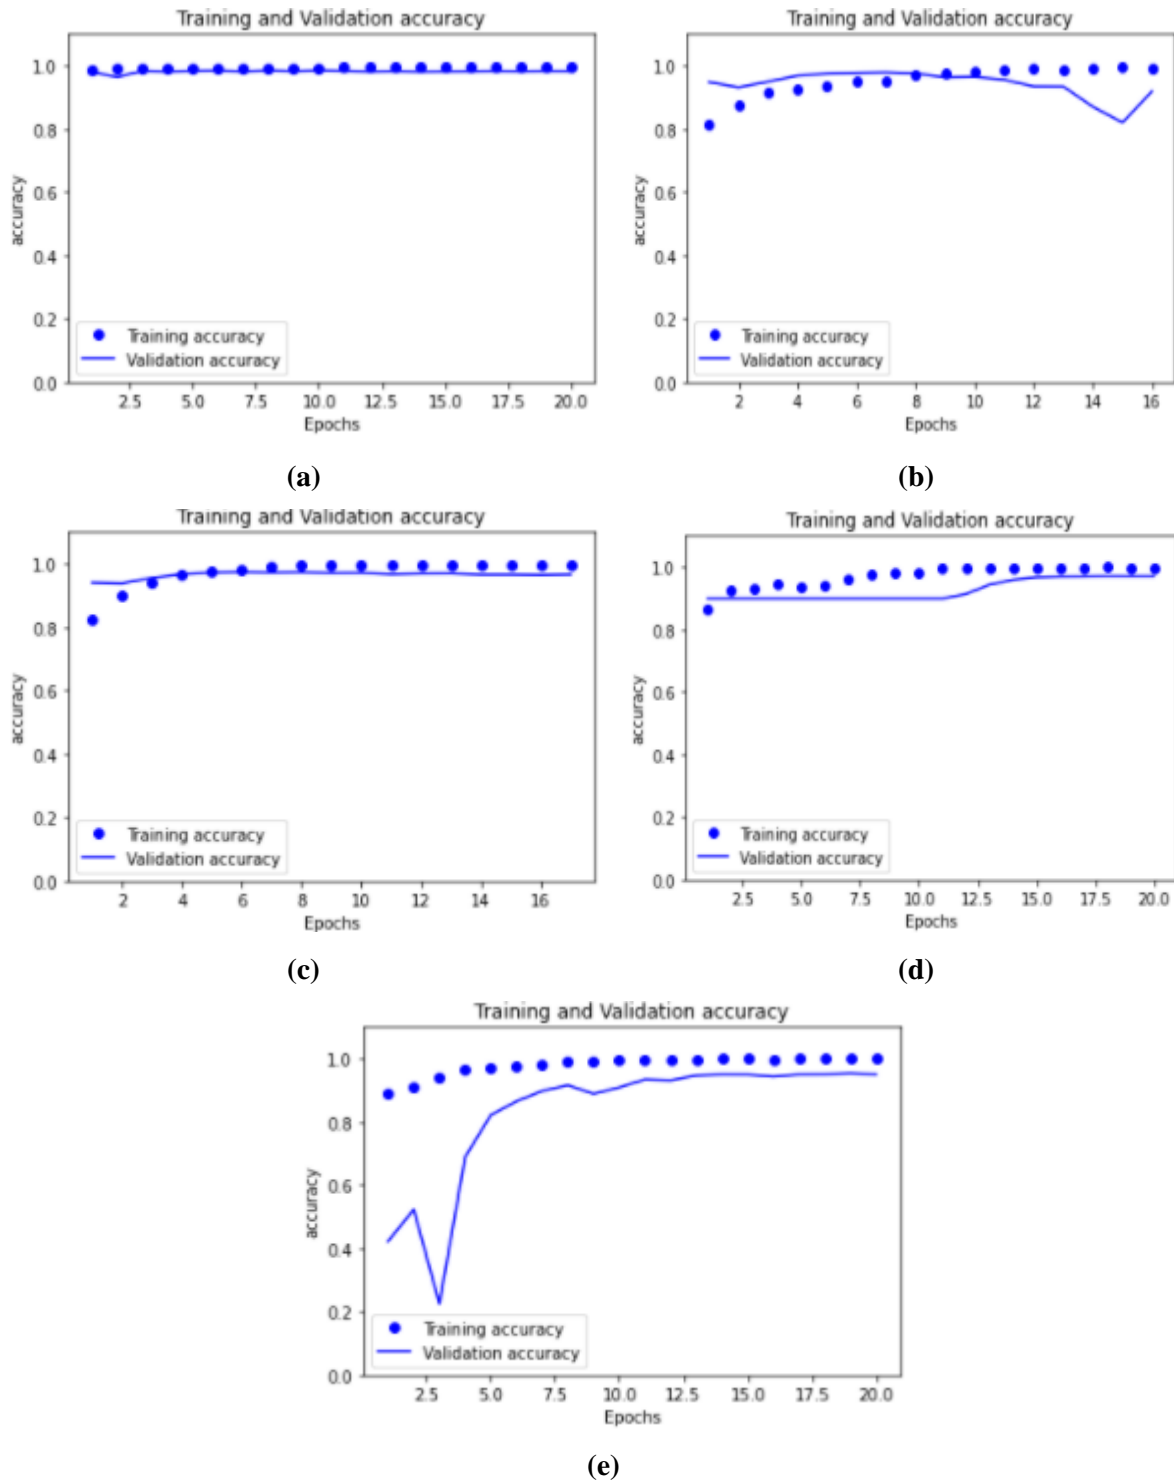


Figure 68 : Tracés de précision et de perte sur les ensembles de formation et de validation pour les modèles (a) CNN, (b) VGGNET, (c) ResNet, (d) Xception et (e) WaveNet en utilisant la fonction d'activation Tanh.

La figure 69, présente une comparaison de précision et de perte sur les ensembles de formation et de validation entre les modèles CNN, VGGNET, ResNet, Xception et WaveNet en utilisant les fonctions d'activation Relu, Selu, Elu, et Tanh.

Les résultats obtenus montrent que la précision de formation est jusqu'à 99% et la perte de formation va aussi basse que 0,1 comme le souligne chaque figure ce qui pourrait être considéré comme un bon signe pour obtenir un bon résultat de classification.

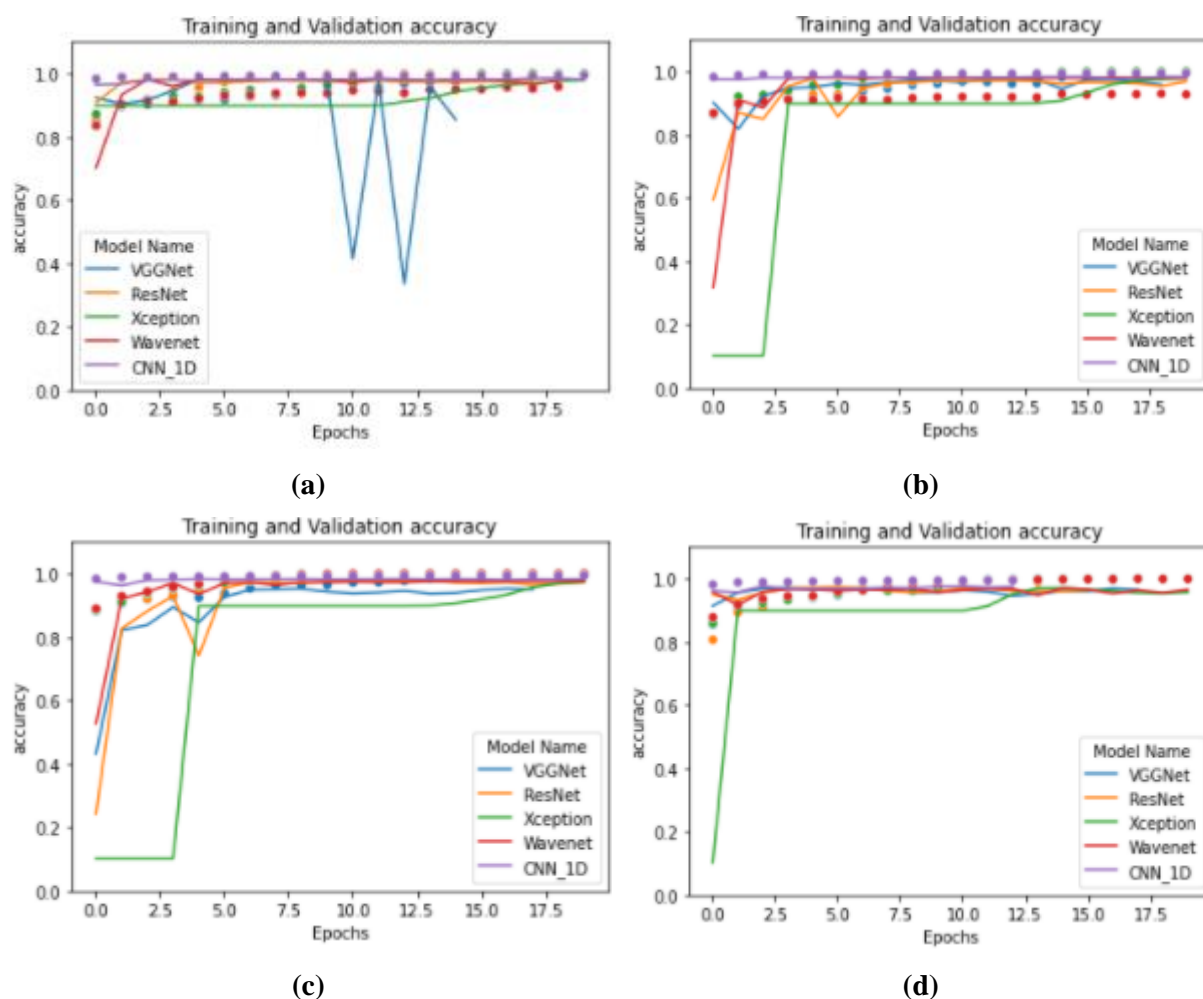


Figure 69 : comparaison de précision et de perte sur les ensembles de formation et de validation entre les modèles CNN, VGGNET, ResNet, Xception et WaveNet en utilisant les fonctions d'activation (a) Relu, (b) Selu, (c) Elu, et (d) Tanh.

Le tableau 5 montre la valeur de précision des modèles CNN, VGGNET, ResNet, WaveNet et Xception avec les quatre fonctions d'activations : Relu, Selu, Elu et Tanh. On peut noter qu'avec la fonction d'activation Relu, les modèles VGGNET et Xception atteignent leur valeur maximale, tandis que WaveNet et ResNet sont données la valeur la plus élevée avec Elu et CNN avec Selu. Les valeurs les plus élevées sont 98.72%, 98,22%, 98,57%, 98,61% et 97,19% obtenues respectivement par CNN, VGGNET, ResNet, Xception et WaveNet. Nous pouvons alors conclure que le CNN a donné la meilleure valeur de précision.

Tableau 5 : Valeurs de précision des modèles CNN, VGGNET, ResNet, WaveNet et Xception.

	CNN	VGGNET	ResNet	WaveNet	Xception
Relu	98.61%	98.22%	97.65%	98.61%	95.52%
Selu	98.72%	88.41%	98.54%	97.54%	96.23%
Elu	98.50%	94.24%	98.57%	98.18%	97.19%
Tanh	98.08%	93.89%	98.37%	95.28%	96.06%

4 Discussion

Les personnes atteintes d'épilepsie non traitées souffrent des convulsions incertitude, le diagnostic était une pénurie dans les régions éloignées en raison des services médicaux limités [45]. Pour un examen précis de patients atteints d'épilepsie, nous prévoyons de construire un système automatique d'identification de crise afin de diriger les médecins dans leur diagnostic.

L'apprentissage en profondeur ouvre la nouvelle porte au diagnostic intelligent dans le domaine médical et soins de santé, en particulier dans le traitement de signal EEG. Les 5 modèles que nous avons utilisés, ont donné des résultats très prometteurs, avec une précision d'environ 99% pour chacun. Le tableau 6 résume les résultats de détection automatique des crises d'épilepsie et les compare aux modèles utilisés. Cela indique clairement que les modèles utilisés surpassent les autres modèles de l'état de l'art en termes de valeur de précision. Nous n'avons pas plus de données pour les cinq autres critères de performance. Cela fera l'objet de travaux futurs. Dans les références indiquées dans le tableau 6, les auteurs ont implémenté une nouvelle approche pour diagnostiquer automatiquement les crises en utilisant des méthodes d'apprentissage basées sur DL.

Dans [46], les auteurs ont montré que la combinaison de transformation continue en ondelettes (CWT) et le modèle CNN a de hautes performances en reconnaissance d'image et détection de modèle. Cette méthode réalise un taux de précision global d'environ 72,49%. Par conséquent, ces modèles peuvent offrir des alternatives prometteuses pour les diagnostics des cliniciens.

Dans [47], les auteurs proposent le modèle surperformé CNN 3D multicanal pour identifier et classer cette anomalie. Ce modèle est capable d'effectuer des tâches avec une précision de 92,38%.

Les 5 modèles utilisés sont moins exigeants en termes d'effort de calcul que d'autres modèles pré-entraînés et ont produits des résultats prometteurs. Vu que les données d'entraînement sont disponibles, les performances peuvent être encore améliorées. Malgré ces résultats prometteurs, les modèles utilisés nécessitent encore des essais et des études, mais avec les plus grandes valeurs de précision dans l'identification des crises, ils peuvent aider les neurologues et les experts de santé d'interviennent afin d'anticiper cette anomalie.

Tableau 6 : Comparaison entre les méthodes de détection automatique de crise le plus couramment utilisé basé sur le DL.

Référence	Modèle utilisé	Accuracy
[46]	CWT+CNN	72.49%
[47]	3D-CNN model + multi-channel	92.38%
Les modèles utilisés	CNN_1D	98.72%
	VGG-19	98.22%
	ResNet	98,57%
	Xception	98,61%
	WaveNet	97,19%

5 Conclusion

Nous avons présenté dans ce chapitre la démarche de la réalisation de notre solution proposée pour la détection automatique des crises épileptiques qui est présentée sous la forme d'un système automatique basé sur les méthodes d'apprentissage profond. Nous avons utilisé cinq modèles CNN, VGGNET, ResNet WaveNet et Xception.

Les résultats obtenus montrent que le nombre d'époques, la taille de la base, la profondeur de réseaux, et les fonctions d'activation utilisées, sont des facteurs importants pour l'obtention de meilleurs résultats.

Ces résultats peuvent être aussi développé dans les futurs travaux tout en améliorant les techniques de filtrage, pour mieux détecter les crises épileptiques.

Conclusion Générale

Ce travail de recherche a été élaborée dans le cadre de la détection des crises épileptiques à l'aide de méthodes d'apprentissage profond. Généralement, l'activité cérébrale électrique est devenue un domaine de recherche scientifique très demandé permettant d'explorer des pathologies essentielles du cerveau humain. En effet une lecture / interprétation très claire de ces potentiels électriques permet de bien diagnostiquer ces pathologies et en conséquence, de bien réfléchir aux compromis de remèdes. L'analyse de ces enregistrements est une étape indispensable dans le diagnostic de l'épilepsie. Il permet de spécifier un traitement adapté pour chaque patient afin d'éviter les complications liées à cette anomalie.

Nous avons commencé ce manuscrit par présenter quelques notions de base de la physiologie tout en allant vers l'électrophysiologie du cerveau. Quelques généralités sur le système nerveux seront nécessaires pour comprendre l'origine de l'activité électrique cérébrale. Puis, nous allons décrire les principaux outils existants pour le diagnostic du cerveau seront évoqués, à savoir l'Electroencéphalographie 'EEG', et la Magnétoencéphalographie 'MEG'. Ensuite, nous allons monter brièvement les principales pathologies neurologiques et se focaliser essentiellement sur l'épilepsie. Par la suite, nous avons illustré les approches et les principaux travaux existants dans le domaine de reconnaissance des événements dans les images.

Ensuite, nous avons présenté notre démarche pour la problématique posée. Pour ce faire nous avons proposé cinq modèles avec différentes architectures contenant les paramètres : le nombre des couches, la taille de la base, la profondeur de réseaux, et les fonctions d'activation utilisées et le nombre d'époques.

Les résultats obtenus ont montré que les modèles utilisés sont efficaces pour la détection des crises épileptiques en obtenant un bon taux de précision. Afin de montrer la faisabilité de notre démarche, nous avons comparé les résultats obtenus par notre système avec d'autres approches de l'état de l'art. D'après les évaluations menées dans cette mémoire, nous avons illustré que le modèle CNN atteint de bons résultats et assure une précision presque de 99%.

Ces résultats sont intéressants et ouvrent une nouvelle voie de recherche concernant la détection automatique des crises épileptiques. À l'avenir, le prétraitement peut être encore amélioré pour augmenter le rapport signal sur bruit. En cas d'utilisation de méthodes d'apprentissage profond pour l'extraction et / ou la classification de caractéristiques, un grand nombre de paramètres doivent être appris. Par conséquent, des recherches futures peuvent également être effectuées pour réduire le nombre de paramètres. D'autres recherches supplémentaires seront nécessaires pour les méthodes de prédiction des crises d'épilepsie non spécifiques aux patients.

Références

1. OMS. Epilepsie. *Épidémiologie*.34,276-285,2001.
2. Mormann, F; Andrzejak, R; E Elger, C; Lehnertz, K. Seizure prediction: The long and winding road. *Brain*.130, 314–333G, 2007.
3. Gotman, J.A few thoughts on – what is a seizure? *Epilepsy Behav.* 22, S2–S3, 2011.
4. BYaffe, R; al. Physiology of functional and effective networks in epilepsy. *Clin Neurophysiol*.126, 227–236, 2015.
5. Zandi, A; Javidan, M; A Dumont, G; Tafreshi, R. Automated Realtime epileptic seizure detection in scalp EEG recordings using an algorithm based on wavelet packet transform. *IEEE Trans Biomed Eng.* 57,1639–1651, 2010
6. Arme-Sophie, D, Jean-Marc, L. détection de pointes épileptiques à partir de signaux EEG.2010
7. Jacques, B. neuropédagogie : cerveau, intelligences et apprentissage.2015
8. Anthea, M; Jean, H; Charles, W M; Susan, J; Maryanna, Q W; David, L; Jill, D. Wright, Human Biology and Health, Système nerveux périphérique.2018
9. Romo-Vazquez, R. Contribution à la détection et à l'analyse des signaux EEG épileptiques : de bruitage et séparation de sources.2010.
10. Pascal, G. Non-invasive imaging tests for detecting coronary artery disease in symptomatic stable patients. Is diagnostic performance sufficient for guiding strategy.199 341-354, 2015
11. Pérez-Martin, A ; Iris, S ; Michel, D. Travaux Pratiques de Physiologie.2006
12. Trigui, O. Méthode de gestion énergétique d'un véhicule électrique basée sur l'estimation en ligne de la masse et de coefficient de résistance au roulement. 2017
13. Jean, D. Les ondes cérébrales et la psychologie. 2020
14. Vion-Dury ; Blanquet. Pratique de l'EEG. Elsevier Masson. 2008.
15. Brazier, B. The Electrical Activity of the Nervous System.1970.
16. Kohelet, D; Shochat, R; Lusky, A; Reichman, B. Risk factors for neonatal seizures in very low birthweight infants: population-based survey. *Child Neurol*, 19, 123-8,2004.
17. Jean-Baptiste Poline, M. Le rôle de la neuro informatique dans l'émergence de la science reproductible.2005.

18. Haddad, M. Anticipation des crises d'épilepsie temporelle combinant des méthodes statistiques et non-linéaires d'analyse d'électroencéphalographie.2014.
19. Thomas, D ; Berner Klinik, M. Diagnostic et traitement des épilepsies January 2009
20. Janszky, J; Pannek, W; H, I. Janszky, Schulz, F; Behne, F; Hoppe, A; Ebner, A. Failed surgery for temporal lobe epilepsy: Predictors of long-term seizure-free course. *Epilepsy Research*, 64 :35–44, 2005.
21. Alvarez, V ; Beucler, M ; Borges, H ; Tapparel, L. sondage sur l'épilepsie. 2004.
22. Adam, C ; Arzimanoglou, M ; Baulac, A ; Bendriem, B ; Biraben, A et al. Epilepsies : de la clinique aux examens complémentaires .2000
23. Faust, O; Acharya, U. R, Adeli, H.; Adeli, A. Wavelet-based EEG processing for computer-aided seizure detection and epilepsy diagnosis *Seizure*, 26, 56-64,2015
24. Hocepiéd, G; Kacha, A; Grenez, F; Nonclercq, A. Stability analysis of epileptic EEG signals.2008.
25. Janszky, J; Pannek, H.W; Janszky, I; Schulz, R; Behne, F; Hoppe, M; Ebner, A. Failed surgery for temporal lobe epilepsy: Predictors of long-term seizure-free course. *Epilepsy Research*, 64 :35–44, 2005.
26. Xiaoyan, W; Lin, Z; Ziyi, C; Liangjun, Z; Yi, Z; Guangzhou, Ch. Automatic seizure detection using three dimensional CNN based on multi-channel EEG. 2018.
27. Poomipat, B; Lek-uthai, A; Krisnachai, Ch; Jitkomut, S. A Comparison of Deep Neural Networks for Seizure Detection in EEG Signals.2019.
28. Devroye, L; Györfi, L; Lugosi, G. A Probabilistic Theory of Pattern Recognition. 2013.
29. Rahib, A; Murat, A; John Bush, I; Boran, S; Ahmet, I. Identification of Epileptic EEG Signals Using Convolutional Neural Networks. 2020.
30. Bouaziz, B; Chaari, L; Batatia, H; Quintero, R. Antonio Epileptic Seizure Detection Using a Convolutional Neural Network,79-86.2019.
31. Yan, T; Zhao, S; Uono, S; Bi, X; Tian, A; Yoshimura, S et al. Target object moderation of attentional orienting by gazes or arrows. *Attent. Percep.*2016
32. Ilakiyaselvan¹, N; Nayeemulla, A; Khan, A. Shahina, D. Deep learning approach to detect seizure using reconstructed phase space images.2020.

33. Lang, Z ; XiaoFeng, Liu ; Aimin, J ; Xu, Zh. Epileptic Seizure Detection Using Deep Convolutional Network.2017.
34. CHIEN-LIANG, L; BIN, X; WEN-HOAR, H; VINCEN, T. Epileptic Seizure Prediction with Multi-View Convolutional Neural Networks.2019.
35. Parvez, MZ; Paul, M. Epileptic seizure detection by exploiting temporal correlation of electroencephalogram signals. IET Signal Processing 9(6):467–475, 2015
36. Thodoroff, P; Pineau, J; Lim, A. Learning robust features using deep learning for automatic seizure detection, Proceedings of the 1st Machine Learning for Healthcare Conference. PMLR 56:178–190, 2016.
37. Canolty, RT; Edwards, E; Dalal, SS; Soltani, M; Nagarajan, SS; Kirsch, HE; Berger, MS; Barbaro, NM; Knight, RT. High gamma power is phase-locked to theta oscillations in human neocortex. Science 313:1626–1628, 2006.
38. O'SHEA, K; NASH, R. An introduction to convolutional neural networks. 2015
39. WANG, P; XU, J; XU, B; LIU, Ch; ZHANG, H; WANG, F; HAO, H. Semantic clustering and convolutional neural networks for short text categorization. 2015
40. OULMI, M ; KALOUNE, S. Classification d'objets avec le Deep Learning.2017.
41. Sze, V; Chen, YH; Yang, TJ. Efficient processing of deep neural networks: a tutorial and survey. 105, 2295– 2329.2017.
42. Francois, Ch. Xception: Deep Learning with Depth wise Separable Convolutions.2017.
43. Shoeb, A. Application of Machine Learning to Epileptic Seizure Onset Detection and Treatment. 2009.
44. Cun, Y; Boser, B; Denker, J; Henderson, D. Handwritten digit recognition with a back-propagation network, neural information, 12,061-068,1990.
45. Chollet, M. understanding-AlexNet. learn, 22,131-142,2019.
46. Simonyan, K; Andrew, Z. Very deep convolutional networks for large-scale image recognition. 56-65, 2015.
47. Mao, W; Fathurrahman, K. EEG dataset classification using CNN method. 225–239,2017.

Application de l'approche Deep Learning sur des segments EEG pour une détection automatique des crises d'épilepsie

Dhouha SAGGA

Résumé : L'épilepsie est une affection neurologique chronique caractérisée par une explosion électrique excessive et incontrôlée dans le cerveau. Cette anomalie touche environ 50 millions de personnes de tous âges, selon l'organisation mondiale de la santé. La surveillance électroencéphalographique multicanale (EEG) de l'activité cérébrale est une méthode de référence dédiée à l'étude des crises d'épilepsie et à l'enregistrement des modifications de l'activité électrique cérébrale. Les analyses actuelles développées par des experts de l'industrie se concentrent principalement sur des fonctionnalités restreintes qui sont inflexibles et prennent du temps pour détecter une variété de modèles dans une grande quantité de données EEG. Par conséquent, afin d'initier un traitement médicamenteux antiépileptique et de réduire en fin de compte le risque et la complication des crises, un diagnostic rapide et précis doit être créé. Ce travail vise à appliquer des méthodes d'apprentissage pour la détection automatique des crises épileptiques à l'aide de signaux EEG afin de faciliter le diagnostic pour les neurologues. Les résultats expérimentaux montrent que les modèles utilisés ont atteint une précision de 98,72%, 98,61%, 98,57%, 97,19%, et 98,22% respectivement pour CNN, Xception, ResNet, WaveNet, et VGGNet.

Mot-clé : épilepsie, électroencéphalographie, crises, apprentissage profond.

Abstract: Epilepsy is a chronic neurological condition characterized by an excessive and uncontrolled electrical explosion in the brain. This anomaly affects around 50 million people of all ages, according to the World Health Organization. Multichannel electroencephalographic (EEG) monitoring of brain activity is a reference method dedicated to the study of epileptic seizures and record changes in brain electrical activity. Current analyzes developed by industry experts mainly focus on restricted functionality that is inflexible and time-consuming to detect a variety of patterns in a large amount of EEG data. Therefore, in order to initiate antiepileptic drug therapy and ultimately reduce the risk and complication of seizures, a rapid and accurate diagnosis must be created. This work aims to apply learning methods to the automatic detection of epileptic seizures using EEG signals in order to facilitate diagnosis for neurologists. The experimental results show that the models used achieved an accuracy of 98.72%, 98.61%, 98.57%, 97.19%, and 98.22% respectively for CNN, Xception, ResNet, WaveNet, and VGGNet.

Keyword: epilepsy, electroencephalography, seizures, Deep Learning.