

MÉMOIRE

présenté à

L'Institut Supérieur des Gestion de Gabès

en vue de l'obtention du diplôme de

**Mastère de recherche en
Informatique Décisionnelle et de Gestion**

par

Sana BELGACEM

**Classification multi-classes des signaux EEG
d'imagination motrice à l'aide des méthodes
d'apprentissage profond**

Soutenu le .././.... devant la commission d'examen :

M. Mohamed GHORBEL

.....

M. Rafik KHEMAKHEM

Mlle. Amira ECHTIOUI

Président

Rapporteur

Encadrant

Co-encadrante

Année Universitaire : 2020 / 2021

Ne perds jamais espoir.

Lorsque le soleil se couche, les étoiles apparaissent.

(Auteur anonyme)

Dédicace

Je dédie ce mémoire à mes parents qui ont toujours été là pour moi,

À mon tendre époux et mon compagne fidèle,

À mes petits enfants qui rend ma vie plus heureuse et intéressante,

À mon frère et mes sœurs à qui je souhaite un avenir très brillant,

À toute ma famille et la famille de mon mari,

À vous cher lecteur,

À moi-même,

Remerciements

Tout d'abord, je rends grâce à **Dieu** qui m'avait donné la santé, l'aide, la volonté, la patience et le courage pour accomplir ce travail.

Je tiens à remercier sincèrement **M. Mohamed GHORBEL**, Maître de conférences à l'ENET'COM-Sfax, pour m'avoir fait l'honneur de présider mon jury de ce mémoire.

Je tiens à formuler ma profonde gratitude à **M. Rafik KHEMAKHEM**, maitre-assistant et chef de département de l'informatique à l'ISG-Gabès, qui a guidé mes premiers pas dans le monde de la recherche. Merci Monsieur d'avoir accepté de diriger mon mémoire de mastère et pour vos conseils avisés et vos encouragements tout au long de ce travail.

Un grand merci à **Mlle. Amira ECHTIOUI**, enseignante à l'ISIMS-Sfax pour le temps qu'elle a consacré à m'épauler ainsi que ses conseils, son partage des savoirs. Que vous me permet de vous témoigner ma reconnaissance et mon respect le plus sincère.

Enfin, je suis très reconnaissante envers tous les membres de ma famille et en particulier mes parents Houcine et Moufida et mon mari Rchid pour leur inspiration et leur soutien moral toujours encourageant, qui me permettent de poursuivre mes études.

Merci à mon frère Bourhene et mes sœurs Sondes et Ons pour tant d'amour et de solidarité.

Mes plus grands remerciements reviennent à mes petits Mohamed Racel, Iline et Haroun, être votre maman c'est mon grand honneur.

Je remercie infiniment la famille de mon mari pour la compréhension et l'encouragement.

Table des matières

Introduction générale.....	1
Chapitre 1 : Généralités sur les Interfaces Cerveau Machine	2
1.1. Introduction	2
1.2. Principes de base du fonctionnement d'une ICM	2
1.2.1. Définition d'une ICM	2
1.2.2. Structure générale d'une ICM	3
1.2.3. Terminologie sur les différents types d'ICM	4
1.2.3.1. ICM invasive / ICM non invasive.....	4
1.2.3.2. ICM endogène / ICM exogène.....	5
1.2.3.3. Protocoles synchrones / Protocoles asynchrones	5
1.3. Quelques notions de neurophysiologie	6
1.4. Les techniques d'acquisition des activités cérébrales	8
1.4.1. Techniques non-invasives.....	8
1.4.1.1. Imagerie par résonance magnétique fonctionnelle (IRMf)	9
1.4.1.2. La magnétoencéphalographie MEG	9
1.4.1.3. L'électroencéphalographie EEG	10
1.4.1.4. L'électro-oculographie EOG	12
1.4.1.5. Spectroscopie proche infrarouge SPIR	13
1.4.2. Techniques invasives.....	13
1.4.3. Comparaison entre les différentes techniques d'enregistrement	14
1.5. Phénomènes neurophysiologiques utiles pour les ICM	15
1.5.1. Potentiel cortical lent.....	15
1.5.2. Potentiel évoqué P300	16
1.5.3. Potentiel évoqué visuel.....	16
1.5.4. L'imagination motrice	16
1.5.5. Comparaison entre les phénomènes neurophysiologiques utilisés en ICM	17

1.6. Conclusion.....	18
Chapitre 2 : Classification des mouvements d'imagination motrice en se basant sur l'apprentissage profond	19
2.1. Introduction	19
2.2. Etat de l'art.....	19
2.3. Contexte théorique	21
2.3.1. L'intelligence artificielle	22
2.3.2. L'apprentissage automatique	22
2.3.3. L'apprentissage profond.....	23
2.4. Architectures des méthodes proposées.....	24
2.4.1. Prétraitement des signaux EEG	24
2.4.2. Réseaux de neurones convolutifs (CNN)	25
2.4.3. Réseau neuronal récurrent (RNN)	30
2.5. Conclusion.....	35
Chapitre 3 : Évaluation des méthodes proposées pour la classification des mouvements d'imagination motrice.....	36
3.1. Introduction	36
3.2. Présentation des bases de données	36
3.4. Logiciels et outils	37
3.4.1. Colaboratoire Google (Colab)	37
3.4.2. Python.....	39
3.5. Métrique d'évaluation	39
3.6. Etape d'apprentissage.....	41
3.6.1. Optimiseur	41
3.6.2. Fonction de perte	41
3.7. Résultats expérimentaux	42
3.7.1. Classification basée sur le modèle CNN proposé.....	42
3.7.2. Classification basée sur le modèle RNN proposé.....	42

3.7.3. Classification basée sur le modèle LSTM bidirectionnel proposé	43
3.7.4. Étude comparative entre les trois modèles proposés	44
3.8. Discussion	46
3.9. Conclusion.....	48
Conclusion Générale	49

Liste des figures

Figure 1 : Architecture d'une Interface Cerveau-Machine.	3
Figure 2 : Les quatre lobes de l'hémisphère gauche.	7
Figure 3 : Organisation somatotopique du cortex moteur primaire.	8
Figure 4 : Machine IRMf [8].	9
Figure 5 : Appareil du MEG [8].	10
Figure 6 : Présentation d'un enregistrement EEG : (a) casque EEG, (b) Tracé EEG.	10
Figure 7 : Présentation de différentes bandes fréquentielles du signal EEG.	11
Figure 8 : Une représentation du système international 10-20. A : vue horizontale dorsale de la tête, B : vue latérale gauche de la tête.	12
Figure 9 : L'électro-oculographie. A : Emplacement des électrodes EOG. B : Les mouvements oculaires saccadés, la fixation, et les clignements [30].	13
Figure 10 : Une présentation de l'implantation des électrodes avec l'ECOG	14
Figure 11 : Tracés de la variation SCPS pour un patient paralysé.	15
Figure 12 : Potentiel évoqué P300.	16
Figure 13 : Effet de l'imagination motrice de la main gauche et de la main droite sur les signaux EEG.	17
Figure 14 : L'intelligence artificielle et ses sous-ensembles, image d'après [46]	22
Figure 15 : Réseaux de neurones artificiels (ANN)	24
Figure 16 : Exemple de couche convolutive.	25
Figure 17 : Processus de pooling.	26
Figure 18 : Présentation d'un exemple de la mise à plat.	27
Figure 19 : Présentation d'un exemple des couches entièrement connectées.	27
Figure 20 : Architecture du CNN proposée	28
Figure 21 : Présentation de l'architecture du RNN	30
Figure 22 : Présentation de la structure générale d'une cellule LSTM.	31
Figure 23 : Architecture du modèle RNN proposée.	33
Figure 24 : Architecture du modèle LSTM bidirectionnel proposée	34
Figure 25 : a) Montage de 22 électrodes EEG. b) Montage des trois électrodes EOG [5].	36
Figure 26 : Schéma temporel du paradigme, image d'après [47]	37
Figure 27 : (a) Logo collaboratoire google, (b) Logo Jupyter	38
Figure 28 : Logo Python	39
Figure 29 : Logo Keras	39

Figure 30 : La définition de la matrice de confusion	40
Figure 31 : Les valeurs de précision obtenues par l'application de trois modèles proposés avec l'utilisation de l'optimiseur Adam.	44
Figure 32 : Les valeurs de précision obtenues par l'application de trois modèles proposés avec l'utilisation de l'optimiseur RMSprop.	45

Liste des tableaux

Tableau 1 : Comparaison entre les différentes méthodes d'enregistrement utilisées pour les ICMs.....	14
Tableau 2 : Comparaison entre les différents phénomènes neurophysiologiques utilisés en ICM	18
Tableau 3 : Spécifications des différents environnements d'exécution proposés par Colaboratoire google	38
Tableau 4 : La précision (en %) de la classification obtenue par l'application du modèle CNN proposé en utilisant deux optimiseurs différents.....	42
Tableau 5 : La précision (en %) de la classification obtenue par l'application du modèle RNN proposé en utilisant deux optimiseurs différents.....	43
Tableau 6 : La précision (en %) de la classification obtenue par l'application du modèle LSTM bidirectionnel proposé en utilisant deux optimiseurs différents.	43
Tableau 7 : Tableau comparative entre la méthode proposée et quelques méthodes	46

Liste des abréviations

Adam : Adaptive Moment Estimation

ANN: Artificial Neural Network

BN: Batch Normalisation

BOLD: Blood Oxygen Level-Dependent

CCNN: Compact Convolutional Neural Network

CNN: Convolutional Neural Network

CWT: Continuous Wavelet Transform

DCNN: Deep Convolutional Neural Network

DL: Deep Learning

ECG: Électrocardiogramme

ECoG: Électrocorticographie

EEG : Électroencéphalographie

EMG: Électromyographie

EOG : Électrooculographie

FBCSP: Filtre Bank Common Spatial Patterns

FN: False Negative

FP: False Positive

IA : Intelligence Artificielle

ICM: Interface Cerveau Machine

IND: Intra-cortical Neuronal Download

IRMf: Imagerie par Résonance Magnétique fonctionnelle

LIS: Locked-In Syndrom

LSTM: Long Short-Term Memory network

MEG: Magnétoencéphalographie

MI: Motor Imagery

ML: Machine Learning

PCCRNN : Parallel Compact Convolutional Recurrent Neural Network

PCL : Potentiel Cortical Lent

PEV : Potentiels Evoqués Visuels

PSCRNN: Parallel Shallow Convolutional Recurrent Neural Network

RGB: Red, Green, Blue

RNN: Recurrent Neural Network

SAE: Stacked Auto-Encoder

SCCRNN: Series Compact Convolutional Recurrent Neural Network

SCNN: Shallow Convolutional Neural Network

SCP : Slow cortical potential

SLA : Sclérose Latérale Amyotrophique

SNC : Système Nerveux Central

SNP : Système Nerveux Périphérique

SPIR : Spectroscopie Proche InfraRouge

SQUID: Superconducting Quantum Interference Device

SSCRNN: Series Shallow Convolutional Recurrent Neural Network

SVM: Support Vector Machine

TN: True Negative

TP : True Positive

Introduction générale

La technologie d'Interfaces Cerveau-Machine (ICM), en anglais Brain-Computer Interface (BCI) est une voie de communication directe entre un individu et une machine grâce à son activité cérébrale. Celle-ci était enregistrée, analysée et traduite en commande envoyée au système pour accomplir la tâche prévue [1].

En 1973, Vidal faisait des recherches sur la « communication directe cerveau-ordinateur » (Vidal, 1973) et la « détection en temps réel des événements cérébraux dans l'EEG » (Vidal, 1977) [2]. Mais, l'idée de déchiffrer avec succès des pensées ou des intentions au moyen de l'activité cérébrale a souvent été rejetée dans le passé comme étant très étrange et complexe [3].

Au cours des trois dernières décennies, ce contexte a subi des changements radicaux. En effet, la recherche sur l'ICM est maintenant un domaine florissant et en croissance rapide pour les personnes handicapées et en bonne santé [4]. Malgré les développements technologiques, l'ICM a encore de nombreux défis à relever pour faciliter davantage son utilisation dans la vie quotidienne, parmi eux on trouve une faible précision, la rapidité (périodes d'entraînement prolongées) et l'efficacité (bruits non stationnaires) [4].

Ce mémoire est organisé en 3 chapitres :

Dans un premier chapitre, nous présenterons une généralité sur les ICMs, ses principales méthodes d'acquisition particulièrement l'Electroencéphalographie (EEG), et la technique la plus appropriée.

Dans le deuxième chapitre, une étude bibliographique sera présentée pour jeter un coup d'œil sur les méthodes qui ont opté pour la classification des mouvements d'imagination motrice dans la littérature. Ainsi une description de la méthodologie proposée dans le but d'effectuer la tâche de classification, a été réalisée.

Le troisième chapitre concerne l'expérimentation. Nous allons décrire la base de données utilisée et la métrique d'évaluation de la classification. Ensuite, nous présenterons les expériences réalisées et les résultats obtenus avec leurs interprétations et une étude comparative entre les méthodes utilisées sera établie.

Enfin, Nous clôturons cette mémoire par une conclusion générale et quelques perspectives d'amélioration.

Chapitre 1 :

Généralités sur les Interfaces Cerveau Machine

1.1. Introduction

Le but de ce chapitre est de donner une vision d'ensemble du domaine des Interfaces Cerveau-Machine (ICM). Pour cela nous allons décrire dans la première partie le principe de base de fonctionnement d'une ICM. La seconde partie met en évidence les notions des neurophysiologies a pour but de connaître la source des activités cérébrales. La troisième partie montre les principales technologies utilisées pour quantifier ces activités. La quatrième section s'intéresse au phénomène neurophysiologie les plus utilisées dans la création des ICMs.

1.2. Principes de base du fonctionnement d'une ICM

1.2.1. Définition d'une ICM

Une Interface Cerveau-Machine (ICM : en anglais BCI, Brain Computer Interface), est un mécanisme qui permet d'établir une communication directe en temps réel entre le cerveau d'un utilisateur et un système électronique externe (ordinateur, chaise roulante) sans utiliser les voies naturelles nerveuses (la moelle épinière et les nerfs) et musculaires [5, 6].

Ce mécanisme met en œuvre les échanges des informations et des commandes dont ils sont envoyés exclusivement par l'activité cérébrale (l'échange du courant électrique entre les neurones du cerveau) qui permet de contrôler les machines. Ainsi, l'utilisateur peut rester inactif et totalement statique et ses intentions auront converti en commandes analysables et interprétables par une machine [7].

Cela est notamment intéressant pour les sujets qui souffrent d'un handicap moteur grave tel que le syndrome d'enfermement (Locked In Syndrome) ou les lourdes paralysies pour leur offrir un appui et bonifier leurs vie grâce au contrôle mental des appareils externes [8].

Le principe de l'ICM est de mesurer les signaux physiologiques émis par l'utilisateur et prédire les réponses les plus performantes dans un bref laps de temps [9].

1.2.2. Structure générale d'une ICM

Une ICM est une chaîne du traitement digital en temps réel de l'activité cérébrale.

Ce traitement est découpé en plusieurs étapes intégrées au sein d'une boucle fermée qui permet à l'utilisateur d'avoir un retour sensoriel de l'impact de son activité cérébrale sur l'appareil. La figure 1 ci-dessous illustre les différentes étapes d'une ICM.

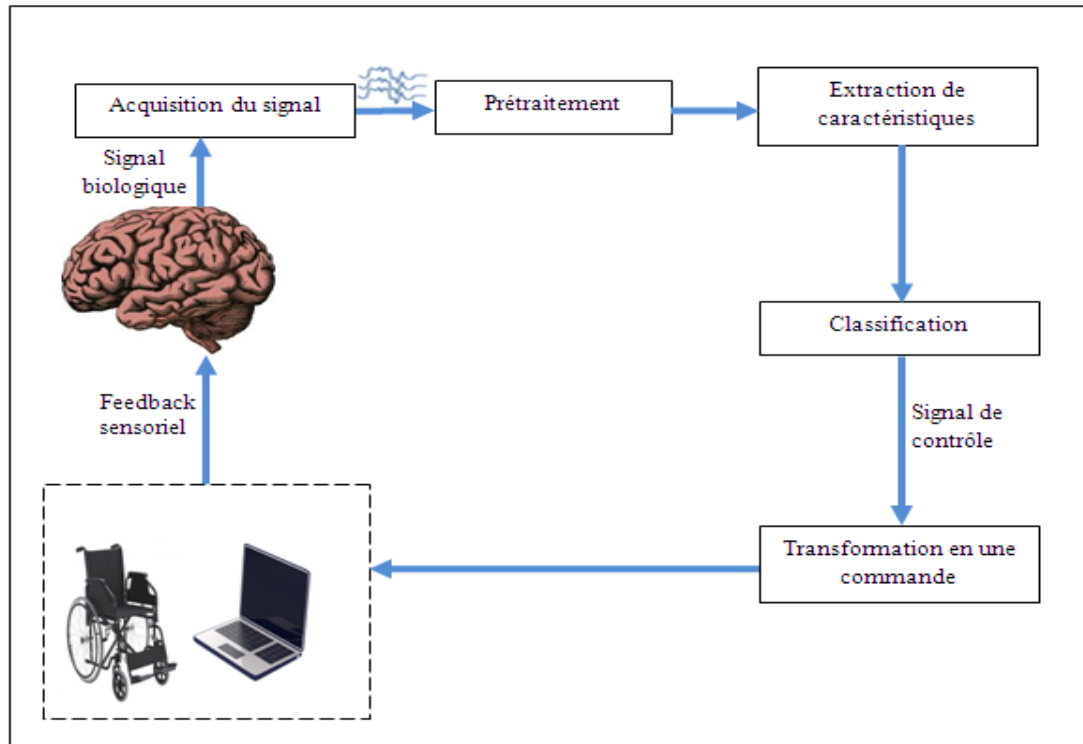


Figure 1 : Architecture d'une Interface Cerveau-Machine.

Dans ce qui suit, nous allons expliquer brièvement ces étapes :

- **Acquisition du signal :** cette étape permet de mesurer l'activité cérébrale. De nombreuses techniques d'acquisition peuvent être utilisées pour accomplir une ICM [1]. Ces techniques sont décrites dans la section 1.4.
- **Prétraitement :** Tous les signaux cérébraux enregistrés peuvent être affectés par des artefacts. Ce nécessite un filtrage par l'augmentation du rapport signal/bruit et l'élimination des artefacts, lors de cette étape, pour les améliorer et extraire les caractéristiques pertinentes [10].
- **Extraction de caractéristiques :** Il s'agit d'extraire les tâches mentales discriminantes d'un signal prétraité. Les caractéristiques extraites sont regroupées dans un vecteur appelé « *vecteur de caractéristiques* » avec une dimension réduite tout en préservant les informations importantes [3].

- **La classification** : ou la reconnaissance de formes permet de détecter ou prédire l'intention de l'utilisateur à partir du vecteur des caractéristiques définis par l'étape précédente [3, 11]. Il faut que les classes soient distinctes entre eux et chaque classe soit libellée en fonction du vecteur de caractéristiques. Il existe plusieurs algorithmes de classification (classifiers) tels que les réseaux de neurones ou les Analyses Linéaires Discriminantes (ALD), etc. [12]. Les signaux classifiés sont appelés signaux de contrôle.
- **Transformation en une commande (interface de contrôle)** : Une fois que la tâche mentale de l'utilisateur a été reconnue, elle est convertie en commande efficace et interprétable par une machine connectée (ordinateur, chaise roulante, ...) [3].
- **Retour sensoriel (Feedback)** : cette étape offre à l'utilisateur un retour sensoriel qui est dans le plus souvent visuel mais peut être parfois auditif ou par tactile pour lui montrer l'effet de sa tâche demandée sur un appareil extérieur.

1.2.3. Terminologie sur les différents types d'ICM

Il existe plusieurs catégories d'ICM qui peuvent être classifiés en invasives ou non invasives, endogènes ou exogènes et synchrones ou asynchrones.

Ces types d'ICM sont décrits dans ce qui suit :

1.2.3.1. ICM invasive / ICM non invasive

La distinction entre ces deux types d'ICM se fait suivant le type de technique d'acquisition utilisée pour collecter la tâche mentale demandée.

- ICM invasive

Les ICMs invasives ou directes, utilisent des méthodes d'enregistrement invasives qui nécessitent une implantation des électrodes à l'intérieur du crâne par une opération neurochirurgicale, et mesure le signal neuronal par le biais d'enregistrements directs. Ainsi, Ils permettent d'atteindre une haute résolution spatio-temporelle avec le minimum des bruits et des artéfacts, ce qui permet de proposer une réponse plus rapide et plus précise. Cependant, ce type d'ICMs peut être risqué pour la santé. En effet, Il peut y avoir des problèmes d'infection ou de lésions dues au mouvement des électrodes au cours du temps [13].

- ICM non invasive

Les ICMs non invasives ou indirectes, utilisent des techniques d'acquisition non invasives dont les électrodes sont posées sur le cuir chevelu pour enregistrer les signaux cérébraux. Les

signaux captés traversent la boîte crânienne avant d'arriver aux électrodes posées à la surface. Ils sont donc vulnérables à contenir des bruits et des parasites [7, 14].

Ce type d'ICM est facile à appliquer avec une résolution temporelle robuste permettant d'identifier toutes les modifications de l'activité cérébrale [14].

1.2.3.2. ICM endogène / ICM exogène

Selon la nature des signaux de contrôle utilisés, les ICMs sont classés comme endogènes ou exogènes.

- ICM endogène

Les ICMs endogènes permettent au sujet de contrôler le système sans stimuli externe [13], et de générer spontanément des activités cérébrales telles que l'imagination motrice que ce soit de façon consciente ou inconsciente [10]. Cette famille est destinée principalement aux individus qui souffrent des handicaps moteurs graves tels que la Sclérose Latérale Amyotrophique (SLA) [13]. Cependant, une ICM endogène peut être fatigant pour certains utilisateurs. De plus, la phase d'entraînement peut durer beaucoup de temps [13].

- ICM exogène

Les ICMs exogènes utilisent une activité mentale issue dans le cerveau par un stimulus externe [7]. Généralement, la stimulation est visuelle dont les signaux de commande sont de type Potentiels Evoqués Visuels tels que le SSPEV. Ce type de stimuli exige que l'individu soit capable de contrôler ses muscles. En revanche, il existe un autre type de stimulation qui est destiné spécialement aux individus souffrant de certains handicaps que leur empêche de contrôler leurs muscles. Dans ce cas, l'ICM utilise des stimuli sensoriels tels que les potentiels P300 [14]. La fixation du signal de commande pour une ICM exogène est simple et rapide, de plus l'entraînement est très superficiel.

1.2.3.3. Protocoles synchrones / Protocoles asynchrones

La notion de synchronicité est considérée comme un classement des ICMs qui dépend de la façon d'activation du système, soit volontaire ou non. On distingue ainsi les protocoles synchrones à stimulation automatique versus les protocoles asynchrones à rythme automatique [13].

- Protocoles synchrones :

Le système impose le sujet à réaliser une tâche mentale en réponse à un stimulus donné par la machine, pendant des instants prédéfinis par des signaux visuels ou sonores. Bien que

l'utilisateur ne puisse envoyer une commande qu'après un stimulus, la connaissance de l'instant de détection du signal à l'avance est un avantage pour les ICMs synchrones pour que le sujet essaie d'éviter à faire des mouvements qui provoquent des parasites et des bruits dans cette période, et ne s'accomplissent qu'au temps de relaxation [11, 13].

- Protocoles asynchrones :

Le sujet peut envoyer des commandes quand il le décide, sans attendre des stimuli externes. En outre, Il est autorisé à modifier son activité cérébrale qui est traitée d'une manière continue par le système. Ainsi, l'utilisateur est apte à contrôler la machine successivement et à chaque instant. Mais, les ICMs asynchrones sont plus exigeants et compliqués en termes de calcul [13, 15].

1.3. Quelques notions de neurophysiologie

Le cerveau (spécifiquement le cortex cérébral) est divisé en quatre parties principales dites « lobes ». Chaque lobe assure un ensemble organisé de fonctions. La figure 2 illustre les principaux lobes du cerveau. Ceux-ci sont définis dans ce qui suit :

- **Lobe frontal** : Ce lobe se trouve dans la partie antérieure du cerveau. Il est responsable à de nombreuses fonctions cognitives telles que la pensée, le raisonnement, la perception, la mémoire, la conscience, l'apprentissage, et le comportement [16]. Il nous permet de réfléchir, décider, planifier et exécuter [17]. De plus, cette région a pour fonction le contrôle et la coordination de tous les mouvements du corps dont celles musculaires, les mouvements volontaires, et les mouvements cohérents et organisés de la tête et de la gorge ensemble [18]. Il contient également le centre de production de la parole, de gestion des ressentis, et des émotions [19] aussi bien d'autres aspects de la personnalité [18].
- **Lobe pariétal** : Ce lobe se situe dans la partie moyenne du cerveau derrière le lobe frontal [19]. Il est responsable principalement par les processus sensoriels tels que le sens de la douleur ou la fatigue, la détection de la température du corps, et toutes les allergies cutanées, et de leurs traités [20]. Il est impliqué dans les tâches visuelles et l'orientation spatiale et intervient dans l'aspect cognitif [19].
- **Lobe temporal** : C'est la partie qui se situe entre l'arcade auxiliaire et l'oreille. Elle gère les deux sens de l'audition et du goût [18]. Elle assure aussi des fonctions cognitives (la mémoire, la reconnaissance des visages, et la compréhension du langage) [21].

- **Lobe occipital** : Ce lobe est situé à l'arrière du cerveau, et au-dessus du cervelet. Il renferme le cortex visuel qui permet de détecter et traiter les images en interprétant les couleurs, les formes, et les mouvements [16].




Figure 2 : Les quatre lobes de l'hémisphère gauche.

Le cortex cérébral est divisé en plusieurs aires fonctionnelles dont chacune assure une fonction cognitive précise. Les aires motrices (cortex moteur) sont situées dans la partie postérieure du lobe frontal, contigu le sillon central. L'aire motrice primaire ou cortex moteur primaire, également appelée M1, est le centre de la commande motrice. Son activité est à l'origine de la planification, du contrôle et de l'exécution des mouvements volontaires [22]. Chaque organe moteur est relié à une région spécifique comme illustré dans la figure 3.

Le système nerveux est essentiellement constitué par les neurones. Il existe plus de 100 milliards de neurones dans le système nerveux humain, dont un peu moins de 20 milliards dans le cortex [22].




Figure 3 : Organisation somatotopique du cortex moteur primaire.

1.4. Les techniques d'acquisition des activités cérébrales

L'ICM permet principalement de mesurer l'activité cérébrale de l'utilisateur afin de dégager son désir qui sera envoyé comme une commande à un appareil externe tel qu'une chaise roulante, une prothèse, ... [4]. On peut distinguer plusieurs techniques d'acquisition de signaux cérébraux. Généralement, il existe deux grandes familles des méthodes qui permettent de capter le signal cérébral : techniques invasives et techniques non-invasives [8].

1.4.1. Techniques non-invasives

Les techniques non-invasives permettent d'éviter l'implantation chirurgicale de capteurs. L'activité cérébrale est mesurée depuis l'extérieur du crâne [8]. Ces techniques permettent donc d'assurer l'intégrité physique de l'utilisateur [10]. Mais, les signaux enregistrés peuvent être contaminés par des artefacts tels que les mouvements musculaires (électromyogramme, EMG), les clignements des yeux (électro-oculogramme, EOG), l'activité cardiaque (électrocardiogramme, ECG), etc. [10].

Plusieurs méthodes sont disponibles dans cette classe telles que l'Imagerie par Résonance Magnétique fonctionnelle (IRMf), la magnétoencéphalographie (MEG), l'électroencéphalogramme (EEG), L'électro-oculographie (EOG) et la Spectroscopie proche infrarouge (SPIR).

1.4.1.1. Imagerie par résonance magnétique fonctionnelle (IRMf)

L'IRMf est une technique d'imagerie qui permette de mesurer indirectement l'activité cérébrale et de la cartographier à travers la détection de variations locales du flux sanguin et ainsi affiché les régions stimulées dans le cerveau. En effet, une activation neuronale nécessite une augmentation du flux sanguin riche en oxygène entrant dans la zone cérébrale [23]. Pour visualiser le degré d'activation d'une zone précise, il est nécessaire d'utiliser le signal magnétique BOLD (Blood-Oxygen-Level-Dependent) qui permet de calculer le rapport entre l'oxyhémoglobine (sang oxygéné) et désoxyhémoglobine (sang désoxygéné) [8].

Cette technique fournit une meilleure résolution spatiale de l'ordre du millimètre en produisant une image de très haute résolution. De plus, c'est une procédure non-invasive qui ne présente aucun danger aux sujets. Néanmoins, l'IRMf a des défauts tels que : sa faible résolution temporelle de l'ordre de la seconde. De plus, cet appareil est coûteux et très volumineux [10]. La figure 4 ci-dessous représente l'appareil de l'IRMf.



Figure 4 : Machine IRMf [8].

1.4.1.2. La magnétoencéphalographie MEG

Cette méthode non-invasive est basée sur la mesure des variations du champ magnétique à la surface du crâne produite par l'activité électrique générée naturellement dans le cerveau. Ces variations étant extrêmement faibles ce qui nécessite l'utilisation de dispositif d'interférence quantique supraconducteur (SQUID), c'est-à-dire les capteurs doivent être refroidis à l'hélium liquide [8]. Cette technique nécessite l'installation du matériel spécifique dans une chambre isolée magnétiquement. La figure 5 ci-dessous représente la machine MEG. Ce dispositif n'est pas transportable et coûte très cher [23]. En revanche, la magnétoencéphalographie offre une

très bonne résolution spatiale (de l'ordre de millimètres) et une résolution temporelle élevée (de l'ordre de millisecondes) à cause de l'utilisation d'un grand nombre de capteurs [23]. En outre, les signaux enregistrés passent par des neurones pyramidaux dont les axones sont orientés parallèlement au crâne sans distorsion [24] et ainsi le rapport signal sur bruit est relativement élevé [23, 25].



Figure 5 : Appareil du MEG [8].

1.4.1.3. L'électroencéphalographie EEG

Cette technique est la plus souvent utilisée dans le développement des ICMs vue qu'elle est non invasive, portable, peu coûteuse et pratique. Elle fournit une forte résolution temporelle (de l'ordre de la milliseconde) [4] et une résolution spatiale très faible. L'EEG permet d'enregistrer l'activité électrique locale du cerveau à l'aide des électrodes placées sur le scalp du patient et maintenues généralement à un casque et reliées à l'appareil par des câbles électriques (figure 6 (a)). Afin d'améliorer la conductivité électrique entre le crâne et les électrodes, la plupart des systèmes utilisent un gel ou une pâte conductrice [10]. Les variations des potentiels électriques recueillis dans le temps seront affichées sous la forme d'un tracé sur un écran, on parle d'électroencéphalogramme illustré dans la figure 6 (b).




Figure 6 : Présentation d'un enregistrement EEG : (a) casque EEG, (b) Tracé EEG.

1.4.1.3.1. Principaux rythmes de l'EEG

Le signal EEG recueilli est composé principalement de cinq bandes de fréquences (appelées aussi ondes) qui permettent d'identifier l'état de conscience du sujet (Figure 7).

- **Les bandes delta :** Malgré leurs fortes amplitudes, elles sont les ondes les plus lentes des ondes cérébrales avec une fréquence en dessous de 4 Hz. Elles sont généralement obtenues lors d'un état de sommeil.
- **Les bandes thêta :** elles correspondent à des oscillations de fréquences assez basses (4-8 Hz). Elles révèlent à un état de détente, de plein éveil, de méditation profonde et utilisée en hypnose. C'est aussi un dépôt pour la mémoire, les émotions et les sensations.
- **Les bandes Alpha :** Ces sont des ondes qui ont une fréquence entre 8 et 13 Hz et une forte amplitude (de 30 à 50 μV). Elles apparaissent principalement lorsque le sujet ferme ses yeux et se relaxe. Ces rythmes se rapportent aux états d'éveil détendu et la pensée abstraite.
- **Les bandes Beta :** ce sont des ondes qui ont une fréquence plus élevée (de 13 à 30 Hz) mais l'amplitude est plus basse (de 10 à 30 μV). Elles se présentent lors d'un état attentif avec une activité intense du cerveau du sujet lorsque les yeux ouverts.
- **Les bandes gamma :** Elles correspondent à des rythmes de fréquence supérieurs à 30 Hz. Elles sont présentées dans chaque région du cerveau et en réponse à des stimulations sensorielles. Ce sont des rythmes des consciences et perceptions.

Les rythmes cérébraux les plus utilisées en ICM basée sur l'imagination motrice sont les oscillations Alpha et Bêta [26, 27].




Figure 7 : Présentation de différentes bandes fréquentielles du signal EEG.

1.4.1.3.2. Positionnement des électrodes

Le positionnement des électrodes sur le cuir chevelu, se fait selon le système international « 10-20 ». Le terme « 10-20 » définit les distances entre deux électrodes adjacentes en pourcentage (10% ou 20%) de la distance totale soit entre le nasion et l'inion ou entre le côté droit et gauche du crâne [26].

Chaque électrode est identifiée par une lettre et un numéro. La lettre représente l'aire cérébrale (Fp pour Fronto-polaire, F pour Frontale, C pour Centrale, P pour Pariétale, O pour occipitale et A est utilisée pour identifier les oreilles). Les chiffres pairs représentent les électrodes mises sur la partie droite du crâne alors que les chiffres impairs correspondent à la partie gauche du crâne. La lettre « z » remplace le zéro et est utilisée pour marquer les électrodes positionnées sur la ligne médiane qui relie le nasion à l'inion. Le chiffre augmente avec la latéralité par rapport au plan central [28].

Une augmentation de nombre des électrodes permette une amélioration au niveau de la résolution spatiale [29].

La figure 8 ci-dessous illustre l'emplacement des électrodes selon le système international 10/20.

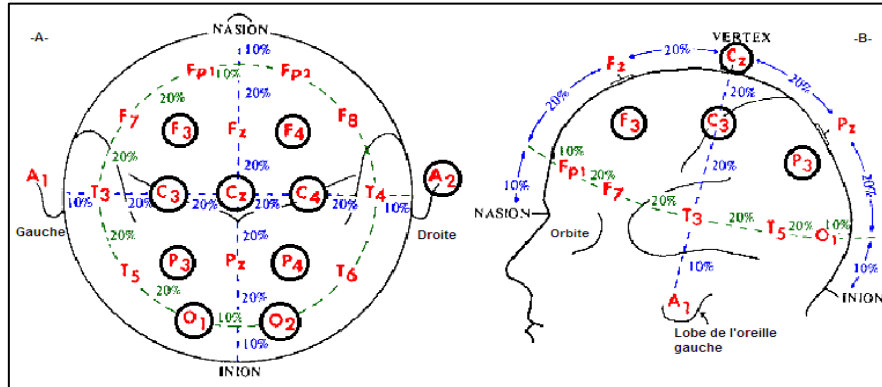


Figure 8 : Une représentation du système international 10-20. **A :** vue horizontale dorsale de la tête, **B :** vue latérale gauche de la tête.

1.4.1.4. L'électro-oculographie EOG

L'EOG est la technique qui permet d'enregistrer les changements de potentiels liés aux activités oculaires horizontaux et verticaux par l'intermédiaire de 4 électrodes en montage bipolaire.

Deux électrodes sont placées à gauche et à droite des yeux pour la mesure horizontale, l'autre paire est positionnée au-dessus et en dessous de l'un des yeux, œil droit ou œil gauche pour la mesure verticale [26].

La figure 9 présente l'emplacement des électrodes EOG avec une électrode de référence placée au centre du front et le signal EOG enregistré.

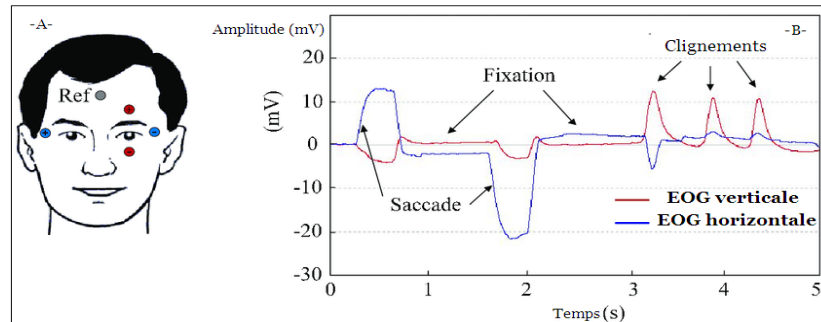


Figure 9 : L'électro-oculographie. **A :** Emplacement des électrodes EOG. **B :** Les mouvements oculaires saccadés, la fixation, et les clignements [30].

1.4.1.5. Spectroscopie proche infrarouge SPIR

Comme pour l'IRMf, cette technique est fondée sur la mesure du taux d'oxygénation des tissus dans le cerveau à travers les changements d'absorption de la lumière proche infrarouge.

Contrairement à l'IRMf, le SPIR est avantageux par sa portabilité, son faible coût de revient, et une résolution spatiale adaptée (à l'ordre d'un cm^2). En revanche, sa résolution temporelle est relativement faible [23].

1.4.2. Techniques invasives

Les techniques invasives consistent à implanter des capteurs à l'intérieur du crâne par le biais d'une intervention chirurgicale. Ainsi, il est facile à discriminer les signaux puisque les électrodes sont placées à proximité du cerveau.

Bien que ces méthodes offrent une haute résolution temporelle et spatiale avec un bon rapport signal sur bruit, il peut y avoir des risques pour la santé telle qu'une infection, ou des lésions tissulaires [24].

Ces techniques sont souvent réservées aux sujets avec une pathologie cérébrale sévère (comme les patients épileptiques) pour délimiter les aires cérébrales responsables des crises avant lobectomie [11].




Figure 10 : Une présentation de l'implantation des électrodes avec l'ECoG

Généralement, il existe deux modalités invasives se distinguant entre eux par le type d'électrodes implantées [23] :

- L'ÉlectroCorticoGraphie (ECoG) : Les électrodes sont placées directement sur le cortex (Figure 10).
- L'enregistrement neuronal intra-cortical (IND) : Les électrodes sont implantées à l'intérieur du cortex.

1.4.3. Comparaison entre les différentes techniques d'enregistrement

Bien que le signal EEG ait une faible résolution spatiale par rapport aux autres techniques d'acquisition, il est caractérisé par une résolution temporelle bien élevée.

Le tableau 1 ci-dessous représente les différences entre les méthodes d'enregistrement étudié précédemment.

Tableau 1 : Comparaison entre les différentes méthodes d'enregistrement utilisées pour les ICMs.

Méthode d'enregistrement	Nature du signal	Résolution spatiale	Résolution temporelle	RSB	Invasive	Transportable
IRMf	Métabolique	++	--	++	Non	Non
MEG	Magnétique	++	++	+	Non	Non
EEG	Electrique	-	++	--	Non	Oui
EOG	Oculaire	****	+	****	Non	Oui
SPIR	Métabolique	+	--	+	Non	Oui
ECoG	Electrique	++	++	+	Oui	Oui
IND	Electrique	+++	++	++	Oui	Oui

1.5. Phénomènes neurophysiologiques utiles pour les ICM

En ICM, plusieurs phénomènes neurophysiologiques qui dépendent de la tâche effectuée par le sujet sont utilisés.

Il existe deux types principaux de signaux soit évoqués soit spontanés [12] :

- **Les signaux spontanés**, sont produits suite à des commandes générées volontairement par le sujet lui-même tel que le potentiel cortical lent et l'imagination motrice.
- **Les signaux évoqués**, appelés aussi potentiels évoqués, sont produits de façon automatique pour répondre à des stimuli extérieurs tel que le potentiel évoqué P300 et le potentiel évoqué visuel.

1.5.1. Potentiel cortical lent

Potentiel cortical lent (PCL, en anglais Slow Cortical Potential : SCP) est une variation lente de l'activité cérébrale du tissu cortical dont la fréquence est inférieure à 1 Hz et dure quelques millisecondes jusqu'à plusieurs secondes.

L'utilisateur apprend à contrôler son potentiel après une longue formation à travers le phénomène de « *feedback* » (retour d'information visuel) en affichant toutes les mesures acquises en temps réel afin de le guider durant le processus d'apprentissage et bien commander le système [12].

La figure 11 présente les tracés des SCPS d'un sujet indiquant la moyenne de plus de 700 trials. La sélection des lettres est faite par le potentiel cortical positif (ligne solide) alors que la réjection est faite par le potentiel cortical négatif (ligne fine).




Figure 11 : Tracés de la variation SCPS pour un patient paralysé.

1.5.2. Potentiel évoqué P300

Le potentiel évoqué P300, appelée aussi P3, est une variation positive d'un signal électrique dû à un stimulus souvent visuel, parfois auditif ou tactile qui apparaît environ 300 millisecondes après un stimulus rare et pertinent [31]. Ce potentiel est présenté principalement dans la région pariétale [10].

L'utilisation des ICMs basée sur P300 ne nécessite pas d'apprentissage. Mais, le problème est que l'amplitude de ce potentiel est généralement réduite par rapport au celle de signaux spontanés, ce qui le rend difficile à détecter [11].

On peut détecter le signal P300 à partir du lobe occipital. Les électrodes qui fournissent les signaux les plus pertinents sont : Fz, Cz, et Pz [22].

La figure 12 illustre la forme du signal P300. Le temps entre le stimulus et la réponse est variable (entre 250 et 350 ms) tandis que la durée de la réponse est assez courte (entre 50 et 100 ms) [22].




Figure 12 : Potentiel évoqué P300.

1.5.3. Potentiel évoqué visuel

Les potentiels évoqués visuels (PEV, en anglais Visual Evoked Responses : VER) sont les variations de signaux cérébraux qui apparaissent dans le cortex visuel après un stimulus visuel (comme par exemple un motif graphique clignotant ou des flashes lumineux) [15].

L'amplitude des VEP augmente lorsque le sujet concentre son regard sur le stimulus. Ainsi, les réponses sont plus faciles à détecter [31].

1.5.4. L'imagination motrice

L'imagination motrice engendre des changements des rythmes μ et β (entre 8 et 40 Hz) dans le cortex sensorimoteur. Ce phénomène est appelé la désynchronisation ERD et la

synchronisation ERS. Les signaux ERD/ERS peuvent être utilisés pour représenter les processus moteurs. Il s'agit d'une diminution (ERD) ou d'une augmentation dans l'amplitude des composantes oscillatoires du signal EEG. La figure 13 présente un exemple sur la génération des signaux ERD/ERS lors de l'imagination des mouvements de la main droite et de la main gauche.

Les zones du cortex moteur où apparaît la désynchronisation dépendent du type de mouvement imaginaire. Par exemple, l'imagination du mouvement de la main droite, de la main gauche ou des pieds peut être discriminée par l'utilisation des électrodes C3, C4 et Cz respectivement [11, 32].

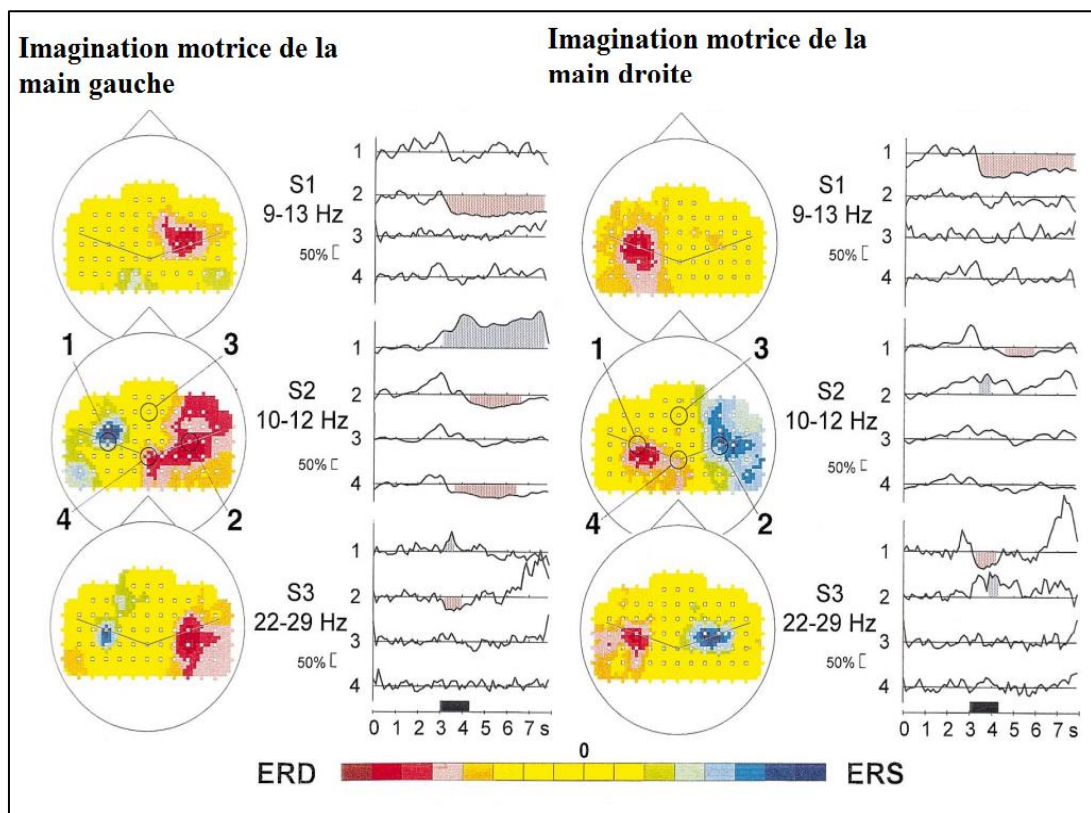


Figure 13 : Effet de l'imagination motrice de la main gauche et de la main droite sur les signaux EEG.

1.5.5. Comparaison entre les phénomènes neurophysiologiques utilisés en ICM

Le tableau 2 ci-dessous représente les différences entre les phénomènes neurophysiologiques étudiés précédemment.

Tableau 2 : Comparaison entre les différents phénomènes neurophysiologiques utilisés en ICM

Phénomène	Type de l'ICM	Signal cérébral	Avantages	Inconvénients
Potentiels évoqués	Exogène	- P300 - PEV	*Apprentissage minimal. *Configuration du signal de contrôle facile et rapide. *Meilleurs taux de transfert.	*Répondre à des stimuli externes. *Peut engendrer de la fatigue chez certains sujets.
Signaux spontanés	Endogène	- SCP - IM	*Indépendant de toute stimulation. *Générés volontairement. *Utiles pour les patients dont les organes sensoriels sont affectés. *Convient aux applications de contrôle des appareils domestiques.	*Formation chronophage. *Les utilisateurs ne sont pas tous capables d'obtenir le contrôle. *Faible taux de transfert.

1.6. Conclusion

Ce chapitre nous a permis, en premier lieu, de présenter le principe de base du fonctionnement d'une ICM. En second lieu, nous avons introduit quelques notions de neurophysiologie. Cette partie nous a permis de familiariser avec la structure de l'organe le plus complexe de notre corps ainsi que le mode de fonctionnement des neurones. Ensuite, nous avons discuté les différentes techniques d'acquisition des activités cérébrales invasives et non invasives. Enfin, nous avons présenté quelques phénomènes neurophysiologiques utiles pour les ICMs. Le chapitre suivant décrit notre méthodologie utilisée pour la classification des tâches d'imagination motrice.

Chapitre 2 :

Classification des mouvements d'imagination motrice en se basant sur l'apprentissage profond

2.1. Introduction

Le chapitre précédent a présenté un contexte général sur les ICMs. Ce chapitre abordera les différentes méthodes de traitement du signal nécessaire à la réalisation de ces ICMs. Nous nous restreindrons au cas particulier des ICMs basées sur l'imagerie motrice, présentées dans le paragraphe 1.5.4. Ce chapitre se décompose en deux sections, l'une abordant un état de l'art des ICMs en EEG, et la seconde portant sur notre méthode proposée.

2.2. Etat de l'art

De nombreux travaux de recherches ont été effectués pour le développement de méthodes de classification des mouvements d'imagination motrice en se basant sur l'apprentissage profond.

Dans [33], les auteurs appliquent un modèle basé sur les réseaux de neurones convolutifs (CNN) pour améliorer la stratégie de réadaptation des accidents vasculaires cérébraux en exécutant deux tâches d'imagination motrice différentes (poing gauche/droit ou les deux poings/les deux pieds).

Dans [34], les auteurs ont utilisé un nouveau modèle CNN multi-branches basé sur la fusion, appelé EEGNet Fusion pour améliorer la précision de la classification de l'IM-EEG inter-sujets. Après une comparaison avec les modèles EEGNet, ShallowConvNet et DeepConvNet, les chercheurs ont démontré que leur modèle est bien adapté à la classification des tâches de l'imagination motrice lorsqu'ils l'ont utilisé en combinaison avec la méthode de prétraitement proposée mais avec un coût de calcul est très élevé.

Dans [35], les auteurs ont appliqué une approche d'apprentissage profond basée sur le CNN pour générer le neuro-feedback. Ils ont proposé un nouveau concept de Méga Blocs pour adapter une architecture CNN au décodage des tâches mentales à l'aide de l'EEG pour l'apprentissage intra et inter-sujets. Toutefois, ils ont remarqué que la combinaison des canaux EEG en profondeur pourrait poser des problèmes dans des ensembles de données de très grande dimension.

Les auteurs dans [36] ont obtenu une précision compétitive en utilisant les caractéristiques temps-fréquence générées par une transformation de Fourier à court Terme avec CNN suivi d'un Stacked auto-encoder (SAE). Dans [37], les auteurs ont introduit des mesures de connectivités des réseaux cérébraux et les combinés avec une seule couche de CNN dans le but de reconnaître les tâches de l'imagination motrice.

Dans [38], un algorithme CWT-SCNN a été proposé pour classer les signaux EEG d'imagination motrice des mains gauche et droite. La combinaison entre la transformée en ondelettes continue et le réseau de neurones convolutif simplifié permet d'améliorer la précision de la classification et la valeur kappa avec temps d'apprentissage réduit. Dans [39], les auteurs ont proposé une nouvelle méthode basée sur le réseau neuronal convolutif profond (DCNN) pour effectuer l'extraction des caractéristiques et la classification d'IM-EEG de la main gauche et de la main droite à un seul essai.

Dans [40], les auteurs ont utilisé un modèle DCNN avec des filtres temporels et spatiaux séparés pour la classification des signaux MI-EEG bruts des électrodes symétriques sur la région du cortex moteur gauche et droite pour les mouvements du poing gauche, le poing droit, les deux poings et les deux pieds, sans aucune opération de prétraitement et d'extraction de caractéristiques artificielles. Les filtres utilisés sont le dropout spatial et la normalisation des lots (BN) qui ont réduit efficacement le risque de sur-ajustement, et améliorer la capacité de généralisation et l'effet de classification du modèle. Les résultats obtenus montrent la performance la plus stable du modèle utilisé.

Des autres recherches ont utilisé la mémoire à long ou à court terme (LSTM), qui est un type spécial de réseau neuronal récurrent (RNN), pour extraire des caractéristiques temporelles comme dans [41]. En fait, les auteurs ont appliqué le CNN et le LSTM afin de détecter et classer les signaux EEG d'imagination motrice des mains gauche et droite dans le domaine du vieillissement en bonne santé. Le CNN est utilisé pour extraire les caractéristiques les plus pertinentes alors que le LSTM est utilisé pour classer la série chronologique. Les résultats qui sont obtenus représentent une découverte prometteuse afin de démocratiser l'indépendance des utilisateurs par l'adoption de technologies de Muse headband en combinaison avec l'apprentissage profond.

Dans [42], la structure hybride CNN-LSTM a donné une bonne précision de classification de quatre tâches différentes tâches de l'IM (main gauche, main droite, langue et pieds).

Pour transformer les signaux IM-EEG en images 2D à l'aide d'un apprentissage profond, les auteurs dans [43] ont proposé une méthode de classification basée sur le DCCN pour extraire les caractéristiques spatiales et fréquentielles, suivi du LSTM qui est souvent utilisé pour extraire des caractéristiques temporelles et classer les résultats en 5 classes différentes (4 tâches d'imagination motrice et un repos). Les résultats de cette combinaison étaient 5% meilleurs que les résultats de la méthode Support Vector Machine (SVM) sur le même jeu de données.

Dans [44], les auteurs ont proposé deux types des structures, séries et parallèles, en combinant le CNN et le LSTM pour extraire les caractéristiques multidimensionnelles et améliorer la précision de classification des tâches mentales imaginées (main gauche, main droite, pieds et langue). Ces chercheurs ont utilisé un CNN Compact (CCNN), c'est un CNN avec des convolutions profondes et séparables qui permettent d'extraire directement les caractéristiques spatiales et fréquentielles des données brutes, et un CNN peu profond (SCNN pour Shallow CNN), il est inspiré du FBCSP et se compose seulement de deux couches de convolution, comme module CNN pour former un réseau neuronal récurrent convolutif série ou parallèle avec LSTM. Ils ont développé alors quatre nouvelles architectures (SCCRNN, SSCRNN, PCCRNN et PSCRNN). Les résultats obtenus par l'architecture série sont les meilleurs par rapport aux méthodes conventionnelles et les algorithmes d'apprentissage profond.

Dans la référence [45], les auteurs ont visé à explorer la meilleure méthode de classification des tâches d'IM à l'aide de signaux EEG basée sur une approche d'apprentissage profond en comparant deux modèles proposés : CNN modifié et RNN-LSTM modifié sur le même ensemble de données de base. Les résultats ont montré que le modèle CNN modifié a excédé le modèle RNN-LSTM modifié en termes de précision. D'ailleurs, une comparaison avec les méthodes récentes affirme que le CNN modifié surpasse les méthodes de l'état de l'art.

Notre objectif est de proposer trois nouvelles méthodes de classification de l'imagination motrice basée sur l'apprentissage profond. La section suivante détaille la démarche de notre méthodologie proposée.

2.3. Contexte théorique

L'apprentissage profond (Deep Learning) est une technologie de modélisation prédictive des données (image, audio, texte) et constitue une classe d'algorithmes d'apprentissage automatique (Machine Learning) qui a permis dans les dernières années des avancées importantes en intelligence artificielle. Elle est capable de classer les mouvements

d'imagination motrice grâce à des architectures articulées de différentes transformations non linéaires.

2.3.1. L'intelligence artificielle

L'intelligence artificielle (IA) est une science qui étudie les moyens de fabriquer des machines et des systèmes informatiques intelligents capables d'apprendre et de résoudre des problèmes de manière créative en tant qu'humains [48, 49].




Figure 14 : L'intelligence artificielle et ses sous-ensembles, image d'après [46]

La figure 14 présente le vaste domaine de l'intelligence artificielle contenant un sous-ensemble « apprentissage automatique » dont l'une des principales technologies est l'apprentissage profond (Deep Learning).

2.3.2. L'apprentissage automatique

C'est un sous domaine de l'IA qui permet à des applications d'être plus précises dans la prévision des résultats sans être explicitement programmés à l'aide des algorithmes alimentés par un grand nombre de données historiques [50].

Les tâches d'apprentissage automatique sont généralement classées en trois approches élémentaires [50] :

- L'apprentissage supervisé où l'algorithme d'apprentissage est entraîné souvent pour une analyse prédictive avec des entrées étiquetées et des sorties souhaitées.
- L'apprentissage non supervisé où seuls des exemples d'entrées sont donnés sans sorties correspondantes à fin d'établir des segmentations ou des classifications. Il agit sur les données sans formation préalable.

- L'apprentissage par renforcement est une méthode de formation basée sur les récompenses et les punitions des comportements dans l'espace, réel ou virtuel, de problèmes.

Les applications d'apprentissage automatique peuvent être classées différemment [50] :

- La classification où les entrées sont divisées en deux ou plusieurs classes, et l'apprenant doit produire un modèle qui attribue des entrées invisibles à une ou plusieurs de ces classes.
- La régression : se pose lorsque la valeur de sortie est continue plutôt que discrète, comme le prix ou le poids.
- Le regroupement (clustering) est la division de l'ensemble d'entrée en groupes en fonction de la similarité.
- Détection d'anomalies : identification de points de données inhabituels dans un ensemble de données.
- Recherche d'associations : identification dans un ensemble de données de séries d'éléments souvent associées.
- La réduction de la dimensionnalité : il s'agit de réduire le nombre de variables dans un ensemble de données et les mapper dans un espace de dimension inférieure.

Dans les dernières années, la technologie est en évolution constante et une grande quantité de données balayant notre monde de façon spectaculaire. Néanmoins, il est difficile d'exploiter les contenus de données puisqu'ils n'ont pas été correctement étiquetés ou édités. Par conséquent, un outil plus puissant devient un besoin assez urgent ; connu sous le nom de l'apprentissage profond (Deep Learning). Il a permis des avancées importantes en intelligence artificielle.

2.3.3. L'apprentissage profond

Actuellement, nous assistons à une croissance spectaculaire de l'image et des données en raison de la propagation rapide des appareils électroniques capables d'enregistrer et de partager des images, des vidéos et des informations. L'apprentissage profond est extrêmement utile pour la collection, l'interprétation et l'analyse de grandes quantités de données d'une manière plus rapide et plus facile [48].

L'algorithme d'apprentissage automatique le plus populaire qui comprend les statistiques et la modélisation prédictive et qui concerne les algorithmes inspirés de la structure et de la fonction du cerveau appelés réseaux de neurones artificiels (ANN pour Artificial Neural Network). L'ANN est composée de milliers d'unités (les neurones) connectés entre eux et qui effectuent chacune de petites opérations simples, reliant les entrées aux sorties désirées.




Figure 15 : Réseaux de neurones artificiels (ANN)

Le réseau de neurones artificiels profonds est l'un des modèles de calcul les plus utilisés aujourd'hui pour analyser et classer les images. Il utilise une variation de perceptrons multicouches et les réduire sous une forme plus facile à traiter, sans perdre les fonctionnalités essentielles pour obtenir une bonne prédiction.

2.4. Architectures des méthodes proposées

Du point de vue du traitement du signal cérébral, la réalisation d'une ICM consiste à résoudre un problème de détection d'une ou plusieurs tâches d'imagination motrice à partir des signaux EEG, on parle d'un problème de classification. À partir des signaux bruts, on applique un simple prétraitement et on extrait les caractéristiques les plus pertinentes. Puis, ces derniers seront projetés dans un vecteur afin de faciliter la discrimination entre les différentes tâches d'IM. Ensuite, ce vecteur de caractéristiques est considéré comme une entrée à l'algorithme de classification des tâches mentales. Dans ce travail, nous avons proposé trois méthodes basées sur le CNN, le RNN-LSTM et le LSTM bidirectionnel.

2.4.1. Prétraitement des signaux EEG

Nous avons appliqué un simple prétraitement qui consiste à éliminer les trois canaux EOG tout en gardant les 22 canaux EEG. Nous avons extrait seulement les époques d'IM. Nous avons 288 époques d'IM et chaque époque dure 3 secondes.

2.4.2. Réseaux de neurones convolutifs (CNN)

Un réseau neuronal convolutif (CNN) est une sorte de réseaux de neurones artificiels qui inspire son fonctionnement par celle du cortex visuel. C'est un algorithme d'apprentissage profond très performant pour classer des images. Ces derniers sont fournis sous la forme d'une matrice de pixels. Les valeurs de chaque pixel peuvent être soit binaire où les 0 représentent les pixels noirs et les 1 représentent les pixels blancs, soit en niveaux de gris où les valeurs sont comprises entre 0 (le noir) et 255 (le blanc), soit en couleur (RVB : Rouge, Vert, Bleu).

Une architecture CNN typique se compose de 4 couches différentes : couche convolutive, couche mise en commun (pooling), couche de mise à plat (flatten) et couche entièrement connectée (fully connected appelée aussi dense). Les CNN sont capables d'extraire des caractéristiques spatiales d'une image par l'application d'une succession de filtres qui sont apprises par le réseau lors de la phase d'entraînement (apprentissage sans supervision). Les caractéristiques extraites ont une puissance de discrimination élevée pour les problèmes de classification multi-classe.

- Couche convolutive (CONV) :

La couche de convolution est le noyau du CNN. Elle contient plusieurs opérations convolutives (convolution des filtres) appliquées sur l'image d'entrée afin d'extraire les caractéristiques. Les trois hyperparamètres suivants permettent de dimensionner le volume de la couche de convolution : **la profondeur** (matrice de filtre) appelé kernel (noyau) et souvent en 3×3 , **le stride** (le pas) qui représente le décalage du kernel entre chaque calcul, et **le padding** (la marge) consiste à mettre des zéros à la frontière de l'image d'entrée.

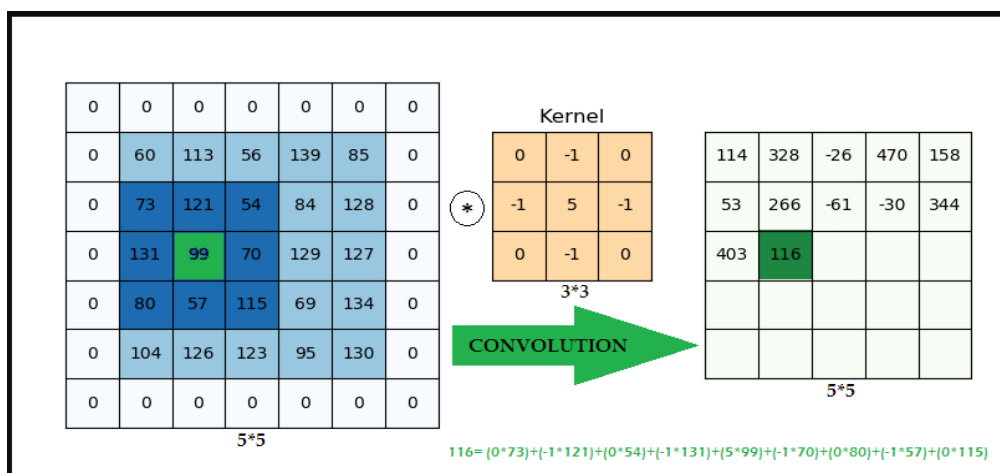


Figure 16 : Exemple de couche convolutive.

Il est connu que la dimension du volume de sortie est donnée par la formule suivante :

$$\left\lfloor \frac{i-k+2p}{s} \right\rfloor + 1 \quad (1)$$

Où « i » est la dimension associée à l'entrant, « k » la dimension du filtre, « p » l'épaisseur de la marge à zéro et « s » l'amplitude du pas utilisée.

Dans la figure 16 ci-dessus, on a un entrant de dimension 5x5x1 ($i=5$) avec une marge à zéro de taille 1 ($p=1$), le filtre est de dimension 3x3x1 ($k=3$) avec un pas de 1 ($s=1$) pour les déplacements du filtre. La sortie de cette convolution est de dimension 5x5x1.

- Couche mise en commun (pooling) :

Le but de la mise en commun est de transformer la représentation commune des caractéristiques en une représentation plus utilisable qui préserve les informations importantes tout en éliminant les détails non pertinents.

L'utilisation de la couche de mise en commun dans les CNN vise à obtenir l'invariance aux changements de position ou de conditions d'éclairage, la robustesse à l'encombrement et la compacité de la représentation. En général, la couche de mise en commun résume les sorties de groupes de neurones voisins dans la même carte de noyau.

Dans la couche de mise en commun, la résolution des cartes de caractéristiques est réduite en regroupant sur le voisinage local sur les cartes de caractéristiques de la couche précédente, améliorant ainsi l'invariance aux distorsions sur les entrées.

Les méthodes de mise en commun maximale (max pooling) et de mise en commun moyenne (average pooling) sont deux choix populaires utilisés par les CNN en raison de leur efficacité de calcul.




Figure 17 : Processus de pooling.

- **Couche mise à plat (flattening) :**

Tous les pixels obtenus des dernières couches convolutives et mise en commun, sont récupérés ligne par ligne et converties en un vecteur 1D (figure 18). Ils sont utilisés comme entrée pour la couche entièrement connectée pour effectuer la classification voulue.

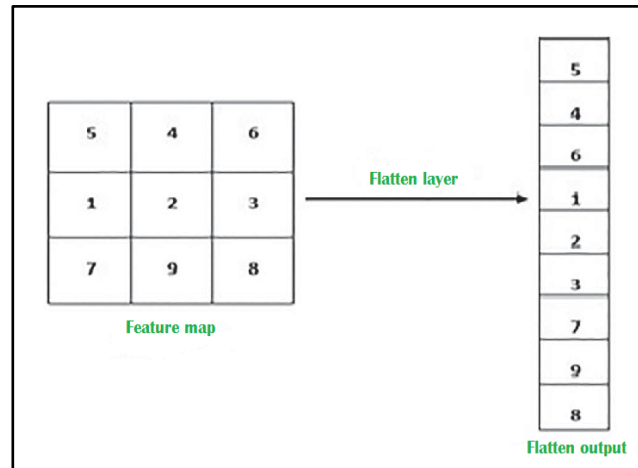


Figure 18 : Présentation d'un exemple de la mise à plat

- **Couche entièrement connectée (appelée en anglais Fully-Connected ou dense) :**

La couche entièrement connectée est la dernière partie de CNN. En fait, une ou plusieurs couches entièrement connectées (FC) peuvent être ajoutées au réseau pour effectuer la classification. Dans le cas d'un apprentissage supervisé, la dernière couche contient les neurones correspondant au nombre de classes. Chaque neurone de la couche FC est entièrement connecté aux neurones de la couche précédente. Cette couche permet de combiner toutes les cartes d'entités issues des couches précédentes pour classer les images. De plus, il est généralement suivi d'une fonction d'activation Softmax qui permet de générer des probabilités d'appartenance à chaque classe.




Figure 19 : Présentation d'un exemple des couches entièrement connectées.

- **Architecture du modèle CNN proposée :**

Le CNN est considéré comme la meilleure méthode de détection de composante spatiale et fréquentielle des données. Les caractéristiques les plus pertinentes sont extraites des bandes de fréquences μ et β (entre 8 et 30 Hz) dans le cortex sensorimoteur.




Figure 20 : Architecture du CNN proposée

Notre modèle CNN proposé comporte trois grandes parties : prétraitement des données EEG (comme présenté dans la section 2.4.1), l'extraction de caractéristiques et la classification.

La deuxième partie est composée de deux couches de convolution dont chacune utilise un noyau de taille 3×3 avec un pas de 1, et une fonction d'activation (Relu), suivie d'une couche normalisée par lots de taille 64 et d'une couche de mise en commun max de

taille 2×2 . Après les 2 couches de convolution et de regroupement maximal, nous avons obtenu une carte de caractéristiques. Nous aplatissons cette sortie pour construire un vecteur de caractéristiques 1D qui sera compilé par les étapes suivantes.

Pour la classification, nous avons utilisé trois couches entièrement connectées dont la première couche prend l'entrée du vecteur de caractéristiques obtenue par la couche mise à plat. Chacune de deux premières couches entièrement connectées (FC) est suivie par une fonction d'activation (Relu) et une unité d'abandon (la probabilité d'abandon est fixée à 0,5).

La troisième couche (FC) génère un vecteur de 4 meilleurs canaux (vecteur de classification). Ce dernier est envoyé à l'étape Softmax pour la normalisation et la détermination de probabilité de chaque classe ce qui permet de former la sortie finale (output layer).

Nous avons utilisé la fonction d'activation Relu (Rectified Linear activation) pour les couches cachées. C'est la fonction d'activation la plus couramment utilisée dans les modèles d'apprentissage profond puisqu'elle est très efficace en termes de calcul et minimise la probabilité de disparition du problème de gradient. Une transformation Relu est appliquée après chaque opération de convolution et chaque couche entièrement connectée afin de remplacer tous les valeurs négatives dans l'entrée par des 0 en appliquant la fonction $f(x) = \max(0, x)$.

La normalisation par lots (Batch Normalisation) est une technique de normalisation interne introduite dans le réseau neuronal profond pour effectuer des opérations de recentrage et de mise à l'échelle sur les entrées de la couche que le précède afin de réduire le temps d'apprentissage et améliorer la performance et la stabilité des réseaux de neurones artificiels.

La couche entièrement connectée inclue la plupart des paramètres du CNN, et ainsi, les neurones éprouvent une co-dépendance entre eux pendant l'apprentissage, ce qui réduit la puissance individuelle de chaque neurone. En outre, elle entraîne un sur-ajustement des données d'entraînement et ralentisse le traitement de l'information. Pour prévenir cela, nous avons utilisé le processus d'abandon. C'est une approche de régularisation dans les réseaux de neurones artificiels permettant d'éviter le sur-ajustement des données d'entraînement en empêchant l'adaptabilité articulaire complexe de tous les neurones. Elle consiste à ignorer temporairement quelque neurone choisi aléatoirement avec une certaine probabilité lors de la formation d'un réseau profond.

La couche de classification appelée aussi couche de sortie est un vecteur qui contient les étiquettes des classes pertinentes et utilise la fonction d'activation SoftMax qui permet de

gérer l'opération d'élection. En effet, la fonction SoftMax calcule les probabilités de chaque classe cible sur toutes les classes cibles possibles et leur affecte des valeurs dans l'intervalle $[0,1]$ dont la somme de toutes les probabilités sera égale à 1. La classe qui a la meilleure probabilité représente le mouvement concerné.

2.4.3. Réseau neuronal récurrent (RNN)

Le Réseau neuronal récurrent (RNN pour Recurrent Neural Network) est un réseau de neurones très répandu en apprentissage profond. Il présente des connexions récurrentes dont toutes les entrées sont liées les unes aux autres, c'est-à-dire les résultats produits par une couche seront parmi les entrées de cette couche ou d'une couche plus basse. On parle ainsi d'une récursivité dans le sens de l'évolution de la séquence.

Toutes les unités de circulation sont reliées par des chaînes pour former une boucle fermée permettant à l'information de persister. La figure 21 présente un exemple de l'architecture du RNN.




Figure 21 : Présentation de l'architecture du RNN

Toutefois, il est difficile d'entraîner RNN par un algorithme de descente de gradient. Pour faire face à ce problème, une nouvelle version améliorée de RNN, appelée le réseau de mémoire à long/court terme (LSTM), en anglais 'Long Short-Term Memory network', est inventée.

Elle utilise des neurones plus sophistiqués et peut extraire plus efficacement les caractéristiques temporelles des signaux EEG. En outre, elle est capable de modéliser des dépendances à très long/court terme et de gérer l'oubli.

Elle est utilisée dans le domaine de l'apprentissage profond et particulièrement dans les applications où les données constituent des séquences (structures temporelles). Elle est adaptable à la classification, au traitement et à la prévision sur la base de données chronologiques.

Une LSTM standard possède deux portes un pour l'entrée et l'autre pour la sortie. Après les améliorations des nombreux chercheurs, une troisième porte d'oubli est introduite dans la cellule. Ces portes sont un moyen de laisser éventuellement passer les informations.

La cellule LSTM se souvient des valeurs sur des intervalles de temps arbitraires et les trois portes régulent le flux d'informations entrant et sortant de la cellule et utilise cette information pour faire de bonnes prédictions sur ce qui se passera ensuite. À la sortie, on distingue deux états (état de la cellule et état caché) qui seront transférés à la cellule suivante. Les informations peuvent être modifiées un peu en utilisant des multiplications et des additions. Chaque ligne transporte l'information, de la sortie d'une couche aux entrées des autres. La figure 22 ci-dessous illustre la structure générale de la cellule LSTM.




Figure 22 : Présentation de la structure générale d'une cellule LSTM

- **La porte d'oubli (Forget gate) :** Elle est chargée de découvrir les informations qui doivent être supprimées de l'état de la cellule. Cet effet est décidé selon l'importance de l'information par la fonction sigmoïde. Ceci est indispensable à l'optimisation des performances du réseau LSTM. Cette porte reçoit deux entrées, la sortie de la cellule précédente (h_{t-1}) et l'entrée de contenu (x_t), et la fonction sigmoïde est appliquée afin de générer un nombre pour chaque valeur dans l'état de cellule (C_{t-1}) ; ou bien « ≈ 0 » (c'est-à-dire omettre ceci) si la porte d'oubli veut que l'état de la cellule oublie cette information, ou bien « ≈ 1 » (c'est-à-dire conserver ceci) si la porte d'oubli veut que l'état de la cellule reste souvenant de cette information.
- **La porte d'entrée (Input gate) :** Elle est responsable de découvrir et d'ajouter les informations pertinentes à l'état de la cellule. La fonction sigmoïde décide quelles valeurs doivent être ajoutées à l'état de la cellule parmi les informations de (h_{t-1}) et (x_t). Ceci est très similaire à la porte d'oubli. Ensuite, la fonction tanh donne un poids allant de -1 à +1 aux valeurs conservées selon leur niveau d'importance pour éviter les problèmes de surcharge de la machine en calculs. Puis, la valeur de la fonction sigmoïde est multipliée par le vecteur de la fonction tanh afin d'ajouter l'information profitable à l'état de la cellule par l'intermédiaire d'une opération d'addition.
- **La porte de sortie (Output gate) :** maintenant, on peut décider ce qu'on va sortir en se basant sur l'état de la cellule filtrée. Pour le filtrage, on exécute une fonction sigmoïde, comme avec la porte d'oubli et la porte d'entrée, qui décide quelles valeurs parmi les valeurs de (h_{t-1}) et (x_t) laisser passer en utilisant les 0 et les 1. Par la suite la fonction tanh donne un poids dans la plage -1 à +1 aux valeurs qui sont transmises et multipliées par la sortie de Sigmoid. Enfin, la valeur obtenue est envoyée en sortie ainsi qu'à l'état caché (Hidden state) de la cellule suivante.
- **L'état de la cellule (Cell state) :** c'est la clé des LSTM, symbolisé par une ligne horizontale passant par le haut du diagramme. Il s'étend tout le long de la cellule formant un chemin transporteur. Elle est calculée en premier temps par la porte d'oubli en multipliant la sortie de ce dernier par l'ancien état de la cellule afin d'omettre les informations insignifiantes. Ensuite, une opération d'addition est exécutée avec la sortie de la porte d'entrée.

- **Architecture d'un modèle RNN proposée :**

Le modèle RNN proposé commence par une étape de prétraitement comme présenté dans la section 2.4.1. Ensuite, quatre cellules LSTM ont utilisé. Dans chacune de ces cellules, le nombre d'unités correspond au nombre de fenêtres temporelles glissantes. Ces cellules sont suivies d'une unité d'abandon (la probabilité d'abandon est fixée à 0,5) pour éviter le sur-ajustement, d'une couche SoftMax et d'une couche de classification à quatre catégories (Figure 23).

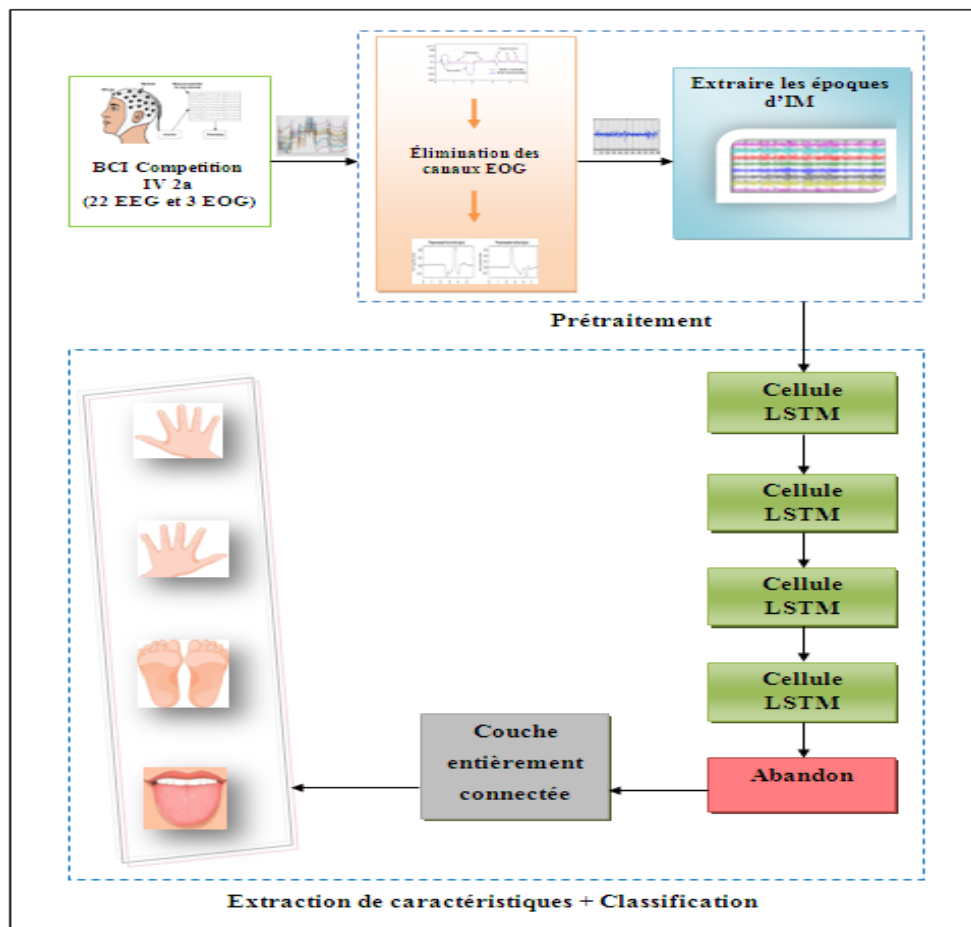


Figure 23 : Architecture du modèle RNN proposée

À fin de réduire le temps d'apprentissage, nous avons utilisé une couche cachée normalisée par lots de taille égale à 100.

- **Architecture du modèle LSTM bidirectionnel proposée :**

Le réseau LSTM bidirectionnel (BiLSTM) peut être entraîné dans les deux directions temporelles simultanément, c'est-à-dire doublé le transfert entre deux cellules LSTM successifs. Ainsi, nous pouvons distinguer un premier transfert avant permettant de parcourir

le signal arrivé depuis la mémoire du passé et l'autre transfert arrière depuis les observations futures disponibles. La structure de la cellule LSTM est décrite en détail dans la section 2.4.3.

Le modèle BiLSTM proposé est similaire au modèle RNN proposé. Les différences entre ces deux modèles sont :

- Utilisation de quatre cellules LSTM bidirectionnels (BRNN) signifie connecter quatre couches cachées de directions opposées à la même sortie. Avec cette forme d'apprentissage profond génératif, la couche de sortie peut obtenir des informations à partir d'états passés et futurs en même temps.
- Utilisation d'une couche cachée normalisée par lots de taille égale à 50.

Notre architecture proposée est illustrée par la figure 24 ci-dessous.

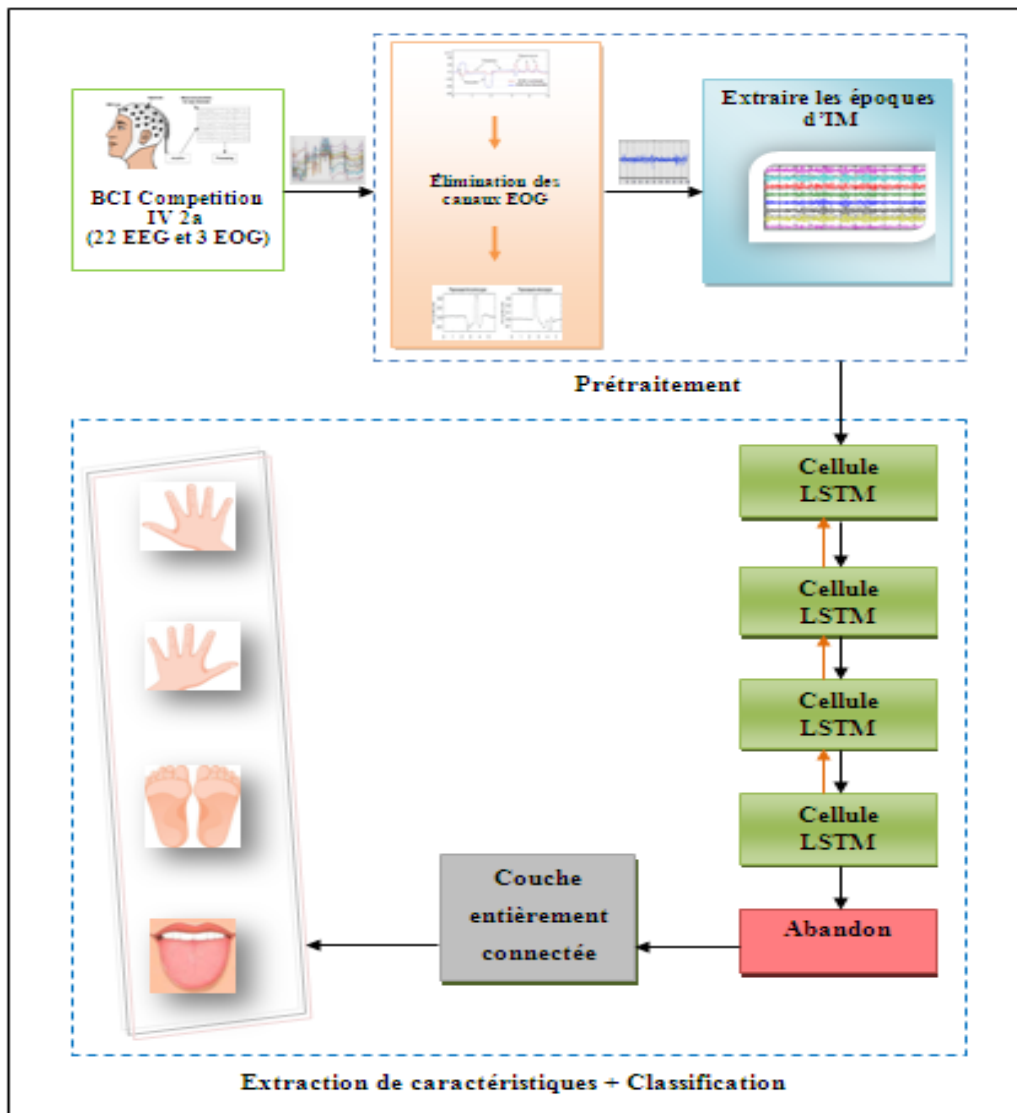


Figure 24 : Architecture du modèle LSTM bidirectionnel proposée

2.5. Conclusion

Dans ce chapitre, nous avons présenté les différents modèles de classification des mouvements d'imagination motrice basés sur l'approche de l'apprentissage profond. D'abord, nous avons commencé par un état de l'art sur les méthodes de traitement des signaux. Ensuite, nous avons étudié le contexte théorique tout en concentrant sur l'importance des théories de l'intelligence artificielle, de l'apprentissage automatique et de l'apprentissage profond. Enfin, une description détaillée des méthodes proposées pour la classification des tâches d'IM a été présentée. Le chapitre suivant sera consacré essentiellement à l'implémentation de ces méthodes et le test de la performance de notre approche proposée.

Chapitre 3 :

Évaluation des méthodes proposées pour la classification des mouvements d'imagination motrice

3.1. Introduction

Dans ce chapitre, nous allons représenter la base de données, le logiciel et l'outil utilisés ainsi que les résultats expérimentaux de nos modèles d'apprentissage profond proposés. Ensuite, nous allons discuter ses performances en termes de précision de la classification. Et nous finissons par comparer les résultats obtenus par notre système avec d'autres approches de l'état de l'art.

3.2. Présentation des bases de données

Dans ce travail, nous utilisons l'ensemble de données BCI Competition IV 2a qui contient des signaux EEG de quatre tâches d'imagination motrice différentes pour neuf sujets : imagination du mouvement de la main gauche, de la main droite, des deux pieds et de la langue.

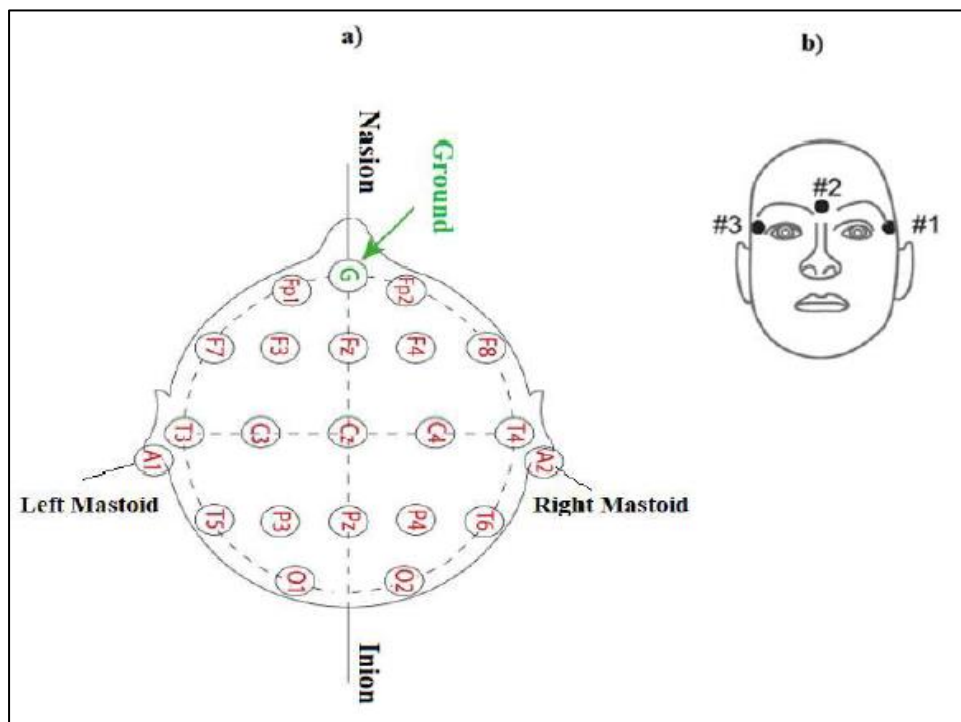


Figure 25 : a) Montage de 22 électrodes EEG. b) Montage des trois électrodes EOG [5].

Les signaux EEG ont été enregistrés avec 22 électrodes dont les distances inter-électrodes sont de 3,5 cm, la fréquence d'échantillonnage est à 250 Hz et une bande passante filtrée entre 0,5 Hz et 100 Hz. Les canaux EEG suivent la norme internationale 10/20.

Également, trois canaux EOG sont enregistrés. Chaque classe d'IM réalise 72 essais, soit au total 288 essais par session sont menés. La figure 25 ci-dessus représente le montage qui cartographie les canaux EEG et EOG respectivement sur (a) et (b).

Les sujets étaient posés dans un fauteuil confortable en face d'un écran d'ordinateur. Chaque session commence par un enregistrement de canaux EOG pendant 5 minutes ; deux minutes avec les yeux ouverts en regardant une croix de fixation sur l'écran, une minute avec les yeux fermés, une minute avec des mouvements oculaires. Cet enregistrement permet d'estimer l'influence de l'EOG.




Figure 26 : Schéma temporel du paradigme, image d'après [47]

Chaque essai commence à ($t = 0$ s) par une alerte sonore toute court suivie d'une croix de fixation qui apparaît pendant deux secondes sur un écran noir. Ensuite, une apparition d'un repère, pendant 1,25 s sur l'écran, pointe soit vers la gauche, la droite, le bas ou le haut et correspond respectivement à main gauche, main droite, pieds ou langue. Après cela, les sujets réalisent la tâche souhaitée pendant la période imaginaire.

Les sujets restent immobiles et répètent la même tâche de l'imagination motrice plusieurs fois jusqu'à ($t = 6$ s). Suite à chaque essai, ils peuvent prendre de courtes pauses. La figure 26 illustre le schéma de synchronisation d'une session.

3.4. Logiciels et outils

3.4.1. Colaboratoire Google (Colab)

Le collaboratoire de Google a été utilisé comme environnement de programmation principal pour toutes les instructions du projet. Il est basé sur le projet Open Source « Jupyter ».



Figure 27 : (a) Logo colaboratoire google, (b) Logo Jupyter

L'apprentissage profond est actuellement utilisé dans tous les types de grandes applications d'analyse de données ce qui nécessite un large temps de traitement. Pour assurer une meilleure efficacité et une réduction du temps de traitement, il est intéressant d'utiliser des machines haut de gamme avec des unités de traitement graphique (GPU) multi cœurs à hautes performances et d'autres unités de traitement similaires.

Toutefois, ces unités sont chères et consomment de grandes quantités d'énergie. C'est là que Google Colab entre en jeu.

C'est un service hébergé de notebooks Jupyter qui s'exécute dans le Cloud et stocke ses notebooks sur Google Drive et peut être chargé depuis « GitHub ». Il ne nécessite aucune configuration et il permet d'accéder gratuitement à des ressources informatiques, dont des GPU.

C'est une plate-forme puissante pour apprendre et développer rapidement des modèles d'apprentissage profond en Python. Le tableau 3 ci-dessous présente les différents environnements d'exécution proposés par Colaboratoire google.

Tableau 3 : Spécifications des différents environnements d'exécution proposés par Colaboratoire google

CPU	GPU	TPU
Intel Xeon Processor with two Cores @ 2.30 GHz and 13 GB RAM	Up to Tesla K80 with 12 GB of GDDR5 VRAM, Intel Xeon Processor with two cores @ 2.20 GHz and 13 GB RAM	Cloud TPU with 180 teraflops of computation, Intel Xeon Processor with two cores @ 2.30 GHz and 13 GB RAM

3.4.2. Python

Python est le langage de programmation utilisé dans ce travail grâce à sa popularité, sa facilité d'utilisation et son abondance de bibliothèques et de frameworks qui facilitent le codage et font gagner du temps de développement.



Figure 28 : Logo Python

L'apprentissage automatique et l'apprentissage profond sont exceptionnellement bien pris en charge.

Dans notre programme nous avons utilisé principalement la bibliothèque « Keras » qui est une bibliothèque open source. Elle facilite l'exécution de nouvelles expériences de réseaux de neurones profonds.



Figure 29 : Logo Keras

3.5. Métrique d'évaluation

Il existe des nombreuses techniques d'évaluation de performance des modèles de classification. Dans ce travail, nous utilisons les valeurs de précision (accuracy) pour indiquer le pourcentage de bonnes prédictions de la classification d'IM.

La valeur de la précision est égale à la division de nombre de prédictions correctes (positives et négatives) par la totale des prédictions (nombre total d'échantillons évalués). Nous cherchons à avoir des pourcentages les plus proches possibles de 100%.

Pour mesurer les performances des classifieurs, il faut distinguer quatre types d'éléments classés pour la classe souhaitée, à savoir TP (True Positive), TN (True Negative), FP (False Positive), et FN (False Negative). La figure 30 présente la définition générale de la confusion.

		Classe réelle	
		-	+
Classe prédite	-	True Negatives (vrais négatifs)	False Negatives (faux négatifs)
	+	False Positives (faux positifs)	True Positives (vrais positifs)

Figure 30 : La définition de la matrice de confusion

Nous prenons l'exemple de deux classes d'IM (mouvement de la main droite et mouvement de la main gauche)

- **Vrai positif (TP pour True Positif) :** où la prédiction est positive, et la valeur réelle est aussi positive. Par exemple si on a prédit mouvement de la main droite (ou mouvement de la main gauche), la valeur réelle est mouvement de la main droite (ou mouvement de la main gauche).
- **Vrai négatif (TN pour True Negative) :** où la prédiction est négative, et la valeur réelle est aussi négative. Par exemple si on a prédit un mouvement de la main gauche (ou mouvement de la main droite), la valeur réelle est mouvement de main gauche (ou mouvement de main droite).
- **Faux positif (FP pour False Positif) :** où la prédiction est positive, mais la valeur réelle est négative. Par exemple si on a prédit un mouvement de la main droite (ou mouvement de main gauche), la valeur réelle est mouvement de la main gauche (ou mouvement de main droite).

- **Faux négatif (FN pour False Négatif)** : où la prédiction est négative, mais la valeur réelle est positive. Par exemple si on a prédit mouvement de la main gauche (ou mouvement de main droite), la valeur réelle est mouvement de main droite (ou mouvement de main gauche).

L'équation (2) définit la métrique de précision (*Accuracy*) :

$$\text{Précision} = (TP + TN) / (TP + TN + FP + FN) \quad (2)$$

3.6. Etape d'apprentissage

Pour un apprentissage efficace des données, les paramètres dus ont été discuté : l'optimiseur (optimizer), et la fonction de perte (loss function).

3.6.1. Optimiseur

Nous avons testé deux optimiseur ADAM et RMSprop :

- **Adam (Adaptive Moment Estimation)** est un algorithme d'optimisation qui peut être utilisé à la place de la procédure classique de descente de gradient stochastique pour mettre à jour les poids du réseau de manière itérative en fonction des données d'apprentissage.
- **RMSprop** est un algorithme d'optimisation inédit et conçu pour les réseaux de neurones. Cet algorithme prêt à l'emploi est utilisé comme outil pour les méthodes de mesure du taux d'apprentissage adaptatif.

Il peut être considéré comme une adaptation de l'algorithme rprop qui a initialement motivé son développement pour l'apprentissage par mini-batch.

Il peut également être considéré comme similaire à Adagrad, qui utilise le RMSprop pour ses taux d'apprentissage décroissants. L'algorithme est également utilisé comme algorithme RMSprop et algorithme d'optimisation Adam dans les applications d'apprentissage en profondeur, de réseaux neuronaux et d'intelligence artificielle.

3.6.2. Fonction de perte

Dans cette recherche, l'entropie croisée catégorique '*categorical cross-entropy*' est utilisée comme fonction de perte. Cette fonction est utilisée pour comparer la distribution des prédictions avec la vraie.

3.7. Résultats expérimentaux

Nous avons perfectionné les modèles CNN, RNN et LSTM bidirectionnel avec 250, 500, 750 et 1000 époques (ce sont des hyperparamètres qui définissent le nombre de passages de l'ensemble des données d'apprentissage dans le modèle). Le taux d'apprentissage utilisé est de 0,0001.

Nous avons évalué ces trois modèles proposés avec deux optimiseurs ADAM et RMSprop. Ils sont des algorithmes d'optimisation basés sur la descente de gradient. Ils adaptent automatiquement le taux d'apprentissage pour chaque paramètre.

Nous avons divisé la base de données en deux partitions : 90% pour la phase d'apprentissage et 10% pour la phase de test.

3.7.1. Classification basée sur le modèle CNN proposé

L'architecture CNN que nous avons proposée est détaillée dans le chapitre précédent. Les résultats de la précision de la classification sont donnés par le tableau ci-dessous.

Tableau 4 : La précision (en %) de la classification obtenue par l'application du modèle CNN proposé en utilisant deux optimiseurs différents.

Nombre des époques	Les optimiseurs	
	Adam	RMSprop
250	44	56
500	64	54
750	60	62
1000	44	52

D'après le tableau 4, nous remarquons que notre modèle CNN a donné la plus grande valeur de précision qui est de l'ordre de 64% avec l'optimiseur ADAM sur 500 époques.

3.7.2. Classification basée sur le modèle RNN proposé

L'architecture du modèle RNN que nous avons proposé est détaillée dans le chapitre précédent. Les résultats de la précision de la classification sont donnés par le tableau ci-dessous.

Tableau 5 : La précision (en %) de la classification obtenue par l'application du modèle RNN proposé en utilisant deux optimiseurs différents.

Nombre des époques	Les optimiseurs	
	Adam	RMSprop
250	96	56
500	64	40
750	94	42
1000	98	58

D'après le tableau 5, nous remarquons que le modèle RNN proposé a donné la plus grande valeur de précision qui est égale à 98% avec l'optimiseur ADAM sur 1000 époques.

On peut remarquer aussi que les faibles valeurs de précision sont obtenues avec l'optimiseur RMSprop.

3.7.3. Classification basée sur le modèle LSTM bidirectionnel proposé

L'architecture du modèle LSTM bidirectionnel proposé que nous avons proposé est détaillée dans le chapitre précédent. Les résultats de la précision de la classification sont donnés par le tableau ci-dessous.

Tableau 6 : La précision (en %) de la classification obtenue par l'application du modèle LSTM bidirectionnel proposé en utilisant deux optimiseurs différents.

Nombre des époques	Les optimiseurs	
	Adam	RMSprop
250	58	46
500	68	50
750	56	46
1000	62	50

D'après le tableau 6, nous remarquons que le modèle LSTM bidirectionnel a donné la plus grande valeur de précision avec l'optimiseur ADAM sur 500 époques. Cette valeur est égale à 68%.

On peut remarquer aussi que des faibles valeurs de précision sont obtenues avec l'optimiseur RMSprop. Elles atteignent 50 % sur 500 et 1000 époques.

3.7.4. Étude comparative entre les trois modèles proposés

D'après les tableaux 4, 5 et 6, nous pouvons conclure que les résultats obtenus avec l'utilisation de l'optimiseur Adam sont meilleurs que celles obtenus avec l'utilisation de l'optimiseur RMSprop.

On peut noter aussi que l'optimiseur Adam est plus performant dans les modèles d'apprentissage profond. Il adapte automatiquement le taux d'apprentissage pour chaque paramètre afin de maximiser la fonction de validation.

Une étude comparative entre les trois modèles proposés utilisant l'optimiseur Adam et RMSprop sont illustrées respectivement dans les figures 31 et 32.

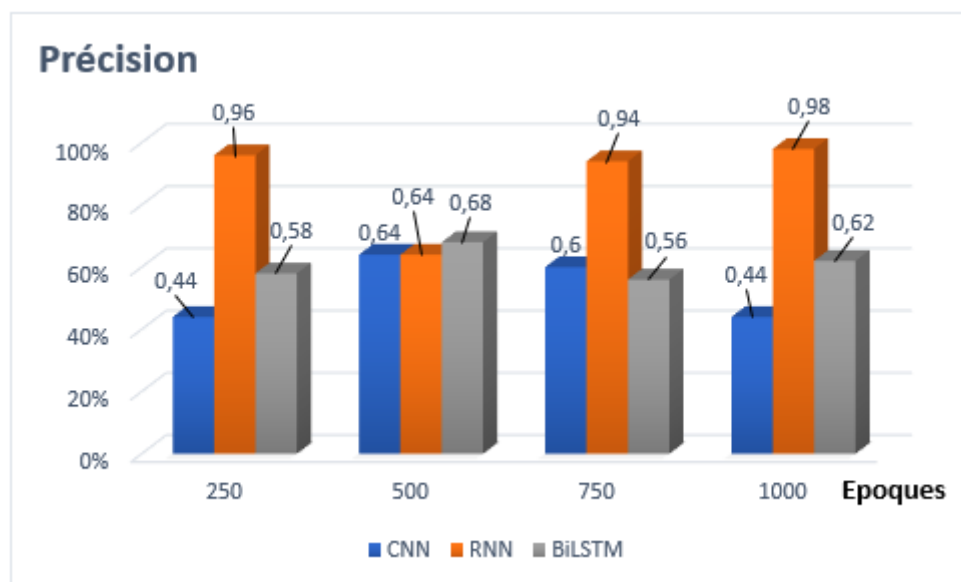


Figure 31 : Les valeurs de précision obtenues par l'application de trois modèles proposés avec l'utilisation de l'optimiseur Adam.

La figure 31 résume les valeurs de précision obtenues par l'application des trois modèles proposés : CNN, RNN et le BiLSTM avec l'optimiseur Adam.

La valeur de précision la plus importante est de 98%. Elle est obtenue avec le RNN après 1000 époques.




Figure 32 : Les valeurs de précision obtenues par l'application de trois modèles proposés avec l'utilisation de l'optimiseur RMSprop.

La figure 32, nous permet de constater qu'avec le modèle RNN proposé nous avons obtenu des valeurs significatives en termes de précision de la classification, 96%, 64%, 94% et 98% respectivement après 250 époques, 500 époques, 750 époques et 1000 époques.

Nous remarquons que ce modèle est le gagnant sur toutes les époques sauf après 500 époques le modèle LSTM bidirectionnel prend le pas sur lui et réalise une précision à l'ordre de 68%.

Nous pouvons déduire que le LSTM bidirectionnel n'atteint souvent pas la meilleure valeur de précision. Ce qui signifie que le double transfert entre deux cellules LSTM successifs n'atteint pas des résultats excellents.

Le modèle CNN proposé a acquis des mauvais résultats par rapport aux deux autres modèles proposés. En effet, il atteint sa valeur de précision maximale après 500 époques de l'ordre de 64%. Par conséquent, il nécessite un processus d'extraction de caractéristiques plus performantes pour améliorer ses résultats.

Nous pouvons conclure que le modèle RNN proposé est le meilleur choix pour la classification des mouvements d'IM par rapport aux autres classifieurs.

3.8. Discussion

Notre méthode proposée qui est basée sur le modèle RNN a donné des résultats très prometteurs, avec une précision maximale de l'ordre de 98% (1000 époques).

Le tableau suivant présente une comparaison entre notre méthode proposée et quelques méthodes de l'état de l'art, en termes de précision de la classification.

Tableau 7 : Tableau comparative entre la méthode proposée et quelques méthodes de l'état de l'art.

Référence	Modèle utilisé	Valeur de la précision
[41]	CNN et LSTM	96,5%
[45]	CNN modifié	74%
[43]	DCNN-LSTM	70,64%
[51]	Fusion CNN/LSTM	61,68%
Méthode proposée	RNN	98%

La comparaison prouve que notre méthode proposée basée sur le modèle RNN surpasse les autres modèles en termes de précision de la classification.

Dans [41], les auteurs ont proposé une architecture d'apprentissage profond basé sur les réseaux de neurones convolutifs (CNN) et la mémoire à long-court terme (LSTM) pour la détection et la classification de mouvements d'imagination motrice des signaux EEG à l'aide d'un BCI headband peu coûteux et peu invasif couplé à un téléphone portable, via l'application Mind-monitor. Ils ont utilisé un petit jeu de données qui comprend 4 utilisateurs, 3 femmes et 1 homme, dont 3 utilisateurs pour la formation et la validation et un utilisateur pour les tests du modèle. Ils sont âgés entre 33 à 55 ans et sont en bonne santé. La couche CNN est utilisée pour extraire les caractéristiques les plus pertinentes des 5 ondes cérébrales. Elle détecte mieux la composante spatiale des données. Les couches LSTM sont utilisées pour classer la série chronologique. Elles sont adaptées aux séries temporelles où les décalages entre les événements sont incertains. Les résultats obtenus donnent une précision de l'ordre de 96,5%.

Dans [45], les auteurs ont appliqué deux méthodes de classification basée sur l'apprentissage en profondeur avec une tentative d'atteindre la meilleure par une comparaison entre les deux

modèles CNN et LSTM. Ils ont utilisé les données EEG d'imagination motrice multi-classes (4 classes d'IM) de l'ensemble de données BCI Competition IV 2a qui comprend 9 sujets, pour tester deux méthodes de classification. Pour chaque sujet, les données EEG comportent 288 essais de la tâche MI de quatre classes et chaque classe a été testée 72 fois. Les résultats obtenus montrent que le modèle CNN modifié surpasse le modèle RNN-LSTM modifié en termes de valeur de précision qui est de l'ordre de 74%.

Dans [43], les auteurs ont proposé une méthode de classification dans laquelle les signaux EEG sont transformés en images qui préservent les dimensions spatiales-fréquentielles des signaux en utilisant des algorithmes d'apprentissage profond. Le modèle proposé est composé de LSTM sur le dessus de CNN. Les auteurs ont utilisé un ensemble de données Physionet, qui comprend 109 sujets, et les signaux EEG d'imagination motrice pour trois bandes de fréquences (Mu [8-13 Hz] et Bêta [13-30 Hz], Delta [0,5-4 Hz]) ont été transformés en images à trois canaux à l'aide d'une projection azimutale équidistante (AEP), pour projeter l'espace des électrodes 3D dans un plan 2D, et de l'algorithme d'interpolation de Clough-Tocher et ainsi l'obtention des images 2D. Six sujets ont été exclus car leurs enregistrements ne sont pas adaptés, l'analyse a été donc appliquée sur 103 sujets. Les images 2D représentent les données d'entrée de DCNN qui sont utilisées pour extraire les caractéristiques fréquentielles et spatiales. Un LSTM est appliqué pour extraire les caractéristiques temporelles et classer les résultats en 5 classes différentes (4 tâches d'IM et un repos). Ils ont obtenu une précision de classification moyenne de l'ordre de 70,64 %.

Dans [51], les auteurs ont proposé deux méthodes de classification basées sur la fusion de deux modèles de réseaux de neurones convolutifs (CNN). La première méthode de fusion des CNNs comprend un CNN1 qui contient 5 blocs (chaque bloc contient une couche de convolution, Batch Normalization et Max Pooling, puis une couche Flatten) et un CNN2 qui contient 4 blocs (chaque bloc contient une couche de convolution et Max Pooling, suivi ensuite d'un LSTM et d'un Flatten). La seconde méthode de fusion des CNNs implique un CNN1 qui contient 5 blocs (chaque bloc contient une couche de convolution, Batch Normalization et Max Pooling, suivi d'une couche Flatten) et un CNN2 qui contient 4 blocs (chaque bloc contient une couche de convolution, Batch Normalization et Max Pooling, et une dernière couche Flatten). Ils ont utilisé l'ensemble de données BCI Competition IV 2a, qui comprend 9 sujets sains enregistrés en deux sessions où les sessions comportent 288 essais de 4 s chacune. La première méthode proposée, basée sur la fusion des CNN et l'ajout d'une couche LSTM, a donné la meilleure valeur de précision de 61,68 %.

Nous pouvons résumer les principaux résultats obtenus dans ce travail comme suit :

- Notre méthode proposée basée sur le modèle RNN fournit la meilleure valeur de précision de la classification, cela revient :
 - aux caractéristiques des signaux EEG, qui ont une résolution temporelle forte.
 - au modèle RNN qui est l'un des meilleurs modèles pour l'extraction des résolutions temporelles.
- Notre méthode proposée basée sur le modèle CNN fournit des faibles valeurs de précision de la classification, cela revient :
 - aux caractéristiques des signaux EEG, qui ont une faible résolution spatiale.
 - au modèle CNN qui est l'un des meilleurs modèles pour l'extraction des résolutions spatiales.

3.9. Conclusion

Dans ce chapitre, nous avons présenté la démarche de la réalisation de notre solution proposée pour la classification des mouvements d'IM multi-classes en se basant sur des méthodes d'apprentissage profond.

Nous avons proposé trois méthodes différentes basées sur le CNN, le RNN et le LSTM bidirectionnel. Une étude comparative nous amène à choisir la meilleure méthode qui nous donne la valeur de précision de classification la plus élevée.

Ces résultats peuvent être aussi développés dans les futurs travaux tout en améliorant la phase de prétraitement et la phase d'extraction des caractéristiques, pour mieux classer les tâches d'IMs.

Conclusion Générale

Nous nous sommes intéressés durant ce travail de recherche aux interfaces cerveau machine non invasives utilisant des mesures de l'activité cérébrale par l'électroencéphalographie (EEG) et basées sur l'imagination motrices multi classes. Notre objectif est de classifier les mouvements l'imagination motrice à l'aide de méthodes d'apprentissage profond.

Nous avons commencé ce manuscrit par présenter quelques notions de base du fonctionnement d'une ICM ainsi que quelques généralités sur le système nerveux pour expliquer l'origine de l'activité électrique cérébrale.

Puis, nous avons étudié les principales techniques d'acquisition en mettant l'accent sur l'Electroencéphalographie (EEG) et nous avons présenté les phénomènes neurophysiologiques les plus utilisés dans la création des ICMs.

Ensuite, nous avons cité les approches et les principaux travaux existant dans le domaine classification des mouvements d'IM à l'aide des méthodes d'apprentissage profond.

Par la suite, nous avons présenté notre démarche pour la problématique posée. Pour ce faire nous avons proposé trois méthodes basées sur le CNN, le RNN, et le LSTM bidirectionnel.

Nous avons comparé les résultats obtenus et nous avons déduit que la méthode proposée basée sur le modèle RNN est la plus efficace pour la classification des tâches d'IM en obtenant un bon taux de précision.

Afin de montrer la faisabilité de notre démarche, nous avons comparé les résultats obtenus par notre système avec d'autres approches de l'état de l'art. D'après les évaluations menées dans ce mémoire, nous avons montré que notre méthode proposée basée sur le modèle RNN atteint de bons résultats et assure une précision de l'ordre de 98%.

Dans nos futurs travaux, nous pensons à jouer de plus sur le prétraitement pour augmenter le rapport signal sur bruit. De plus, nous voulons augmenter le nombre de couche ainsi qu'améliorer les techniques de prétraitement et d'extraction des caractéristiques, pour mieux classifier les tâches d'IM et améliorer encore la précision de la classification.

Références

1. F. Lotte. Les Interfaces Cerveau-Ordinateur: Conception et Utilisation en Réalité Virtuelle. *Revue des Sciences et Technologies de l'Information - Série TSI : Technique et Science Informatiques*, Lavoisier, 31 (3), pp.289-310. hal-00659822v2. 2012.
2. D. Elstob et E. Lindo Secco. A low cost EEG based BCI prosthetic using motor imagery. *International Journal of Information Technology Convergence and Services (IJITCS)*, Vol.6, No.1. 2016.
3. L. Fernando, N. Alonso et J. Gomez-Gil. Brain Computer Interfaces, a Review. *Sensors* 2012, 12, 1211-1279; doi: 10.3390/s120201211.
4. D. Yang, T. Nguyen, et W. Chung. A Synchronized Hybrid Brain-Computer Interface System for Simultaneous Detection and Classification of Fusion EEG Signals. *Hindawi Complexity*. Volume 2020, Article ID 4137283, 11 pages. <https://doi.org/10.1155/2020/4137283>.
5. M. Bekaert, C. Botte-Lecocq, F. Cabestaing, A. Rakotomamonjy. Les interfaces Cerveau-Machine pour la palliation du handicap moteur sévère. *Sciences et Technologies pour le Handicap*, Lavoisier, 2009, 3 (1), pp.95-121. 10.3166/sth.3.95-121. hal-00521052.
6. B. RIVET, A. SOULOUMIAC. Extraction de potentiels évoqués P300 pour les interfaces cerveau-machine. Colloque GRETSI, 11-14 septembre 2007, Troyes.
7. A. Lécuyer. Commander « par la pensée » avec les interfaces cerveau-ordinateur ? D'après la conférence d'Anatole Lécuyer.
8. S.N. Abdulkader, A. Atia, M.S. Mostafa. Brain computer interfacing: Applications and challenges. *Article, Egyptian Informatics Journal* (2015) 16, 213–230.
9. T. Demazure, A. Karran, É. Labonté-LeMoyne, P.M. Léger, S. Sénécal, M. Fredette, Gilbert Babin. Enhancing sustained attention, a brain-computer interface integration to enterprise information systems HEC Montréal, Montréal, QC H3T 2A7, Canada (2018).
10. J. Fruitet. Interfaces Cerveau-Machines basées sur l'imagination de mouvements brefs : vers des boutons contrôlés par la pensée. *Traitement du signal et de l'image [eess.SP]*. Université Nice Sophia Antipolis, 2012. Français. tel-00838704.
11. R. Flamary. Apprentissage statistique pour le signal: applications aux interfaces cerveau-machine. *Machine Learning [stat.ML]*. Université de Rouen, 2011. Français. tel-00687501.

12. K. Belwafi. Conception d'une architecture embarquée adaptable pour le déploiement d'applications d'interface cerveau machine. Interface homme-machine [cs.HC]. Université de Cergy Pontoise; Ecole Nationale d'Ingénieurs de Sousse (Tunisie), 2017. Français. NNT : 2017CERG0896. tel-01778144.
13. L.F. Nicolas-Alonso et Jaime Gomez-Gil. Brain Computer Interfaces, Review. Sensors 2012, 12, 1211-1279; doi:10.3390/s120201211.
14. X. Artusi. Interface Cerveau Machine avec adaptation automatique à l'utilisateur. Apprentissage [cs.LG]. Ecole Centrale de Nantes (ECN), 2012. Français. tel-00822833.
15. B. Bioulac, B. Jarry et R. Ardaillou. Interfaces cerveau-machine : essais d'applications médicales, technologie et questions éthiques.
16. <https://www.frcneurodon.org/comprendre-le-cerveau/a-la-decouverte-du-cerveau/anatomie-du-cerveau-et-du-systeme-nerveux/>
17. M. Besserve. Analyse de la dynamique neuronale pour les Interfaces Cerveau-Machines : un retour aux sources. Interface homme-machine [cs.HC]. Université Paris Sud - Paris XI, 2007. Français. tel-00559128.
18. Dr Vital. Le cerveau, le plus mystérieux de nos organes. Mis à jour le 18 mai 2017. https://www.doctissimo.fr/html/sante/mag_2001/mag0713/sa_4280_cerveau_definition.htm.
19. S. Rousseau. Influence du retour sensoriel dans les interfaces cerveau-machine EEG : Etude du potentiel d'erreur, 2012.
20. <https://sante.lefigaro.fr/sante/organe/cerveau/quoi-sert-cerveau>
21. <https://parlonssciences.ca/ressources-pedagogiques/documents-dinformation/architecture-du-cerveau>.
22. A. Akrouf. Classification des signaux EEG pour l'utilisation d'Interfaces Cerveau-Machine dans des applications d'imagination motrice, 2021.
23. C. Lindig-Leon. Classification multilabels à partir de signaux EEG d'imaginations motrices combinées: application au contrôle 3D d'un bras robotique, 2017.
24. S. Rousseau. Influence du retour sensoriel dans les interfaces cerveau machine EEG : étude du potentiel d'erreur. Traitement du signal et de l'image [eess.SP]. Université de Grenoble, 2012. Français. NNT : 2012GRENT101. tel-01558106.
25. R. Grandchamp. Electroencéphalographie et Interfaces Cerveau-Machine : nouvelles méthodes pour étudier les états mentaux, 2012.

26. R.N. ROY. Étude de corrélats électrophysiologiques pour la discrimination d'états de fatigue et de charge mentale: Apports pour les interfaces cerveau machine passives, 2006.
27. M. Perrin. Coadaptation cerveau machine pour une interaction optimale : application au P300-Speller. Neurosciences [q-bio.NC]. Université Claude Bernard - Lyon I, 2012. Français. NNT : 2012LYO10329. tel-01618163.
28. A. Duprés. Interface cerveau-machine hybride pour pallier le handicap causé par la myopathie de duchenne, 2016.
29. A. Barachant. Commande robuste d'un effecteur par une interface cerveau machine EEG asynchrone. Traitement du signal et de l'image [eess.SP]. Université de Grenoble, 2012. Français. NNT : 2012GRENT112. tel-01196752.
30. A. López, F. Ferrero, O. Postolache. An Affordable Method for Evaluation of Ataxic Disorders Based on Electrooculography. *Sensors* 2019; 19(17):3756. <https://doi.org/10.3390/s19173756>
31. E. Libessart. Interface cerveau-machine : de nouvelles perspectives grâce à l'accélération matérielle. Electronique. Ecole nationale supérieure Mines-Télécom Atlantique, 2018. Français. NNT : 2018IMTA0105. tel-02017104.
32. H. Shan, H. Xu, S Zhu, B He. "A novel channel selection method for optimal classification in different motor imagery BCI paradigms", *BioMed Eng OnLine*, 2015, pp. 1-18, Vol. 14, No.93.
33. H. Dose, J. S. Møller, S. Puthusserypady et H. K. Iversen. (2018). A Deep Learning MI-EEG Classification Model for BCIs. In *Proceedings of 2018 26th European Signal Processing Conference* (pp. 1690-93). IEEE. <https://doi.org/10.23919/EUSIPCO.2018.8553332>.
34. K. Roots, Y. Muhammad et N. Muhammad. Fusion Convolutional Neural Network for Cross-Subject EEG Motor Imagery Classification. *Computers* 2020, 9, 72; doi: 10.3390/computers9030072.
35. S. Roy, A. Chowdhury, K. McCreddie et G. Prasad. Deep Learning Based Inter-subject Continuous Decoding of Motor Imagery for Practical Brain-Computer Interfaces. September 2020, Volume 14, Article 918. *Frontiers in Neuroscience*, www.frontiersin.org.
36. Y. R. Tabar, U. Halici. A novel deep learning approach for classification of EEG motor imagery signals. 2017 *J. Neural Eng.* 14 016003.

37. L. Mousapour, F. Agah, S. Salari, M. Zare. A Novel Approach to Classify Motor-Imagery EEG with Convolutional Neural Network Using Network Measures. 2018 4th Iranian Conference on Signal Processing and Intelligent Systems (ICSPIS). 978-1-7281-1194-0/18/\$31.00 ©2018 IEEE.
38. F. Li, F. He, F. Wang, D. Zhang, Yi Xia, X. Li. A Novel Simplified Convolutional Neural Network Classification Algorithm of Motor Imagery EEG Signals Based on Deep Learning. *Appl. Sci.* 2020, 10, 1605; doi: 10.3390/app10051605. www.mdpi.com/journal/applsci.
39. Z. Tang, C. Li, S. Sun. Single-trial EEG classification of motor imagery using deep convolutional neural networks. 0030-4026/© 2016 Elsevier GmbH. All rights reserved. *Optik* 130 (2017) 11–18.
40. X. Lun, Z. Yu, T. Chen, F. Wang et Y. Hou. (2020), A Simplified CNN Classification Method for MI-EEG via the Electrode Pairs Signals. *Front. Hum. Neurosci.* 14:338. doi: 10.3389/fnhum.2020.00338.
41. F. M. Garcia-Moreno, M. Bermudez-Edo, M. J. Rodríguez-Fórtiz, J. L. Garrido. A CNN-LSTM Deep Learning Classifier for Motor Imagery EEG Detection Using a Low-invasive and Low-Cost BCI Headband. Authorized licensed use limited to: UNIVERSITE DE SFAX. Downloaded on January 28, 2021 at 19:31:27 UTC from IEEE Xplore. 978-1-7281-6158-7/20/\$31.00 ©2020 IEEE.
42. Caglar Uyulan. Development of LSTM&CNN Based Hybrid Deep Learning Model to Classify Motor Imagery Tasks, 2020.
43. W. Fadel , C. Kollod, M. Wahdow, Y. Ibrahim, I. Ulbert. Multi-Class Classification of Motor Imagery EEG Signals Using Image-Based Deep Recurrent Convolutional Neural Network. Conference Paper · February 2020 DOI: 10.1109/BCI48061.2020.9061622.
44. L. Wang, W. Huang, Z. Yang, C. Zhang. Temporal-spatial-frequency depth extraction of brain-computer interface based on mental tasks. *Biomedical Signal Processing and Control* 58 (2020) 101845.
45. A. Echtioui, W. Zouch, M. Ghorbel, C. Mhiri, et H. Hamam, Multi-class Motor Imagery EEG Classification using Convolution Neural Network. DOI: 10.5220/0010425905910595 In Proceedings of the 13th International Conference on Agents and Artificial Intelligence (ICAART 2021) - Volume 1, pages 591-595 ISBN: 978-989-758-484-8 Copyrightc 2021 by SCITEPRESS – Science and Technology Publications, Lda.
46. <https://knowledgeone.ca/mini-glossaire-de-lintelligence-artificielle/?lang=fr>.

47. C. Brunner, R. Leeb, G. R. Müller-Putz, A. Schlögl, G. Pfurtscheller. BCI Competition 2008 – Graz data set A.
48. <https://actualiteinformatique.fr>
49. <https://www.lebigdata.fr>
50. <https://whatis.techtarget.com/fr>
51. A. Echtioui, W. Zouch, M.Ghorbel, C. Mhiri et H.Hamam. Fusion Convolutional Neural Network for Multi-Class Motor Imagery of EEG Signals Classification. 978-1-7281-8616-0/21/\$31.00 ©2021 IEEE.

Classification multi-classes des signaux EEG d'imagination motrice à l'aide des méthodes d'apprentissage profond

Sana BELGACEM

Résumé. L'imagerie motrice (IM), où les utilisateurs imaginent les mouvements des membres pour contrôler le système, est un sujet de recherche important dans le créneau des Interfaces Cerveau-Machine (ICM). De nombreuses techniques sont développées pour améliorer les performances de classification des signaux d'imagerie motrice (IM). Dans ce mémoire, nous avons proposé une méthodologie basée sur les méthodes d'apprentissage profond pour la classification des mouvements d'imagination motrice. Dans un premier lieu, un simple prétraitement est effectué par l'élimination des trois canaux EOG. Dans un deuxième lieu, nous avons extrait les époques d'IM des périodes de 3 s de l'ensemble de données en 288 événements pour les 4 classes d'IM (main droite, main gauche, pieds, langue). Ensuite, nous avons testé trois modèles différents : CNN, RNN-LSTM, BiLSTM. Les résultats de la comparaison sur l'ensemble de données BCI Competition IV 2a prouvent que l'approche proposée basée sur le RNN conduit à de meilleures performances en présentant la valeur de précision la plus élevée par rapport à nos méthodes proposées et aux méthodes de l'état de l'art. La méthode proposée a généré une précision de 98%.

Mots clés : ICM, EEG, IM, CNN, LSTM, BiLSTM.

Abstract. Motor imagery (MI), where users imagine limb movements to control the system, is an important research topic in the Brain-Computer Interfaces (BCI). Many techniques are developed to improve the classification performance of motor imagery (MI) signals. In this work, we have proposed a methodology based on deep learning methods for motor imagery classification. In the first step, simple preprocessing is performed by eliminating the three EOG channels. In the second step, we extracted the MI epochs from the 3 s periods of the dataset into 288 events for the 4 MI classes (right hand, left hand, feet, tongue). Then, we tested three different models: CNN, RNN-LSTM, BiLSTM. The comparison results on the BCI Competition IV 2a dataset prove that the proposed RNN-based approach leads to better performance by presenting the highest accuracy value compared to our proposed methods and state-of-the-art methods. The proposed method generated an accuracy of 98%.

Key-words: BCI, EEG, MI, CNN, LSTM, BiLSTM.